UNIVERSIDAD DE MONTEVIDEO

PROYECTO FINAL DE GRADO

Licenciatura en Ciencia de Datos para Negocios

Comportamiento de compra en una cadena de supermercados de Uruguay

INTEGRANTES:

Maria Bittencourt, Malena Gómez, Tomás Sanguinetti, Paula Planinich

TUTOR: Pablo Fleurquin

Montevideo, 01 de diciembre de 2025

ÍNDICE

RESUMEN EJECUTIVO 3
1. ALCANCE 4
ALCANCE 4
LIMITACIONES 4
METODOLOGÍA 5
CRONOGRAMA 7
SOLUCIÓN ESPERADA 8
2. OBJETIVOS 8
Objetivo general 8
Objetivos específicos 8
3. ASPECTOS DEL NEGOCIO 9
4. MODELO DE CLUSTERIZACIÓN 10
4. 1 INVESTIGACIÓN 10
4. 2 ANALISIS EXPLORATORIO DE DATOS 19
- 4. 2. 1 EXTRACCIÓN DE LOS DATOS 19
- 4. 2. 2 LIMPIEZA DE DATOS 21
- 4. 2. 3 ANÁLISIS EXPLORATORIO 23

4. 3 RESULTADOS OBTENIDOS y MODELLING 31
ANÁLISIS DE LOS CLUSTERS 35
5. POWER BI 44
ENFOQUE DEL DASHBOARD 44
EXTRACCIÓN DE DATOS Y MODELADO 44
PÁGINAS 46
MEDIDAS Y MÉTRICAS UTILIZADAS 55
6. CONCLUSIONES GENERALES 57
BIBLIOGRAFÍA 60
ANEXOS 63
Anexo 1 - Modelo Entidad-Relación de la base de datos 63
Anexo 2 - Gráfica utilizada para determinar la ventana de contexto de Word2Vec 64
Anexo 3 - Distribución de clientes frecuentes y no frecuentes por cluster 65
Anexo 4 – Queries utilizadas para la obtención y transformación de los datos de entrada del PBI 66
Anexo 5 – Medidas y parámetros del dashboard 67
ANÁLISIS ESTADÍSTICO 70

RESUMEN EJECUTIVO

La cadena de supermercados analizada es una de las cadenas minoristas con mayor presencia en Uruguay y uno de los actores más relevantes del sector supermercadista. Su programa de fidelidad genera un volumen muy significativo de información transaccional, que abre múltiples oportunidades de análisis, desarrollo de modelos y entendimiento del negocio. En este contexto, el presente proyecto tuvo como objetivo transformar esta base de datos masiva en información estructurada y analíticamente valiosa, capaz de ofrecer una primera aproximación al comportamiento de compra de los clientes y de apoyar la toma de decisiones estratégicas.

En primer lugar, se desarrolló un análisis integral de los datos del programa de fidelidad, incluyendo limpieza, integración y exploración detallada del comportamiento de consumo. En segundo lugar, se implementó una clusterización demostrativa, basada en representaciones vectoriales de productos obtenidas mediante Word2Vec y el algoritmo de K-Means. Este enfoque permitió condensar la complejidad del universo de productos en vectores numéricos y, a partir de ellos, identificar diferencias sutiles pero coherentes en los patrones de compra entre distintos grupos de clientes.

Por último, se elaboró un dashboard interactivo en Power BI conectado a la base corporativa, que complementa el análisis anterior al ofrecer una visión clara y actualizada de la demanda agregada de la cadena. Esta herramienta permite observar la evolución de las ventas en distintas escalas temporales, identificar estacionalidades, comparar el desempeño entre sucursales, subclases y proveedores, y analizar cómo varía la demanda según formato y canal de venta. Su estructura facilita el monitoreo continuo y contribuye a respaldar decisiones operativas vinculadas a la planificación comercial, la gestión del surtido y el trabajo con proveedores.

Los resultados obtenidos representan un aporte significativo para la empresa. Por un lado, permiten pasar de una visión puramente transaccional a una comprensión más estructurada del comportamiento de los clientes. Por otro lado, brindan insumos que pueden utilizarse para repensar el programa de fidelidad, diseñar incentivos más alineados con los hábitos reales de consumo, identificar oportunidades comerciales y mejorar la capacidad analítica del negocio. Si se ampliara el alcance de datos y la infraestructura de cálculo, estas técnicas podrían evolucionar hacia segmentaciones más precisas y modelos predictivos de gran valor estratégico.

1. ALCANCE

ALCANCE

El presente proyecto tiene como alcance principal el análisis de clientes fidelizados de una cadena de supermercados de Uruguay, utilizando los datos disponibles en su programa de fidelidad. El estudio se centrará en el comportamiento de compra de los clientes, incorporando variables demográficas (edad, género y nivel socioeconómico), transaccionales (frecuencia de compra, volumen, importe de tickets) y de producto (categorías, rubros, marcas y combinaciones adquiridas).

El análisis se desarrollará desde dos dimensiones complementarias:

- Perspectiva transaccional, basada en los tickets de compra como unidad de análisis. Esta aproximación permite estudiar el comportamiento de consumo de manera agregada, considerando cada ticket como una manifestación del acto de compra y, en conjunto, como un reflejo de los patrones generales de comportamiento de los clientes. De esta forma, se busca identificar grupos de tickets con características de consumo similares, que representen distintos tipos de comportamientos de compra dentro del ecosistema de la empresa.
- Perspectiva temporal, orientada a detectar estacionalidades y tendencias a lo largo del tiempo, analizando la evolución del consumo y posibles cambios en las preferencias de los clientes.

El trabajo estará circunscripto a la unidad de negocio de supermercados, ya que constituye el ámbito donde la recolección y sistematización de información se encuentra más avanzada y donde se concentra el interés estratégico de la empresa. No se incluyen dentro del alcance otras unidades de negocio pertenecientes al grupo empresarial.

Asimismo, el análisis se limita al entorno digital y al ecosistema de datos provistos por la empresa, sin contemplar información externa ni aspectos competitivos fuera de la compañía. Tampoco se considera la implementación directa de las propuestas en relación con proveedores; el objetivo es generar herramientas analíticas internas, como dashboards dinámicos y segmentaciones, que sirvan para la toma de decisiones comerciales y la comunicación de resultados.

A pesar de las limitaciones que se plantearán a continuación, el proyecto busca entregar una clusterización de tickets y un dashboard interactivo que permitan a la empresa comprender mejor el comportamiento de sus clientes, detectar oportunidades por segmento y apoyar el diseño de campañas futuras.

LIMITACIONES

El volumen de datos disponible representó uno de los principales desafíos del proyecto. A pesar de haberse aplicado estrategias de reducción y muestreo, el tamaño y la complejidad de las bases superaron la capacidad de procesamiento de los equipos utilizados, lo que limitó la posibilidad de ejecutar ciertos métodos analíticos más avanzados o de extender el análisis a todos los años y sucursales originalmente contemplados. En particular, aunque se contaba con información histórica suficiente como para ampliar el horizonte temporal, hacerlo habría implicado trabajar con un volumen excesivo de datos que hubiera dificultado tanto el procesamiento como la interpretación de los resultados, motivo por el cual se acotó el análisis a los últimos tres años.

Asimismo, la capacidad computacional restringida dificultó la implementación de modelos de mayor exigencia, como los basados en aprendizaje profundo (por ejemplo, autoencoders completos o modelos de clustering como dbscan o hdbdcan), y obligó a priorizar técnicas que equilibraran precisión

y viabilidad operativa. Incluso tras reducir el dataset a subconjuntos manejables, los tiempos de ejecución siguieron siendo elevados, lo que condicionó la profundidad de algunas pruebas.

Esta amplitud de datos también trajo consigo desafíos relacionados con la calidad y consistencia de la información. Se identificaron registros con valores inconsistentes en unidades e importes, especialmente en productos correspondientes a canjes, devoluciones, envases y señas, que presentaban valores negativos o iguales a cero sin un patrón claro que permitiera definir una regla de negocio consistente. Los mismos productos aparecían con valores positivos en otros registros, lo que aumentaba la incertidumbre sobre su interpretación. Tras consultar con el equipo de la empresa, se optó por excluir estas subcategorías del análisis por considerarlas problemáticas y poco confiables.

Otra limitación relevante fue la presencia de clientes con comportamientos aleatorios o esporádicos, particularmente aquellos que realizaron una única compra durante el período analizado. Si bien este grupo es parte del público real, su comportamiento introdujo un nivel de ruido considerable en los modelos de segmentación, dificultando la detección de patrones estables y representativos del conjunto de clientes.

Es importante aclarar que la empresa define al cliente fidelizado como aquel que participa del programa de fidelización y autoriza el uso de sus datos de compra asociados a su número de cédula. Esto implica que el concepto de “cliente fidelizado” utilizado a lo largo del proyecto no necesariamente equivale a un cliente recurrente en la cadena. Esta definición amplia hace que la base de datos incluya tanto consumidores efectivamente fieles como compradores ocasionales, lo cual incrementa la heterogeneidad del conjunto y añade complejidad al análisis.

En el caso particular del dashboard desarrollado en Power BI, la principal limitación estuvo vinculada a la magnitud del volumen transaccional. A diferencia del proceso de modelado, donde fue posible trabajar con una muestra acotada de sucursales y años para facilitar el entrenamiento de los algoritmos, un tablero corporativo requiere abarcar el comportamiento completo de la cadena, sin restringirse a subconjuntos específicos. Esto implicó enfrentar un flujo de miles de transacciones diarias, cuya incorporación directa en el modelo tabular generaba tiempos de carga excesivos, un consumo elevado de recursos y una experiencia de usuario poco fluida. Para mitigar este problema, se optó por construir una tabla transaccional previamente agregada, sacrificando el nivel de detalle compra a compra y cliente a cliente, pero conservando la información necesaria para analizar la demanda por sucursal, subclase y proveedor, que constituía el foco del dashboard.

Asimismo, se definió como horizonte temporal los últimos dos años, tanto por su pertinencia para los objetivos analíticos planteados como por la mayor consistencia y calidad de los registros recientes. Estas decisiones permitieron alcanzar un equilibrio adecuado entre representatividad del dato, rendimiento técnico y usabilidad del tablero, aun trabajando con una tabla que, en su forma final, superó los ocho millones de registros.

METODOLOGÍA

El proyecto se desarrolló con una metodología iterativa, trabajando en ciclos cortos que permitieron ajustar el análisis a medida que avanzaba el proceso y surgían nuevas necesidades o limitaciones. El trabajo se organizó a través de agendas semanales, donde se definían las tareas y objetivos de cada período. Cada semana se realizaba una reunión de seguimiento con el tutor académico para revisar avances, resolver dudas y acordar los pasos siguientes.

En cambio, el contacto con la empresa fue puntual y no estructurado. Se realizaba únicamente cuando era necesario aclarar dudas sobre los datos o validar información específica. Esto generó un flujo de comunicación más reactivo y exigió flexibilidad para adaptar el trabajo según la disponibilidad de respuesta por parte de la empresa.

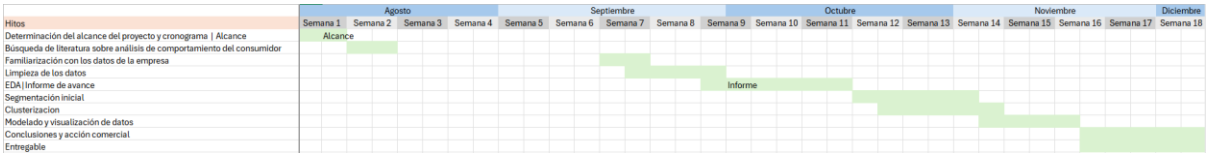
El desarrollo del proyecto se llevó a cabo a través de las siguientes etapas:

- Definición inicial del trabajo: se delimitó el alcance y se elaboró el cronograma, acompañado de una investigación bibliográfica que permitió establecer el marco conceptual y seleccionar las herramientas y técnicas a utilizar.
- Acceso y preparación de datos: se obtuvo acceso a la base, se exportaron los datos a Jupyter Notebook y se realizó la limpieza inicial para corregir problemas de calidad, formato y consistencia.
- Análisis exploratorio: se investigó el comportamiento, distribución y métricas descriptivas de los datos.
- Modelado y segmentación: se aplicaron diferentes métodos (RFM, K-Means, DBSCAN, Word2Vec y Autoencoders), evaluados en función de la investigación previa y las limitaciones computacionales.
- Clusterización: se identificaron los clusters más consistentes y se analizaron sus características para interpretar los distintos patrones de comportamiento de compra.
- Desarrollo del dashboard en Power BI: se construyó una herramienta interactiva orientada al análisis temporal y agregado de las ventas, permitiendo visualizar estacionalidades, variaciones en la demanda y métricas relevantes para la toma de decisiones.
- Conclusiones y recomendaciones: se elaboraron conclusiones basadas en los hallazgos del análisis y se formularon recomendaciones comerciales orientadas a aprovechar oportunidades detectadas y a guiar decisiones estratégicas futuras.

CRONOGRAMA

El cronograma inicial del proyecto debió ser ajustado debido a dificultades de comunicación con la empresa, lo que generó un atraso de aproximadamente cuatro semanas respecto a lo planificado originalmente. Una vez superado este inconveniente, se reordenaron las tareas contempladas en el cronograma, priorizando la extracción y unificación de los datos como paso fundamental para avanzar hacia las siguientes etapas de limpieza, normalización y análisis exploratorio.

Si bien el atraso implicó una reducción en el tiempo disponible para la ejecución técnica, la incorporación de instancias de trabajo adicionales permitió recuperar parte del tiempo y mantener la coherencia entre el alcance definido y los objetivos planteados.



SOLUCIÓN ESPERADA

La solución propuesta busca ofrecer a la empresa una herramienta analítica robusta que permita comprender en profundidad los patrones de consumo de sus clientes, identificando segmentos de comportamiento diferenciados a partir de la información transaccional disponible.

El proyecto apunta a generar una clusterización significativa basada en los tickets de compra, capaz de agrupar comportamientos similares y revelar distintos perfiles de consumo dentro de la red de supermercados. Este enfoque permitiría detectar grupos de clientes con características comunes, como frecuencia de compra, tipo de productos adquiridos, monto promedio del ticket y preferencias de categorías, aportando una visión más clara de las dinámicas que influyen en las decisiones de compra.

Como resultado esperado, se prevé la construcción de un modelo de segmentación interpretable, acompañado de un dashboard interactivo, que facilite la exploración de los datos y la identificación de oportunidades comerciales.

Estas visualizaciones permitirán a la empresa:

- Detectar patrones de compra recurrentes o cambios en las preferencias de los consumidores.
- Identificar segmentos con alto potencial de crecimiento o riesgo de deserción.
- Proporcionar información accionable a las áreas de marketing y proveedores, fomentando estrategias personalizadas de comunicación, promociones o surtido.

Finalmente, desde una perspectiva académica, el proyecto aspira a demostrar la viabilidad de aplicar metodologías avanzadas de análisis de datos a contextos de retail masivo, contribuyendo al desarrollo de modelos replicables en otros sectores de la organización o en futuras investigaciones.

2. OBJETIVOS

Objetivo general

Explorar y comprender en detalle los patrones de compra observados en la cadena a partir de los datos disponibles, con el propósito de generar conocimiento accionable que sirva de apoyo a la toma de decisiones comerciales y estratégicas, y facilite la comunicación de insights hacia proveedores.

Objetivos específicos

- Analizar la dimensión temporal del consumo para reconocer estacionalidades, tendencias y variaciones relevantes en la demanda.
- Explorar posibles agrupamientos o segmentaciones de los tickets de los clientes con base en sus hábitos de compra, a modo de caracterización descriptiva y con fines analíticos.
- Desarrollar herramientas interactivas de visualización que faciliten el monitoreo continuo del comportamiento de los clientes y la comunicación de insights, tanto al interior de la empresa como hacia los proveedores.
- Proporcionar un informe ejecutivo con los principales hallazgos y recomendaciones estratégicas, orientadas a potenciar la relación con los clientes y mejorar la gestión comercial.

Uno de los objetivos iniciales del proyecto era realizar una segmentación centrada en el cliente, con un enfoque más individualizado y orientado al perfil de cada consumidor, analizando su comportamiento a lo largo del tiempo. Sin embargo, este planteo resultó metodológicamente inviable debido a la gran cantidad de datos disponibles, que imposibilitaba trabajar simultáneamente con múltiples sucursales y años de información y mantener una visión transversal del conjunto de clientes. Además, la fuerte presencia de consumidores esporádicos o de baja recurrencia (aquellos que realizaron una única

compra o compras muy aisladas) introducía un nivel de ruido significativo en los modelos, dificultando la identificación de patrones consistentes y representativos del comportamiento real. Por este motivo, se optó por un enfoque alternativo basado en los tickets de compra, que permitió mantener la robustez analítica y obtener una caracterización global del consumo sin comprometer la viabilidad técnica del análisis.

3. ASPECTOS DEL NEGOCIO

El grupo empresarial al que pertenece la cadena es uno de los principales grupos de retail del país, con operaciones en todos los departamentos y presencia tanto física como digital. La compañía integra marcas en distintos rubros, como supermercados, farmacias, tiendas de hogar y electrodomésticos, además de canales de venta online. Su propuesta se centra en la accesibilidad y la cercanía, con un formato de locales que abarca desde grandes hipermercados hasta tiendas de cercanía, adaptándose a las necesidades de distintos segmentos de consumidores.

Uno de los pilares de la propuesta de valor de la empresa es su programa de fidelidad, que cuenta con una amplia base de socios activos. Cada transacción realizada por los clientes queda registrada junto con información demográfica relevante (edad, género, ubicación, nivel socioeconómico). De esta forma, el programa no solo funciona como una herramienta de retención y recompensas, sino también como una fuente estratégica de datos que permite comprender el comportamiento de compra en profundidad y diseñar acciones comerciales más efectivas.

Dentro de las unidades de negocio, los supermercados representan un pilar estratégico. El volumen de clientes fidelizados y la riqueza de la información transaccional los convierten en el espacio más propicio para un análisis avanzado de datos. Comprender en detalle el comportamiento de los clientes resulta fundamental para reforzar la propuesta de valor de la empresa, mejorar la toma de decisiones y sostener la competitividad en un mercado cada vez más dinámico. Esta información, además, representa una oportunidad para fortalecer la relación con los proveedores, al generar insights que potencian la planificación conjunta y la construcción de propuestas de valor compartidas.

Si bien el programa de fidelización constituye una fuente valiosa de información para la empresa, también presenta una limitación conceptual y operativa relevante: los datos disponibles no representan estrictamente a clientes fidelizados, sino únicamente a aquellos que registraron su cédula al momento de la compra. Según Oliver (1999), “la fidelización de clientes es el proceso mediante el cual una empresa desarrolla relaciones duraderas que aumentan la probabilidad de que un consumidor continúe comprando y mantenga una preferencia sostenida por la marca”. Esta definición muestra que la fidelización implica recurrencia y una relación estable con la empresa, algo que no puede deducirse solo porque un cliente registre su cédula en una compra aislada. La fidelización real se refleja en comportamientos sostenidos en el tiempo, sin embargo, el programa actual recoge información solo cuando el cliente voluntariamente ingresa su cédula, lo que no garantiza que todos los compradores registrados sean efectivamente fieles.

Se identifican dos hipótesis principales que explican la falta de registro consistente de compras:

1. Clientes que no ingresan su cédula, ya sea por desconocimiento de los beneficios, falta de hábito, desinterés o ausencia de incentivos percibidos. Este grupo genera transacciones anónimas que reducen la trazabilidad del comportamiento de compra y debilitan el potencial analítico del programa.
2. Clientes que sí ingresan su cédula, pero no están realmente fidelizados, es decir, compradores ocasionales que concurren pocas veces al año. Aunque estén registrados en la base, no

muestran un comportamiento de lealtad o recurrencia, lo que introduce ruido en los análisis orientados a identificar patrones consistentes.

Estas limitaciones representan un desafío estratégico para la empresa, que requiere fortalecer sus mecanismos de fidelización, mejorar la captura de datos y desarrollar incentivos más efectivos para asegurar que las compras queden correctamente asociadas a cada consumidor.

4. MODELO DE CLUSTERIZACIÓN

4. 1 INVESTIGACIÓN

Más del 90% de los clientes que realizan compras en la cadena forman parte del programa de fidelidad, lo que representa una fuente de información sumamente valiosa para la empresa. Este alto nivel de adhesión permite registrar de manera detallada el comportamiento de compra de los consumidores, generando una gran oportunidad para analizar patrones, comprender hábitos y extraer insights estratégicos que contribuyan a una toma de decisiones más informada y basada en datos.

Segmentación y estrategia de mercado

"Estudios han demostrado que resulta más rentable para una empresa mantener a un cliente, que tratar de ganar uno nuevo. El valor de mantener un cliente se debe fundamentalmente a que tiene costos inferiores a los derivados de ganar un nuevo cliente. Por lo tanto, el cuidado de las relaciones de los clientes actuales es una mejor inversión. Económicamente es de 6 a 7 veces más caro conseguir un nuevo cliente que mantener uno que ya tenemos. Y con tan sólo incrementar la inversión en retención de clientes un 5% podrían lograrse incrementos en los beneficios del 5 al 95%. Por tal motivo, las empresas se ven obligadas a invertir tiempo, dinero y esfuerzo en conocer la mayor información que sea posible acerca de sus clientes" (Anita Rojas Huamán, 2020).

Esto cobra aún más sentido si se considera que los mercados pueden alcanzar niveles de saturación, donde captar nuevos clientes resulta cada vez más difícil y costoso. En cambio, los clientes existentes evolucionan constantemente, modificando sus necesidades, preferencias y comportamientos de compra a lo largo del tiempo. Contar con la capacidad de anticipar y predecir esos cambios se vuelve un factor clave para mantener la relevancia de la empresa, fortalecer la relación con sus clientes y generar una ventaja competitiva sostenible en el mercado.

Para alcanzar este objetivo, la segmentación de clientes se convierte en una herramienta fundamental. A través de este proceso, es posible conocer en profundidad a los consumidores, identificando grupos con características, comportamientos y necesidades similares. Esta comprensión permite no solo diseñar estrategias comerciales más efectivas y personalizadas, sino también predecir información relevante sobre su comportamiento futuro, anticipando tendencias, preferencias y posibles oportunidades de negocio. "Se puede definir como "la práctica de dividir una base de clientes en grupos de individuos que son similares en formas especificas relevantes para el marketing, como edad, género, intereses, hábitos de gastos, etc"" (Anita Rojas Huamán, 2020).

Además de mejorar la retención, la segmentación de clientes permite comprender el valor que cada consumidor aporta a la organización y asignar los recursos de manera más estratégica y eficiente. A través de la identificación de patrones de comportamiento, niveles de gasto y frecuencia de compra, las empresas pueden distinguir entre clientes de alto y bajo valor, priorizando esfuerzos comerciales, comunicacionales y de fidelización según su impacto en la rentabilidad.

“Desde el punto de vista de la empresa, para continuar obteniendo ganancias, necesitan dirigir su atención a los clientes que consumen sus productos o servicios con más frecuencia o en grandes volúmenes para crear grupos que sean fructíferos. Es decir, los clientes tienen una importancia diferente y para poder permanecer en el mercado, las empresas deben distribuir su atención de manera desigual, lo que significa que deben trasladar su atención a aquellos clientes que generen mayores ganancias para la empresa.” (Anita Rojas Huamán, 2020)

Beneficios de la segmentación de clientes:

- Definir con precisión los buyer personas, o perfiles representativos de los clientes ideales, permite identificar cómo estos buscan, compran y utilizan un producto o servicio. Este conocimiento posibilita una mejor priorización y orientación de las acciones comerciales, el diseño de mensajes de marketing más efectivos y la mejora en la retención y fidelización de clientes. (Contentsquare, 2024)
- La diferenciación de marca se logra a través de la segmentación, la cual permite alinear la propuesta de valor con las necesidades específicas de cada público objetivo, fortaleciendo así la identidad y posicionamiento de la empresa en el mercado (Adobe Experience Cloud Team, 2025).
- Permite un crecimiento sostenible “cuando las estrategias se adaptan a las necesidades únicas de cada público” (Adobe Experience Cloud Team, 2025).
- “Maximiza el retorno de la inversión al dirigir los esfuerzos hacia donde son más efectivos” (Adobe Experience Cloud Team, 2025).
- Como fue mencionado anteriormente: ayuda a aumentar la retención de clientes, comprender en mayor profundidad la base de clientes y optimizar la asignación de recursos.

En un contexto de creciente competitividad y saturación de los mercados, la supervivencia empresarial se vuelve cada vez más desafiante. En este escenario, la segmentación de clientes se consolida como una herramienta esencial para cualquier negocio, al permitir comprender con mayor precisión las necesidades y comportamientos de los consumidores, optimizar estrategias comerciales y fortalecer la relación con los segmentos más valiosos.

RFM

Entre los muchos modelos utilizados para la segmentación de clientes, el modelo RFM (Recency, Frequency, Monetary) destaca por su simplicidad y eficacia. Este modelo evalúa a los clientes en función de cuán reciente fue su última compra (Recency), con qué frecuencia compran (Frequency) y cuánto gastan (Monetary). Cada una de estas dimensiones aporta información valiosa sobre el nivel de compromiso y el valor que un cliente representa para la empresa. Cuando se combinan, estas métricas permiten construir un perfil robusto que puede emplearse para segmentar clientes y orientar estrategias de marketing más precisas y efectivas. (Yohanni Syahra, Abdul Fadlil, Herman Yuliansyah, 2025, traducción propia)

Las variables se calculan de la siguiente manera:

- Recencia = Fecha de la última transacción en el dataset − Fecha de la última compra del cliente. Representa el número de días transcurridos desde la última compra del cliente.
- Frecuencia = Cantidad total de transacciones realizadas por el cliente en el período de análisis
- Monetario = ∑ (Monto total de cada transacción del cliente)

"El análisis consiste en clasificar a los clientes por su valor en función de las tres variables. Para ello, se construyen escalas, basadas en estas variables, dando a cada cliente un valor según el percentil en que se encuentra. Lo más habitual es escalar por quintiles. Es decir, a todas las variables se le asigna un valor que podría estar entre el 1 y el 5, siendo 1 la peor puntuación y 5 la mejor" (Anita Rojas Huamán, 2020).

En este caso, los clientes más rentables e ideales dentro del modelo RFM son aquellos que presentan las puntuaciones más altas en las tres dimensiones, es decir, un valor 5-5-5. Estos clientes compran con frecuencia, lo hacen recientemente y gastan montos elevados, lo que los convierte en el segmento de mayor valor estratégico para la empresa.

"Por ejemplo, un cliente que estuviera entre el 20% de los que más recientemente han comprado, en el 2º 20% por frecuencia de compra y el 4º 20% en valor total de compras, se le asignaría el segmento 542, (R)5 (F)4 (M)2. Lo vemos en el gráfico:" (Guillermo Córdoba, 2011)

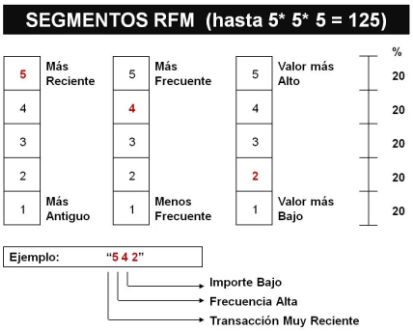


Figura 4.1.1 - Ejemplo de segmentación RFM

Clustering

El clustering constituye una técnica ampliamente utilizada dentro del aprendizaje automático no supervisado, cuyo propósito es identificar grupos de elementos con características similares dentro de un conjunto de datos, con el fin de obtener nuevos insights y facilitar la generación de predicciones. Este enfoque tiene múltiples aplicaciones en diversos ámbitos, entre ellos el reconocimiento de imágenes, la segmentación de clientes y la detección de anomalías. Entre los algoritmos más empleados para este tipo de tareas se destacan DBSCAN y K-Means (Taylor, 2024).

Clustering: K-Means

El algoritmo K-Means pertenece a la familia de métodos de clustering basados en particiones. Asigna a cada punto del conjunto de datos a un único clúster, sin superposición entre ellos ni puntos sin asignar; en consecuencia, genera una partición exhaustiva y mutuamente excluyente del conjunto de datos. Debido a su simplicidad, interpretabilidad y eficiencia computacional, K-Means es ampliamente utilizado en contextos con grandes volúmenes de información (Idrees, 2024).

El funcionamiento del algoritmo puede resumirse en los siguientes pasos:

1. Elegir K: definir el número de clústeres (K), hiperparámetro establecido por quien aplica el algoritmo.
2. Inicializar centroides: ubicar aleatoriamente K centroides (uno por cada clúster) en el espacio de los datos.
3. Asignar puntos a los clústeres: cada punto se asigna al centroide más cercano según la distancia euclidiana.

4. Actualizar centroides: recalcular los centroides tomando la media de todos los puntos asignados a cada clúster.
5. Repetir: repetir el proceso hasta que los centroides no varíen significativamente en su posición (Idrees, 2024).

El objetivo matemático de K-Means es minimizar la función objetivo:

$$J = \sum_{i=1}^{K} \sum_{x \in C_i} \|x - \mu_i\|^2$$

donde K es el número de clústeres, C_i es el conjunto de puntos pertenecientes al clúster i, μ_i es el centroide correspondiente, y ‖x−μi‖^2 representa la distancia cuadrática entre el punto x y su centroide (Idrees, 2024).

Entre las principales ventajas de K-Means se destacan su sencillez, eficiencia computacional, capacidad de escalar a grandes volúmenes de datos y facilidad de interpretación, dado que sus resultados pueden visualizarse fácilmente (Idrees, 2024). No obstante, el algoritmo presenta algunas limitaciones: requiere definir previamente el número de clústeres, es sensible a la presencia de outliers (que pueden alterar de manera significativa la ubicación de los centroides), y asume que los clústeres son esféricos y de tamaño similar, lo cual dificulta su desempeño cuando los datos presentan estructuras más complejas (Idrees, 2024).

K-means: método del codo

La técnica más común para identificar el número óptimo, k, de clusters en el que dividir un conjunto de datos con K-means es el método del codo (elbow method). Este método busca identificar el punto en el que la disminución de la varianza intra-cluster se desacelera, de modo que aumentar el número de clusters no mejorara significativamente la compactación de los datos (Rodriguez, 2023).
Para obtener el k óptimo, se ejecuta el algoritmo de k-means con distintas cantidades de clusters y se calcula, para cada k, la inercia o WCSS (suma de cuadrados dentro del grupo, o within-cluster sums of squares), que corresponde a la suma de las distancias al cuadrado entre los puntos de un grupo y el centroide del mismo.
Al graficar los valores de inercia en función de k, se elige el valor donde se crea el codo, de manera que "aumentar el valor de k no conduce a una reducción significativa en WCSS" (Trovar, 2023).

K-means: silhouette score

La puntuación de la silueta también es una medida utilizada para evaluar qué tan bien quedaron formados los clusters luego de aplicar algoritmos de aprendizaje no supervisado como k-means y, en base a eso, determinar la cantidad óptima de clusters. Mide, para cada dato, qué tan bien ubicado está dentro de su propio cluster, calculando el promedio de la distancia del punto a todos los puntos de su mismo cluster; y qué tan separado está de los demás clusters, calculando para cada cluster distinto al suyo la distancia promedio al punto a ese cluster (Geeks For Geeks, 2025).

$$a(i) = \frac{1}{|C(i)| - 1} \sum_{\substack{j \in C(i) \\ j \neq i}} d(i,j) \qquad b(i) = \min_{j \neq i} \left(\frac{1}{|C(j)|} \sum_{j \in C(j)} d(i,j) \right)$$

Con esto, construye un número entre –1 y 1: un valor cercano a 1 significa que el punto está excelentemente asignado en un grupo y que los grupos son distinguibles, un valor cercano a 0 está en el borde entre dos clusters y los grupos se superponen, y un valor negativo indica que probablemente dicho punto esté mal asignado (Trovar, 2023).

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

Para obtener la medida del algoritmo completo, y así identificar el número óptimo de clusters, se halla el promedio de la puntuación para todos los puntos, y se compara para los distintos valores de k (Geeks For Geeks, 2025).

Clustering: RFM + K-Means

La combinación del modelo RFM con el algoritmo K-Means constituye una de las estrategias más utilizadas para la segmentación de clientes, dada su capacidad para descubrir patrones naturales dentro de grandes volúmenes de datos. Mientras que el modelo RFM permite cuantificar el comportamiento de los consumidores en función de su recencia, frecuencia y valor monetario, K-Means agrupa a los clientes en segmentos homogéneos basados en la similitud de dichos comportamientos. Esta integración facilita la identificación de grupos que no siempre resultan evidentes mediante un análisis tradicional. Diversos estudios han demostrado la efectividad de esta metodología en distintos sectores: Ma (2022) aplicó K-Means sobre datos RFM en el comercio electrónico, mejorando las estrategias de segmentación y targeting; mientras que Paul y Ramanan (2019) evidenciaron un aumento en la retención de clientes en la industria hotelera al combinar ambas técnicas. Del mismo modo, investigaciones más recientes (Tabianan et al., 2022; Nasyuha et al., 2022) destacan que el uso conjunto de RFM y K-Means permite a las empresas minoristas identificar clientes de alto valor, reconocer consumidores inactivos y adaptar sus estrategias de marketing a partir de comportamientos reales. En suma, esta integración no solo enriquece el proceso de toma de decisiones, sino que también promueve un crecimiento sostenible mediante estrategias personalizadas y basadas en datos. (Yohanni Syahra, Abdul Fadlil, Herman Yuliansyah, 2025)

Clustering: DBSCAN

Por su parte, DBSCAN (Density-Based Spatial Clustering of Applications with Noise) es un algoritmo basado en densidad, que agrupa los puntos que se encuentran suficientemente próximos entre sí y clasifica como ruido a aquellos que se encuentran aislados o en regiones de baja densidad (Idrees, 2024).

El procedimiento de DBSCAN puede resumirse de la siguiente manera:

1. Definir parámetros: establecer la distancia máxima (ε) y el número mínimo de puntos (MinPts) requeridos para formar una región densa.
2. Identificar puntos céntricos: determinar los puntos que tienen al menos MinPts vecinos dentro del radio ε.
3. Formar clústeres: conectar los puntos céntricos con sus vecinos para conformar los clústeres.
4. Clasificar el ruido: todo punto que no pertenezca a ningún clúster se clasifica como ruido (Idrees, 2024).

De manera formal, un punto p se considera punto céntrico si existe un conjunto de puntos N(p) tal que:

$$N(p) = \{q \in D \mid dist(p,q) \leq \varepsilon\}, \quad \text{y} \quad |N(p)| \geq MinPts$$

donde D es el conjunto de datos, dist(p,q) es la distancia entre los puntos p y q, y ε es el radio máximo considerado para pertenecer al clúster (Idrees, 2024).

A diferencia de K-Means, DBSCAN no requiere especificar el número de clústeres de antemano, sino que los determina automáticamente según la densidad de los datos. Además, identifica los outliers como ruido, lo que lo hace más robusto frente a observaciones atípicas. También es capaz de detectar

clústeres de formas arbitrarias, no necesariamente esféricas, adaptándose mejor a distribuciones complejas (Idrees, 2024).

Sin embargo, su desempeño depende en gran medida de los valores elegidos para los hiperparámetros ε y MinPts; una selección inadecuada puede conducir a resultados poco representativos. Asimismo, su eficacia disminuye cuando las densidades varían significativamente entre clústeres o cuando el número de dimensiones aumenta, debido a la pérdida de relevancia del concepto de distancia en espacios de alta dimensionalidad (Idrees, 2024).

En síntesis, se recomienda utilizar K-Means cuando se conoce el número aproximado de clústeres, los datos están bien separados o el conjunto es de gran tamaño. Por el contrario, DBSCAN resulta más adecuado cuando el número de clústeres es desconocido, las estructuras son irregulares o el dataset contiene outliers que podrían distorsionar los resultados de K-Means (Idrees, 2024).

Autoencoder

Los Autoencoders son algoritmos de aprendizaje no supervisado diseñados para aprender representaciones útiles de los datos con poca o ninguna supervisión. Según Tschannen, Bachem y Lucic (2018), aprender representaciones significativas con escasa supervisión constituye uno de los desafíos centrales de la inteligencia artificial. Estas redes neuronales aprenden un mapeo desde observaciones de alta dimensión hacia un espacio de representación más reducido, desde el cual las observaciones originales pueden reconstruirse de forma aproximada.

El objetivo principal de un Autoencoder es transformar la entrada en una salida con la menor distorsión posible (Zhang, 2018). Por esta razón, se los utiliza ampliamente para la compresión de datos. Dado que reducen la dimensionalidad de manera no lineal, permiten descubrir representaciones más compactas y relevantes. Esta capacidad surge de la imposición de restricciones estructurales —como limitar el número de unidades ocultas—, lo que obliga al modelo a identificar las regularidades más importantes del conjunto de datos (Ng, 2011).

El uso de Autoencoders también puede mejorar la calidad de la segmentación, al facilitar que los algoritmos de agrupamiento identifiquen patrones menos evidentes. En particular, los Autoencoders Variacionales (VAE) promueven el *desenredo* (*disentanglement*) de las variables latentes, generando representaciones abstractas y concisas de los datos, útiles para diversas tareas posteriores (Tschannen et al., 2018). Además, estos modelos pueden incorporar estructuras de mezcla en las variables latentes, de modo que cada componente corresponda a una categoría específica dentro del conjunto de datos (Tschannen et al., 2018).

Word2Vec

Por otra parte, el *Transfer Learning*, a través de modelos preentrenados como Word2Vec (W2V), permite aprovechar representaciones vectoriales avanzadas de palabras (Goldberg & Levy, 2014). Word2Vec, desarrollado por Mikolov et al. (2013), representa las palabras en un espacio vectorial continuo donde aquellas que comparten contextos similares se ubican próximas entre sí. Dichas representaciones han demostrado capturar significados semánticos y resultar útiles en múltiples tareas de procesamiento del lenguaje natural (Rong, 2014). Además, Word2Vec constituye uno de los antecedentes fundamentales utilizados en arquitecturas modernas de Procesamiento del Lenguaje Natural y ha sido integrado como componente dentro de modelos posteriores de mayor escala, incluyendo los Grandes Modelos de Lenguaje como GPT (Radford et al., 2018).

Esta metodología es especialmente valiosa en contextos empresariales, donde el procesamiento de grandes volúmenes de datos implica un alto costo temporal y computacional. En este sentido, Word2Vec constituye una estrategia eficaz para reducir la dimensión de las características, tanto por la disminución del tiempo de cómputo como por la mejora en el desempeño de las tareas de clasificación (Ma & Zhang, 2015). Al agrupar palabras similares, la dimensión original se proyecta en un nuevo espacio de menor tamaño, lo que acelera el análisis y reduce los costos de procesamiento.

En síntesis, tanto los Autoencoders como Word2Vec buscan generar representaciones más compactas y significativas de los datos, aunque difieren en su propósito y aplicación. Mientras que los Autoencoders se emplean para descubrir estructuras subyacentes mediante reconstrucciones no lineales, Word2Vec está diseñado específicamente para el lenguaje, generando representaciones semánticas a partir del contexto.

Un aspecto clave de Word2Vec es que las relaciones aprendidas entre los vectores pueden evaluarse mediante medidas de proximidad espacial, entre las cuales la similitud de coseno es la más empleada en la literatura. Esta métrica permite cuantificar el grado en que dos elementos comparten patrones de contexto, independientemente de la magnitud de sus vectores, enfocándose únicamente en la orientación en el espacio vectorial. Tal como señalan Turney y Pantel (2010), este enfoque resulta especialmente adecuado para representaciones distribuidas, ya que capta afinidades semánticas emergentes de las coocurrencias sin requerir información categórica previa. En consecuencia, la similitud de coseno constituye una herramienta estándar para identificar proximidad semántica en modelos basados en embeddings, y su aplicación en este trabajo permitió evaluar la coherencia de las relaciones entre productos derivadas del proceso de entrenamiento del modelo (Mikolov et al., 2013; Rong, 2014).

Word2Vec + K-Means

La relación entre Word2Vec y K-means se observa en el uso conjunto de ambas metodologías para optimizar el manejo de grandes volúmenes de texto. Word2Vec permite obtener vectores de palabras y medir su similitud, mientras que K-means agrupa dichos vectores en función de su proximidad, reduciendo la dimensión del espacio original (Ma & Zhang, 2015). De esta forma, K-means actúa como una estrategia de reducción de dimensionalidad al condensar el espacio vectorial en categorías semánticamente coherentes.

Autoencoder + K-Means

De manera análoga, los Autoencoders Variacionales (VAE) comparten con K-means la búsqueda de estructuras latentes que reflejen agrupamientos naturales. Para Tschannen, Bachem y Lucic (2018), la estructura de agrupamiento constituye un *meta-prior* útil para obtener representaciones más informativas, y puede incentivarse mediante la incorporación de distribuciones de mezcla que promuevan la formación de clústeres.

Autoencoder + DBSCAN

Chen, Zhang y Liu (2021) proponen combinar un VAE con el algoritmo DBSCAN dentro de un enfoque de *active learning*. Los autores destacan que el VAE representa adecuadamente los datos de alta dimensión en un espacio latente reducido, mientras que DBSCAN resulta eficaz para identificar ruido y descubrir clústeres sin necesidad de especificar el número de clases de antemano. La combinación de ambos métodos mejora la eficiencia y precisión en la selección de muestras dentro de entornos de alta dimensionalidad.

Word2Vec + DBSCAN

De modo similar al enfoque combinado de VAE y DBSCAN, también es habitual utilizar embeddings de palabras, por ejemplo, generados por Word2Vec, para luego aplicar DBSCAN sobre los vectores de palabras y así descubrir agrupamientos semánticos sin necesidad de fijar el número de clústeres de antemano. En este sentido, el estudio "Influence of various text embeddings on clustering performance in NLP" señala que "DBSCAN supera a K-Means… cuando se aplica sobre embeddings de Word2Vec" (traducido manualmente) (Saha, 2023).

Esta combinación permite agrupar palabras o términos que presentan contextos similares en el espacio vectorial, facilitando la identificación de clústeres semánticos relevantes sin exigir una asignación previa del número de grupos.

Calinski-Harabasz index

El índice de Calinski-Harabasz, también conocido como Criterio de Razón de Varianza, se puede utilizar para evaluar modelos donde no se conocen las etiquetas reales de los datos. El índice es la razón entre la suma de la dispersión entre clusters y la dispersión dentro de los clusters para todos los grupos (donde dispersión se define como la suma de las distancias al cuadrado). (Scikit-learn Developers, s. f., traducción propia)

Para un conjunto de datos E de tamaño n_e, que ha sido dividido en k clusters, el puntaje de Calinski-Harabasz s se define como la razón entre la dispersión media entre clusters y la dispersión dentro de los clusters:

$$s = \frac{\mathrm{tr}(B_k)}{\mathrm{tr}(W_k)} \times \frac{n_E - k}{k - 1}$$

donde $\mathrm{tr}(B_k)$ es el trazo (trace) de la matriz de dispersión entre grupos y $\mathrm{tr}(W_k)$ es el trazo de la matriz de dispersión intra-cluster, definida como:

$$W_k = \sum_{q=1}^{k} \sum_{x \in C_q} (x - c_q)(x - c_q)^T$$

$$B_k = \sum_{q=1}^{k} n_q (c_q - c_E)(c_q - c_E)^T$$

donde:

- C_q es el conjunto de puntos en el cluster q,
- c_q es el centro del cluster q,
- c_E es el centro del conjunto total E,
- n_q es el número de puntos en el cluster q.

(Scikit-learn Developers, s. f., traducción propia)

Los puntajes del índice Calinski-Harabasz son más altos cuando los clusters son densos y están bien separados, lo cual se ajusta al concepto estándar de lo que debe ser un cluster. Además, es un índice rápido de calcular. Sin embargo, presenta una desventaja importante: el valor del índice tiende a ser más alto en clusters de forma convexa en comparación con otros tipos de agrupamiento, como los métodos basados en densidad, por ejemplo los obtenidos mediante DBSCAN. (Scikit-learn Developers, s. f., traducción propia). En línea con esta característica, el índice suele desempeñarse especialmente bien cuando se aplica junto con métodos de clustering que asumen particiones esféricas en el espacio de variables, como K-means, para los cuales su estructura matemática resulta particularmente adecuada.

PCA

PCA (principal component analysis, o análisis de componentes principales) es una técnica de reducción de dimensionalidad en conjuntos de datos reduciéndolos a sus componentes principales, de manera que se conserva la mayor parte de la información. Consiste en transformar variables potencialmente correlacionadas en un conjunto más pequeño de variables (IBM, 2025).

La técnica emplea operaciones matriciales y transforma el conjunto de datos original en uno nuevo que contiene solo los componentes principales: los vectores propios indican la dirección de la varianza, mientras que los valores propios actúan como coeficientes de los vectores propios y denotan la importancia de estas direcciones. De esta manera, el algoritmo toma como primer componente principal al vector propio con mayor valor propio, ya que maximiza la varianza en esa dirección. El segundo componente principal se obtiene de forma análoga, pero debe ser ortogonal al primero para maximizar la explicación de la varianza. El procedimiento se repite para el resto de los componentes principales y las dimensiones que se deseen considerar (IBM, 2025).

t-SNE

t-SNE (t-distributed Stochastic Neighbor Embedding) es una técnica de reducción de dimensionalidad no lineal para la exploración de datos y visualización de datos de alta dimensión (Awan, 2024).

Se diferencia de PCA por ser no lineal y por conservar las similitudes locales (por pares) entre los datos en un espacio dimensional menor, es decir, las relaciones entre los puntos de datos. En contraste, PCA tiene el objetivo de conservar la varianza en un menor espacio de menor dimensión (Awan, 2024).

El algoritmo consiste en tres pasos: Primero calcula las similitudes en alta dimensión, por lo que, para cada par de puntos, calcula qué tan probable es que sean vecinos usando una distribución Gaussiana. Luego intenta reproducir esas similitudes en baja dimensión y calcula las probabilidades de vecindad en ese espacio reducido. Por último, minimiza la diferencia entre ambas distribuciones usando gradient descent, para que las similitudes entre pares de puntos sean lo más parecidas posibles al espacio original (Awan, 2024).

ADF

El test de Dickey-Fuller Aumentado (ADF, por sus siglas en inglés) es una prueba estadística que se utiliza para verificar si una serie temporal es estacionaria o si, por el contrario, sigue un patrón con "memoria larga" en el que los shocks tienden a persistir. En términos sencillos, el ADF contrasta la hipótesis de que la serie tiene una raíz unitaria, es decir, que se comporta como un paseo aleatorio y no vuelve a un nivel promedio estable, frente a la alternativa de que es estacionaria y presenta reversión a la media. En la práctica, esto también permite evaluar si la aparente tendencia de la serie es realmente determinista (por ejemplo, una tendencia lineal que puede modelarse explícitamente) o si se debe a una componente estocástica ligada a la raíz unitaria. Para ello, el test ajusta un modelo que relaciona el cambio actual de la serie con su propio pasado, permitiendo incluir rezagos adicionales para capturar la dinámica temporal, y utiliza un estadístico especial para decidir si se rechaza o no la presencia de raíz unitaria (Dickey y Fuller, 1979; Dickey y Fuller, 1981). En aplicaciones empíricas, el ADF se ha convertido en una herramienta estándar para analizar la estacionariedad de series económicas y financieras antes de especificar modelos de series de tiempo más complejos (Mushtaq, 2011).

t-test

El t-test de una muestra es una prueba estadística básica que se utiliza para comprobar si la media observada de una variable difiere significativamente de un valor de referencia, típicamente cero. Aplicado a la componente estacional de una serie temporal, el test contrasta la hipótesis nula de que

el promedio de esa componente es cero (es decir, que no hay un efecto estacional sistemático) frente a la alternativa de que la media es distinta de cero. Intuitivamente, si el test arroja un p-valor pequeño, se concluye que la componente estacional tiende a desviarse de cero de forma consistente, lo que sugiere la presencia de estacionalidad que no puede atribuirse al azar. Esta idea se apoya en el uso estándar del t-test de una muestra para contrastar medias poblacionales descrito en textos clásicos de estadística aplicada, como Montgomery y Runger (2014).

ANOVA

El análisis de varianza (ANOVA) de un factor es una técnica que permite comparar las medias de varios grupos de manera simultánea, evaluando si las diferencias observadas entre ellos pueden explicarse solo por el azar o si son estadísticamente significativas. En el contexto de una serie de ventas por día, el ANOVA se puede utilizar, por ejemplo, para contrastar si la media de ventas es la misma para todos los días de la semana o si al menos un día presenta un comportamiento distinto. Bajo la hipótesis nula, todas las medias son iguales (el día de la semana no afecta las ventas); un p-valor pequeño indica que se rechaza esta hipótesis y que el patrón semanal es relevante, lo que constituye evidencia de estacionalidad intra-semanal. Esta interpretación sigue el tratamiento clásico del ANOVA de un factor en manuales de diseño de experimentos, como Montgomery (2017).

Sparsity index

En el análisis de datos de alta dimensionalidad, especialmente en contextos transaccionales, es frecuente evaluar el índice de sparsity (o índice de dispersión). Este indicador mide la proporción de valores nulos o cero dentro de una matriz o conjunto de datos, reflejando cuán dispersa es la información disponible. Una matriz altamente *sparse* presenta muchos ceros y pocos valores significativos, lo cual afecta la capacidad de los algoritmos para identificar estructuras latentes, patrones de similitud o clusters bien definidos. En el campo del aprendizaje automático, la sparsity es particularmente relevante en representaciones como las matrices cliente-producto o documento-palabra, donde la mayoría de las interacciones no ocurren. La literatura sugiere que técnicas de representación distribuida, como Word2Vec, pueden contribuir a atenuar algunos efectos de la sparsity al aprender embeddings densos que capturan relaciones semánticas incluso en contextos dispersos (Mikolov et al., 2013; Rong, 2014), aunque su efectividad depende fuertemente de la cantidad y la calidad de los datos disponibles.

4. 2 ANALISIS EXPLORATORIO DE DATOS

• 4. 2. 1 EXTRACCIÓN DE LOS DATOS

Para el desarrollo del proyecto la empresa otorgó permisos y accesos directos a su infraestructura en Snowflake, asignando a cada integrante del equipo un usuario y contraseña individuales. De esta manera, el trabajo se realizó sobre datos en tiempo real, que abarcaban información desde el año 2015 hasta la fecha más reciente disponible, con actualizaciones diarias de todas las unidades de negocio.

La empresa habilitó únicamente las tablas específicas necesarias para el análisis, por lo que no fue necesario realizar un filtrado inicial a nivel de selección de tablas. La tarea principal consistió en determinar qué columnas utilizar, lo cual implicó un proceso de entendimiento de los datos en función de su significado y de la estructura del Modelo Entidad-Relación (Anexo 1) provisto.

El proceso de selección del dataset final representó un desafío considerable, dado que las tablas eran de gran tamaño y la intención inicial del equipo era aprovechar la totalidad de la información disponible

sin realizar recortes. Sin embargo, luego de un análisis conjunto con la empresa y en coordinación con el tutor, se determinó que era necesario reducir el volumen de datos para hacer viable el trabajo.

En consecuencia, se decidió acotar la muestra a los últimos dos años completos (2023 y 2024) y tres sucursales específicas, seleccionadas estratégicamente por representar tres perfiles de negocio diferentes: un hipermercado, un supermercado y un local de cercanía (formato de proximidad). Aun con esta reducción, el volumen seguía siendo elevado, por lo que se adoptó un criterio adicional de segmentación temporal:

Año 2023 → utilizado para el análisis exploratorio (EDA).

Año 2024 → se utilizaron con un propósito comparativo, a fin de evaluar la consistencia y estabilidad de los patrones de comportamiento observados en 2023, y determinar si las tendencias identificadas se mantenían en el tiempo.

Este enfoque permitió trabajar con información representativa y actualizada, manteniendo la diversidad de perfiles de sucursales, a la vez que garantizó la factibilidad técnica del análisis dentro de los recursos disponibles.

Finalmente, el dataset consolidado quedó conformado por un conjunto de columnas que permiten integrar la información de manera coherente:

- TICKET: id del ticket
- TIEM_DIA_ID: id de la fecha
- HORA_HORA_ID: id de la hora del día
- GOEG_LOCL_COD: código de la sucursal en el que se realizó la transacción
- GOEG_LOCL_DESC: descripción de la sucursal en la que se realizó la transacción (nombre)
- ARTC_ARTC_ID: id del artículo
- CLASE: id de la clase a la que pertenece el artículo
- CLASS_NAME: nombre de la clase a la que pertenece el artículo
- SUBCLASE: ide de la subclase a la que pertenece el artículo
- SUB_NAME: nombre de la subclase a la que pertenece el artículo
- FOPA_FOPA_ID: id de la forma de pago
- FOPA_FOPA_DESC: descripción de la forma de pago
- VNTA_IMPORTE_CON_IVA: monto del importe (IVA incluido) del artículo
- VNTA_UNIDADES: cantidad de unidades del artículo
- VNTA_FLAG_PROMO: dato binario que indica si el artículo fue comprado en promoción (0 = no promo; 1 = promo)
- SOCI_SOCI_ID: id del cliente
- CLIE_CLIE_SEXO: dato binario que indica el sexo del cliente (F = femenino; M = masculino)
- SCENTIA_EDAD: edad del cliente al momento de la transacción del artículo
- SCENTIA_NSE: nivel socioeconómico del cliente
- ARTC_OFN1_ID: dato binario del producto en oferta tipo 1
- ARTC_OFN2_ID: dato binario del producto en oferta tipo 2
- ARTC_OFN3_ID: dato binario del producto en oferta tipo 3
- ARTC_COMB_ID: id de oferta por combinación de productos

-	TICKET	TIEM_DIA_ID	HORA_HORA_ID	GEOG_LOCL_COD	GEOG_LOCL_DESC	ARTC_ARTC_ID	CLASE	CLASS_NAME	SUBCLASE	SUB_NAME	FOPA_FOPA_ID	FOPA_FOPA_DESC
Count	6,707,608	6,707,608	6,707,608	6,707,608	6,707,608	6,707,608	6,707,608	6,707,608	6,707,608	6,707,608	6,707,608	6,707,608
Unique	1,306,196	363	NaN	NaN	3	NaN	NaN	380	NaN	1,366	NaN	63
Top	20231211258665983	2023-12-23	NaN	NaN	Hiper Tres Cruces	NaN	NaN	GASEOSAS	NaN	BOLSAS DE MERCADOS	NaN	EFECTIVO
Freq	170	26,747	NaN	NaN		NaN	NaN	317,391	NaN	242,973	NaN	1,689,111
Mean	NaN	NaN	18	166	5,165,180	134,400	396,329	NaN	3,963,287,000	NaN	44	NaN
Std	NaN	NaN	4	95	NaN	97,375	346,774	NaN	3,467,739,000	NaN	29	NaN
Min	NaN	NaN	2	115	NaN	1	-1	NaN	-1	NaN	1	NaN
25%	NaN	NaN	15	115	NaN	23,436	160,009	NaN	1,600,090,000	NaN	31	NaN
50%	NaN	NaN	18	115	NaN	112,376	280,001	NaN	2,800,010,000	NaN	32	NaN
75%	NaN	NaN	21	115	NaN	226,072	710,001	NaN	7,100,010,000	NaN	45	NaN
Max	NaN	NaN	25	419	NaN	440,185	2,010,001	NaN	2,010,001,000	NaN	169	NaN



Para la implementación del dashboard, se estableció una conexión directa con la base de datos de la empresa, lo que permite alimentar la visualización con información real y actualizada de forma automática, garantizando que los indicadores reflejen en tiempo real el comportamiento de las ventas y las transacciones.

• 4. 2. 2 LIMPIEZA DE DATOS

La limpieza consistió en identificar los datos faltantes y eliminarlos debido a que representaban un porcentaje reducido, y no afectaban la representatividad del conjunto; descartar columnas consideradas irrelevantes para los objetivos del análisis; tratar con valores atípicos y datos erróneos, eliminando los registros cuyo importe excedía montos realistas para una compra en el contexto analizado; y la unificación de filas en los casos en que un mismo artículo aparecía registrado en líneas separadas dentro de una misma transacción. Para ello, se consolidaron dichas líneas, sumando las cantidades y registrándose en una única fila.

El análisis de datos faltantes mostró que su proporción era baja (menos del 10%) y que estaban distribuidos de manera equilibrada entre las tres sucursales, por lo que no generaban sesgos entre los tipos de locales analizados. Dado que la incidencia era reducida (en todos los casos por debajo del 10%) y no afectaba la representatividad del conjunto, se optó por eliminar los registros incompletos en lugar de imputar valores, asegurando así que cada transacción mantuviera información demográfica completa y asociada a un cliente identificado. Las columnas que presentaban valores faltantes correspondían a variables demográficas clave: sexo, edad y nivel socioeconómico (NSE). Al eliminar únicamente estos registros aislados, se mantuvo la integridad del dataset y se aseguró que cada venta pudiera ser asignada a un perfil de cliente, condición necesaria para realizar posteriormente una segmentación coherente del comportamiento de compra.

Se eliminó la columna “VNTA_FLAG_PROMO”, dado que el 100% de los registros presentaban el valor cero, lo que indicaba que dicha variable no contenía información útil ni diferenciadora sobre las ventas.

Los importes de venta presentaban valores negativos y montos iguales a cero, los cuales no representan transacciones reales. Dado que estos casos eran pocos y correspondían probablemente a errores de registro o devoluciones puntuales, se decidió eliminarlos del dataset para evitar distorsiones en el estudio del comportamiento de compra.

Los tickets tenían una inconsistencia estructural, donde una misma compra aparecía fragmentada en múltiples líneas. En múltiples ingresos, en lugar de registrarse una única línea indicando la cantidad total adquirida de un producto, el sistema generaba varias filas idénticas, cada una representando una unidad del mismo artículo. Para garantizar la coherencia del registro y optimizar la base de datos, se unificaron estas líneas duplicadas, consolidando aquellas que coincidían en el mismo producto, ticket y horario. En estos casos, se sumaron las cantidades correspondientes y se conservaron en una sola fila representando el total de unidades compradas. Se considera que esta situación puede deberse a

diferencias operativas en el proceso de registro en la caja, dado que algunos cajeros escanean los productos repetidos uno por uno, mientras que otras optan por registrar el artículo una sola vez e ingresar manualmente la cantidad total de unidades. Esta variabilidad en el procedimiento explicaría la duplicación observada en ciertos tickets.

Los montos de los artículos presentaban outliers en su distribución. A partir de los valores de los cuartiles (Q1 = 49 y Q3 = 149), se examinaron los outliers superiores en los importes con el fin de detectar posibles anomalías. Se identificaron varios registros con montos excesivamente elevados que, sin lugar a dudas, representaban errores de carga o inconsistencias en el sistema (por ejemplo, la venta de 45 platos principales con un importe de $99.999.999). Se determinó que los importes superiores a $4.000 correspondían a casos muy particulares, ya sea por errores de registro o por transacciones atípicas que no reflejaban el comportamiento de compra habitual de los clientes. Por este motivo, se optó por eliminar del conjunto los registros de artículos cuyo importe superara dicho valor, asegurando así la coherencia y realismo de los datos analizados. Estos registros representaban un 0.7% de las transacciones totales.

Adicionalmente, se eliminaron los pocos casos en los que la variable sexo no presentaba los valores “masculino” o “femenino”, así como aquellos registros en los que la edad del cliente era menor a 18 años o superior a 100, por considerarse inconsistencias o valores no representativos del universo de estudio.

4. 2. 3 ANÁLISIS EXPLORATORIO

(Considerar el análisis exploratorio realizado y sus detalles)

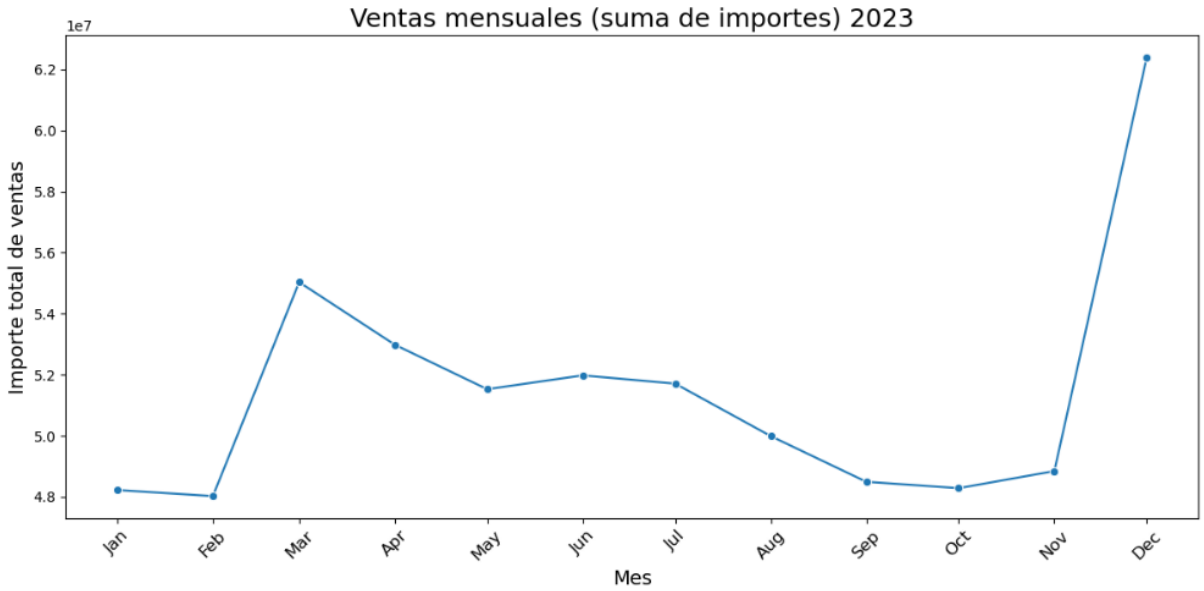


Figura 4.2.3.1 - Suma de los importes de las ventas por mes, en el año 2023

La evolución mensual de las ventas muestra, durante los primeros meses del año, valores que se mantienen estables en niveles relativamente bajos, algo que puede explicarse porque en esa época muchos clientes viajan al este u otros destinos de verano y, por lo tanto, reducen su consumo en los supermercados de la capital y de sus barrios habituales. En marzo se observa un repunte significativo, probablemente vinculado al regreso de la actividad cotidiana y a la vuelta a clases.

A partir de abril se observa una tendencia descendente que se prolonga hasta septiembre, alcanzando uno de los niveles más bajos en octubre. Esta caída puede explicarse por factores estacionales y económicos: se trata de meses sin festividades ni eventos que impulsen el consumo, el poder adquisitivo de los hogares se ve más ajustado al no haber ingresos extraordinarios, y es habitual que en primavera parte del gasto se destine a otros rubros como vestimenta, ocio o consumo fuera del hogar.

Finalmente, diciembre marca un quiebre con un crecimiento abrupto y el mayor pico del año, reflejando el impacto de las fiestas de fin de año, cuando el consumo en supermercados se multiplica. Este comportamiento confirma que el negocio tiene una fuerte dependencia de momentos específicos del calendario y resalta la importancia de diseñar estrategias comerciales y promocionales que sostengan la actividad en los meses “valle” previos a la temporada alta.

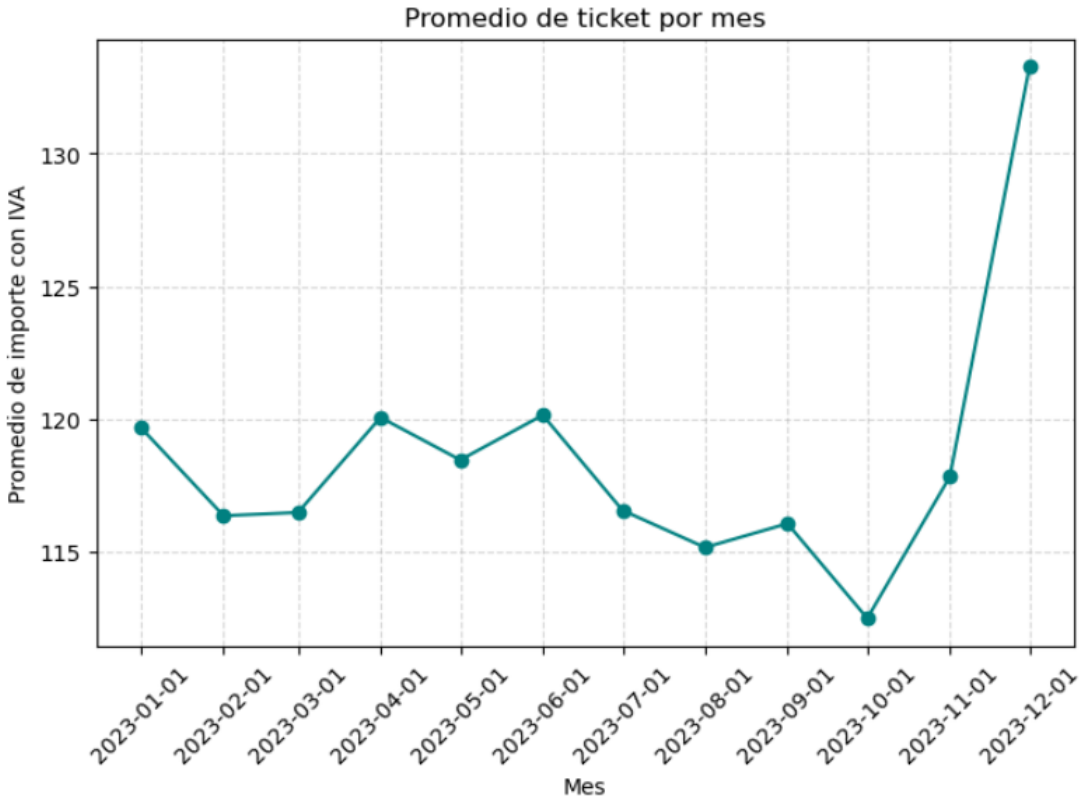


Figura 4.2.3.2 - Promedio de ticket vendido por mes en el año 2023

Esta gráfica complementa el análisis de las ventas mensuales y muestra que las variaciones observadas a lo largo del año no responden únicamente a cambios en la cantidad de tickets emitidos, sino también a modificaciones en el monto promedio de compra por ticket. De esta manera, se evidencia que los resultados de ventas combinan tanto el nivel de tráfico de clientes como el gasto individual en cada visita.

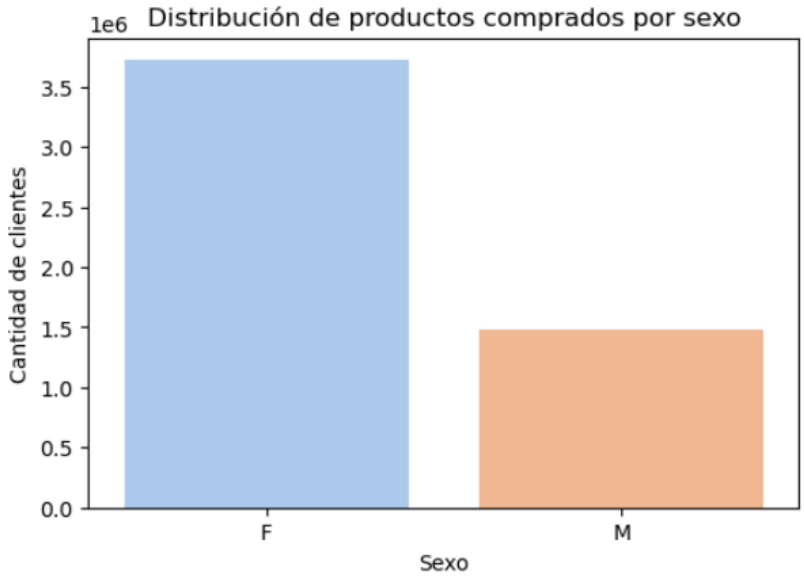


Figura 4.2.3.3 - Distribución de los productos comprados según el sexo en el año 2023

La diferencia observada en la distribución de productos comprados por sexo podría responder a diversos factores, que en esta instancia solo es posible plantear como hipótesis. Una primera explicación puede estar vinculada a los roles de compra en los hogares, donde es habitual que las mujeres asuman la responsabilidad principal de abastecimiento en supermercados, lo que incrementaría el número de transacciones asociadas a ellas.

Otra posible explicación está vinculada al registro en los programas de fidelización. Con frecuencia, la tarjeta de socio se emite a nombre de una sola persona del hogar, lo que concentra en su perfil todas las compras de la familia. Dado que en muchos hogares la responsabilidad de las compras suele recaer en la mujer, resulta lógico que sea ella quien figure como titular del registro de fidelización.

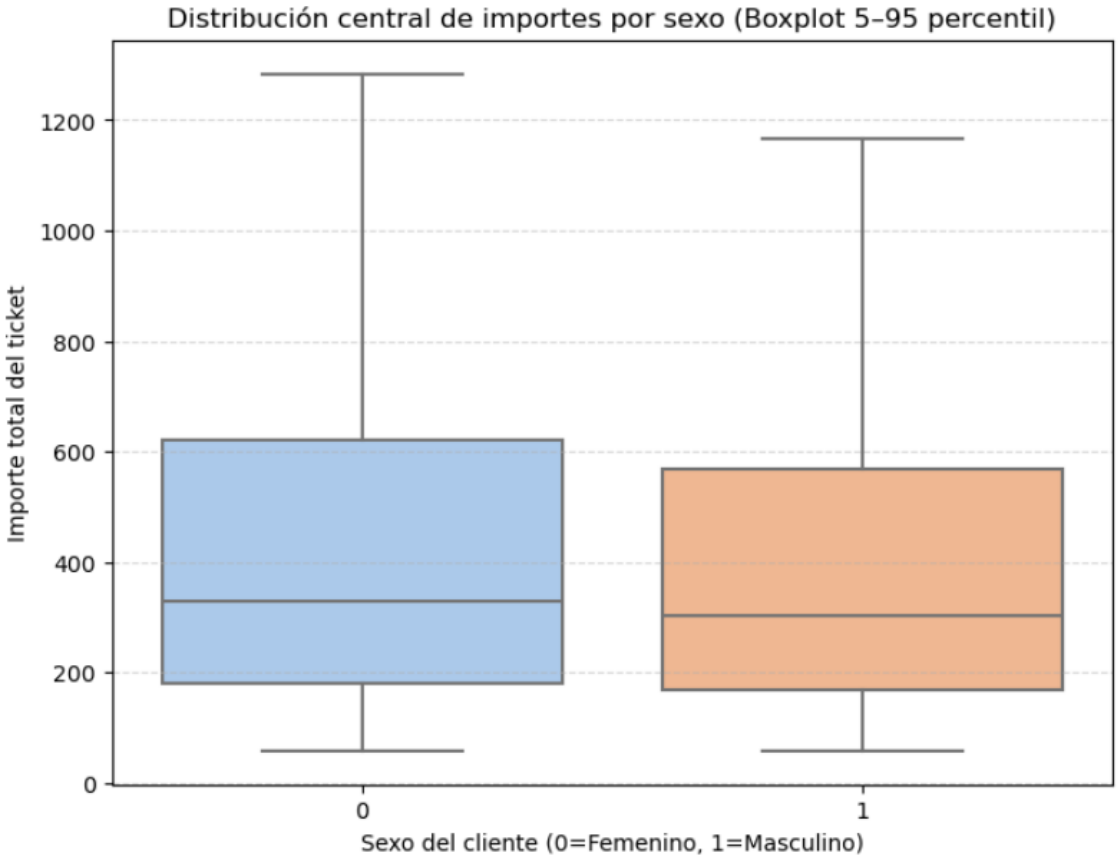


Figura 4.2.3.4 - Boxplots entre los percentiles 5 y 95 comparativos entre hombres y mujeres, de la distribución central de los importes por ticket

Estos boxplots nos muestran que, en términos de importe de compras, el comportamiento entre hombres y mujeres es muy similar.

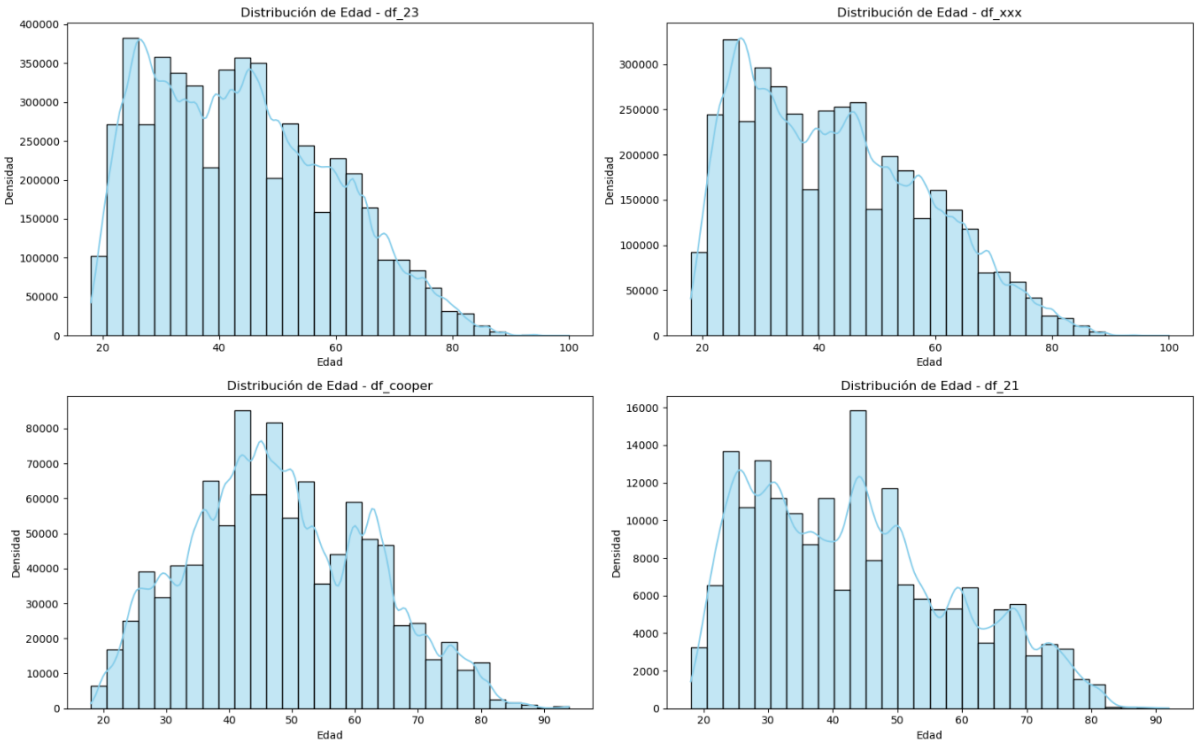


Figura 4.2.3.5 - Distribuciones de ventas por edad, para 2023 en las tres sucursales en estudio, y por sucursal en estudio individualmente

- Df_23: transacciones de los 3 supermercados juntos.
- Df_21: transacciones del supermercado de Cercanía de 21 de Septiembre (Punta Carretas).
- Df_cooper: transacciones del supermercado de Cooper (Carrasco Norte).
- Df_xxx: transacciones del hipermercado de Tres Cruces.

El análisis de la distribución de edades permite identificar diferencias claras entre los distintos formatos de supermercado. En el caso del hipermercado, se observa una mayor concentración de clientes en rangos de edad más jóvenes y de mediana edad, principalmente entre los 25 y 45 años. Esto sugiere que este formato resulta más atractivo para familias activas que realizan compras de mayor volumen y planificación. Otra posible razón para esta distribución de la edad puede ser que el shopping de Tres Cruces donde está ubicado el hipermercado también funciona como terminal de ómnibus en la capital del país. Quienes más utilizan este servicio son los jóvenes, más activos que las personas más grandes, y es muy probable que pasen por el supermercado para comprar algo para su viaje.

En el supermercado tradicional la distribución se desplaza hacia edades más altas, con un pico marcado entre los 40 y 55 años y una presencia significativa de clientes que superan los 60. Este patrón indica que este formato capta a un público más adulto y consolidado, probablemente habituado a una rutina de compras estable.

El supermercado de cercanía presenta una composición más heterogénea: por un lado, se detecta un grupo de clientes jóvenes, en torno a los 25–35 años, que valoran la proximidad y la rapidez en la compra; y por otro, un grupo de adultos de 40–50 años que también utilizan este formato como complemento a otros canales.

En conjunto, considerando todos los supermercados, la mayor concentración de clientes se encuentra entre los 25 y 60 años, lo que refleja que este rango etario constituye el núcleo del consumo en el sector minorista alimentario.

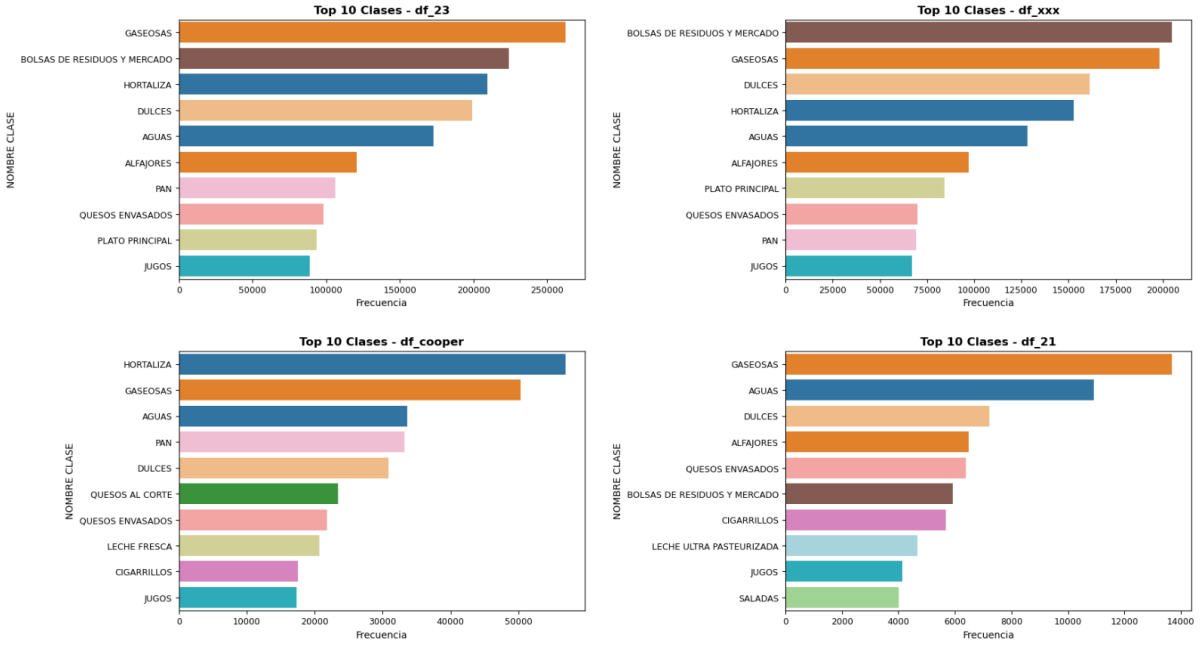


Figura 4.2.3.6 - Distribución de las ventas de clases más frecuentes, para 2023 en las tres sucursales en estudio, y por sucursal en estudio individualmente

El análisis de las clases de productos más comprados muestra diferencias claras entre los distintos formatos de supermercado. En el total agregado de todas las sucursales, se destacan categorías como gaseosas, bolsas de residuos, hortalizas, dulces y aguas, lo que refleja una combinación entre productos de consumo inmediato y cotidiano junto con artículos básicos de reposición frecuente.

En el caso del hipermercado, se observa un comportamiento similar al global, aunque con una mayor concentración en bolsas de residuos y gaseosas, además de la presencia destacada de platos principales y quesos envasados. Esto sugiere que en este formato predominan compras más planificadas y de mayor volumen, propias de clientes que buscan aprovechar surtido y economía por cantidad. El alto porcentaje de ventas de gaseosas y dulces también se asocia al servicio de terminal que se ofrece en Tres Cruces, ya que es común comprarse algo para ingerir durante el viaje en ómnibus.

Por su parte, el supermercado tradicional muestra un peso mayor de productos frescos como hortalizas, pan y leche, a los que se suman categorías como quesos al corte y cigarrillos. Este patrón indica que este formato está más asociado a compras de reposición y de consumo cotidiano, donde el cliente acude con mayor frecuencia.

Finalmente, el supermercado de cercanía presenta un perfil distinto, con una clara predominancia de gaseosas y aguas, seguidas por dulces, alfajores y cigarrillos. En este caso, el consumo se caracteriza por ser de impulso y menor volumen, enfocado en la conveniencia y en cubrir necesidades inmediatas.

En conclusión, mientras que los hipermercados concentran un consumo más planificado y voluminoso, los supermercados tradicionales y de cercanía se orientan a compras de reposición y conveniencia, respectivamente, mostrando cómo cada formato responde a distintas necesidades de los clientes.

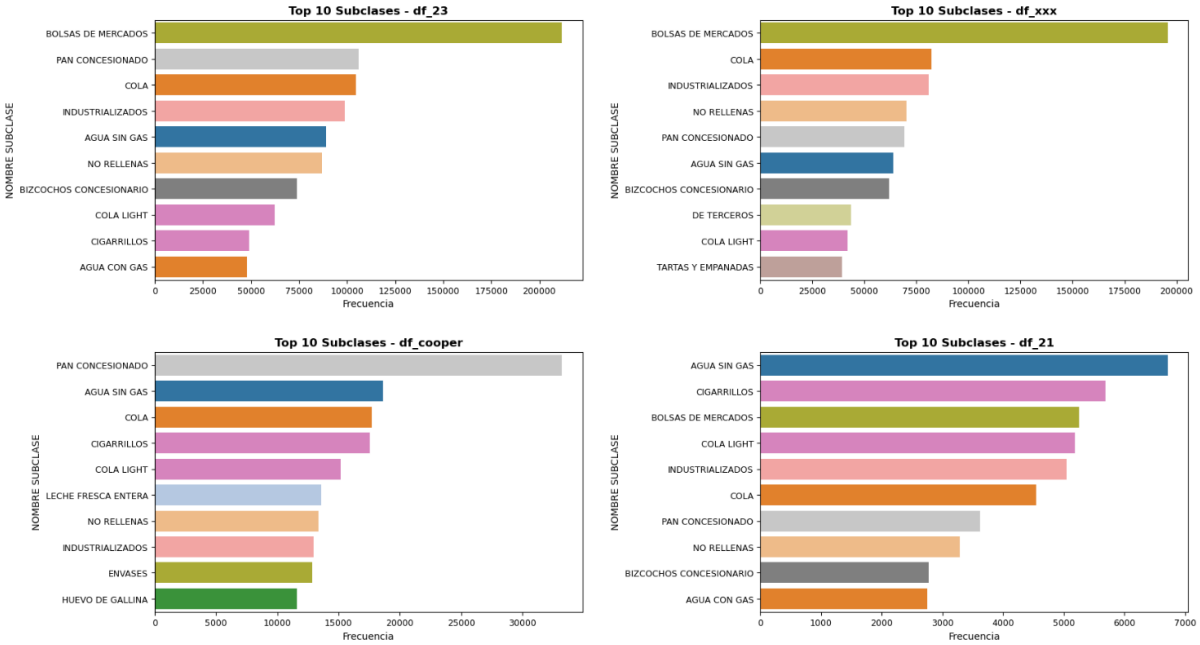


Figura 4.2.3.7 - Distribución de las ventas de subclases más frecuentes, para 2023 en las tres sucursales en estudio, y por sucursal en estudio individualmente

Analizando las subclases de productos, se observa una conclusión coherente con los patrones identificados en las clases. El hipermercado concentra principalmente artículos de abastecimiento masivo, como bolsas, gaseosas e industrializados. El supermercado tradicional se orienta hacia productos frescos y de consumo cotidiano, destacándose el pan, la leche y los huevos. Finalmente, el supermercado de cercanía muestra un patrón asociado a compras rápidas e inmediatas, donde predominan las bebidas, los cigarrillos y los bizcochos.

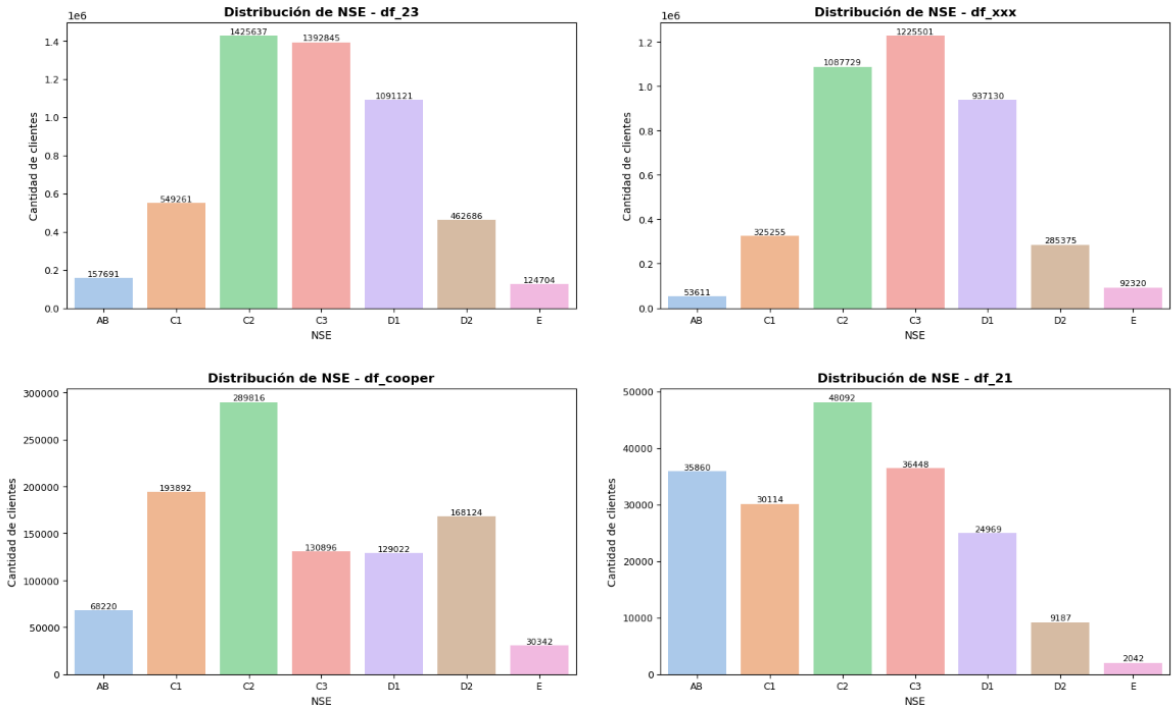


Figura 4.2.3.8 - Distribución de las ventas por niveles socioeconómicos, para 2023 en las tres sucursales en estudio, y por sucursal en estudio individualmente

El análisis de la distribución por nivel socioeconómico muestra que, en el total de supermercados, la mayor concentración de clientes se encuentra en los segmentos medios, especialmente en C2 y C3, seguidos por D1. En contraste, los extremos (los niveles altos (AB) y los bajos (E)) representan una proporción reducida del total. Esto confirma que el núcleo del consumo en el sector se encuentra en la clase media y media-baja.

Al observar cada formato de manera individual, el hipermercado refleja un patrón muy similar al global, aunque con un peso relativamente mayor en los segmentos C3 y D1. Este comportamiento sugiere que el hipermercado resulta más atractivo para sectores de clase media y media-baja, que buscan realizar compras grandes y aprovechar precios más competitivos. La distribución resulta coherente con su localización. Al estar dentro de la principal terminal de ómnibus del país, el establecimiento recibe diariamente un flujo muy diverso de personas que se trasladan desde distintos puntos de Montevideo y del interior. Esto implica que concurren individuos pertenecientes a todos los estratos socioeconómicos, lo cual se refleja en una distribución amplia y heterogénea de clientes. En este sentido, tiene sentido considerar que la composición del público de este hipermercado guarda cierta representatividad respecto a la estructura socioeconómica de la población uruguaya en general, y se aproxima a una distribución normal.

En el supermercado tradicional, los segmentos predominantes siguen siendo C2 y C3, pero con una mayor presencia relativa de C1 y D2. Esto muestra que este formato atiende a un público más heterogéneo, que va desde las clases medias hasta sectores populares. La participación de clientes de nivel socioeconómico algo más alto también puede explicarse por la ubicación de la sucursal analizada, en Carrasco Norte, un barrio con mayor poder adquisitivo que zonas como Tres Cruces, aunque sin llegar a ser de los más exclusivos de la ciudad. Además, en esta zona la competencia incluye supermercados como Tienda Inglesa y Devoto, que están más orientados a un público de nivel socioeconómico alto, lo que refuerza la posición del supermercado tradicional como una alternativa intermedia en el área.

Por último, en el supermercado de cercanía se mantiene la importancia de los segmentos C2 y C3, aunque se observa un mayor peso relativo del segmento AB en comparación con los otros formatos. Esto puede vincularse a la localización de este tipo de tiendas en barrios residenciales diversos, donde los clientes de mayor poder adquisitivo recurren a ellas por conveniencia, aunque sus compras sean de menor volumen.

En síntesis, todos los formatos dependen principalmente de la clase media como base de su clientela, aunque cada uno muestra matices: el hipermercado se orienta más a sectores medios-bajos, el supermercado tradicional concentra un público variado y el supermercado de cercanía logra captar también a clientes de mayor poder adquisitivo gracias a su proximidad.

En relación con los patrones de compra, se analizó el comportamiento de los clientes según su frecuencia de visita. Para este estudio, se definió como cliente frecuente a aquel que realiza al menos doce compras anuales, equivalente a una visita mensual. A partir de esta clasificación, se identificó que únicamente el 8,5% de los clientes puede considerarse frecuente, un porcentaje considerablemente reducido si se tiene en cuenta la amplia variedad de productos disponibles en la cadena. No obstante, a pesar de su baja representación dentro de la base total de clientes, este grupo concentra el 62,0% de los importes por ventas de las sucursales analizadas, y el 62,9% de la cantidad de facturas de las sucursales analizadas.

Al comparar los datos correspondientes a los años 2023 y 2024, se observó una notable estabilidad en los patrones generales de comportamiento. Tanto las clases como las subclases más frecuentes se mantuvieron prácticamente inalteradas, al igual que las proporciones relativas entre ellas. Esta consistencia sugiere que la estructura del consumo y las tipologías de clientes presentan una dinámica estable en el tiempo, sin cambios significativos en la composición de la demanda.

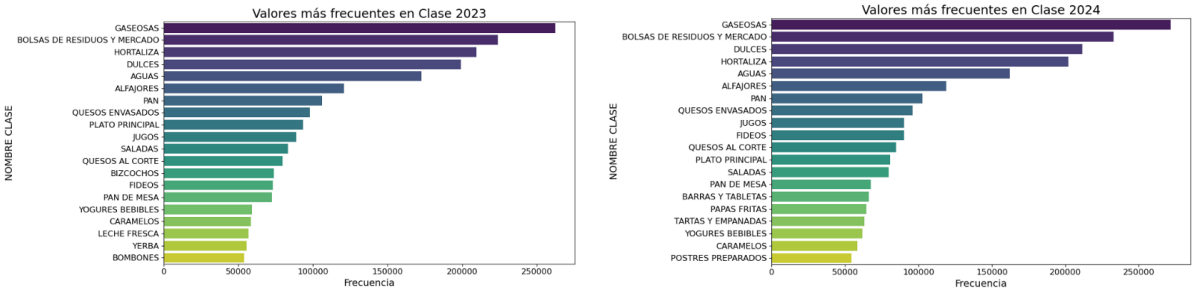


Figura 4.2.3.9 - Comparación de clases más frecuentes entre 2023 y 2024

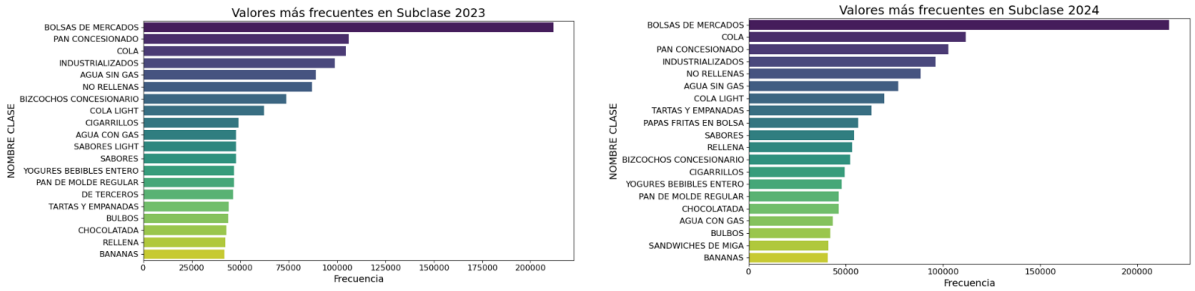


Figura 4.2.3.10 - Comparación de subclases más frecuentes entre 2023 y 2024

En relación con la evolución de las ventas mensuales, se identificaron variaciones moderadas entre ambos años. El límite inferior de las ventas se incrementó de $48.000.000 a $52.000.000, mientras que el límite superior permaneció estable en torno a los $62.000.000. En ambos períodos se repite el patrón de ventas más bajas durante los primeros dos meses del año, seguido por un aumento marcado en marzo. Sin embargo, en 2024 la caída registrada en abril fue más pronunciada que en 2023, aunque posteriormente se observó una tendencia al alza que aproximó los niveles mensuales a los alcanzados el año anterior. En los dos años analizados, septiembre volvió a destacarse como un mes de baja actividad comercial, pero en 2024 se registró un repunte progresivo en octubre y noviembre que no había sido tan evidente en 2023. Finalmente, diciembre se consolidó en ambos casos como el mes de mayor volumen de ventas, mostrando un incremento abrupto respecto de noviembre y de los meses previos.

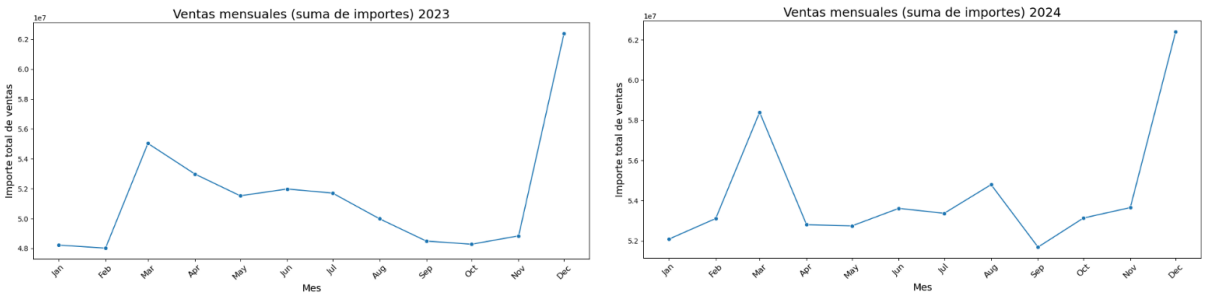


Figura 4.2.3.11 - Comparación importe de venta mensuales entre 2023 y 2024

Donde sí se identificaron variaciones más marcadas fue en el promedio mensual del ticket. En 2023, los valores se ubicaron en un rango que osciló entre $110 y $135, mientras que en 2024 dicho intervalo se desplazó hacia arriba, situándose entre $120 y $145. Esta diferencia refleja un aumento generalizado

en el monto promedio de compra por cliente, consistente con la tendencia al alza observada en otros indicadores del período.

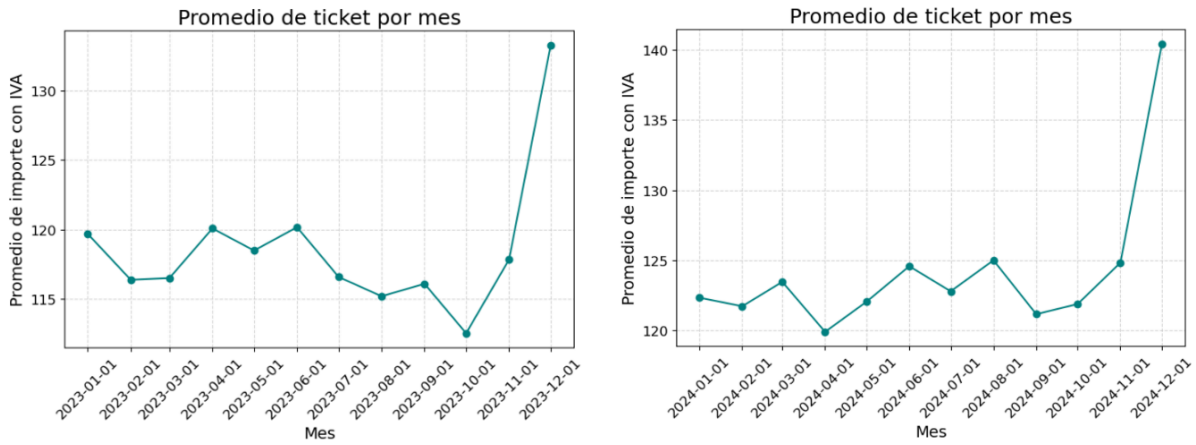


Figura 4.2.3.12 - Comparación promedio de ticket por mes entre 2023 y 2024

4. 3 RESULTADOS OBTENIDOS y MODELLING

Dado el elevado nivel de ruido presente en la base de transacciones y la magnitud del volumen de datos analizado, los métodos de reducción de dimensionalidad y clusterización aplicados no lograron obtener agrupamientos consistentes ni estadísticamente sólidos. En este contexto, nos referimos a ruido como la combinación de una alta variabilidad distintiva en los tickets individuales (con muchos tickets que contienen muy pocos ítems y presentan combinaciones de productos poco repetidas), una señal débil de patrones repetidos (es decir, escasas coocurrencias consistentes de clases de productos entre tickets, lo que dificulta la identificación de grupos estables) y la presencia de transacciones atípicas, ya sea por montos muy elevados o muy bajos, o por combinaciones de categorías poco frecuentes, que terminan distorsionando el desempeño de los métodos de reducción de dimensionalidad y clusterización. A esto se suma que la matriz ticket–clase presenta un índice de sparsity del 99,72%, lo que indica que casi todas las combinaciones posibles de ticket y clase son celdas vacías, reforzando la falta de estructura repetitiva sobre la que los algoritmos puedan aprender. Ante esta limitación metodológica, se optó por realizar una clusterización de carácter demostrativo, cuyo objetivo es ilustrar el proceso y explorar la generación de perfiles suaves de comportamiento de los consumidores, más orientados a mostrar el potencial analítico de la técnica que a obtener segmentos definitivos o conclusiones robustas.

La técnica seleccionada para la generación de los perfiles demostrativos se basó en una representación vectorial de los tickets mediante Word2Vec, complementada con un proceso de clusterización con K-Means. Word2Vec permitió transformar la información categórica de los productos en vectores numéricos continuos, capturando relaciones de coocurrencia y patrones de asociación entre artículos que suelen comprarse conjuntamente. Para evitar que la segmentación quedara condicionada por la estructura predefinida por la empresa, el modelo se entrenó exclusivamente utilizando el identificador del artículo (ARTC_ARTC_ID), prescindiendo de las variables de clase y subclase.

Se definió un espacio vectorial de 128 dimensiones, que determina cuántas características numéricas se asignan a cada producto, buscando un equilibrio entre capacidad representativa y eficiencia computacional; un número mayor habría permitido incorporar relaciones más complejas, pero con el riesgo de aumentar el consumo de recursos y favorecer el sobreajuste. La ventana de contexto se fijó en 40 (Anexo 2), valor que indica la cantidad de productos cercanos dentro de cada ticket que el modelo

considera al aprender las relaciones de productos que aparecen juntos. Este parámetro se determinó a partir del análisis de la distribución del número de productos por ticket, de modo que cubriera la totalidad o la amplia mayoría de los casos, evitando que el modelo se vea influenciado por el orden en el que los productos aparecen en el registro de compra y garantizando que las relaciones capturadas respondan a patrones reales de asociación.

En cuanto a los resultados del modelo Word2Vec, los vectores aprendidos lograron capturar relaciones intuitivas entre los productos a partir de su coocurrencia en los tickets. Por ejemplo, para el caso de las mandarinas, el análisis de similitud de coseno mostró una distancia de 0,7349 respecto a las paltas, lo cual resulta razonable dado que ambas pertenecen a la misma temporada de consumo. Asimismo, las mandarinas presentan una distancia de 0,7455 con las manzanas, 0,8447 con las bananas y 0,8660 con las naranjas, todas frutas de compra frecuente y asociadas a patrones regulares de consumo. Estas distancias reflejan que el modelo identifica correctamente agrupaciones naturales dentro del surtido, incluso sin información explícita sobre categorías o estacionalidad, apoyándose únicamente en los patrones de coocurrencia observados en los datos transaccionales.

Los vectores resultantes se emplearon como insumo para aplicar K-Means con el fin de agrupar tickets que presentaran patrones de compra similares. El método del codo no arrojó un punto de inflexión claro ni permitió identificar un número óptimo de clusters. Una posible hipótesis es que, debido a la naturaleza del conjunto de datos, la métrica de inercia no resulta adecuada para las técnicas demostrativas empleadas en esta instancia. En consecuencia, la elección de seis clusters se basó en el análisis previo realizado con metodologías más apropiadas para este tipo de datos, las cuales habían mostrado resultados coherentes antes de ser descartadas por limitaciones vinculadas a la capacidad computacional, la escala del dataset y el nivel de ruido observado. Para mejorar la estabilidad del modelo, se estableció n_init = 20, dado que el incremento respecto a 10 inicializaciones no produjo variaciones sustanciales según la métrica Calinski–Harabasz y se adoptó como configuración robusta. Finalmente, el parámetro max_iter se fijó en 300, correspondiendo al valor estándar utilizado en scikit-learn, suficiente para asegurar la convergencia sin afectar la eficiencia del proceso.

Las técnicas de modelado, reducción dimensional y clusterización evaluadas y posteriormente descartadas durante el desarrollo del proyecto fueron:

Se evaluó la posibilidad de aplicar un modelo RFM (Recency, Frequency, Monetary Value) debido a su amplia presencia en la literatura y a su uso frecuente en estudios de segmentación de clientes. No obstante, la estructura del conjunto de datos impidió obtener resultados adecuados. Una proporción considerable de los clientes había realizado una única compra, lo cual generaba una distribución fuertemente sesgada y anulaba la capacidad del modelo para distinguir comportamientos diferenciados. En estas condiciones, la variable frequency deja de aportar información relevante y, en consecuencia, la métrica recency pierde sentido analítico, puesto que no existe repetición en el comportamiento de compra que permita interpretar que un cliente reciente tenga un mayor valor o un grado de compromiso superior respecto de otro cuya única compra se haya realizado al inicio del período. Además, el enfoque RFM requiere analizar la evolución de las métricas a lo largo del tiempo para reflejar la recurrencia y el valor de las relaciones con los clientes. En este caso, la magnitud de la base de datos, que abarca varios años de transacciones, limitó la posibilidad de realizar dicho seguimiento temporal de manera integral, dado que el procesamiento simultáneo de múltiples períodos superaba la capacidad computacional disponible. Por estos motivos, se optó por explorar métodos alternativos de segmentación más adecuados al tipo y volumen de datos, que permitieran

capturar relaciones complejas entre productos, tickets y clientes sin depender estrictamente de la frecuencia temporal de compra.

Se aplicó una combinación de Word2Vec y DBSCAN con el propósito de generar una representación vectorial de los productos presentes en cada ticket y luego identificar patrones mediante un método de clusterización basado en densidad. Esta aproximación ofrecía ventajas teóricas relevantes: DBSCAN determina automáticamente el número de clusters y distingue explícitamente los puntos considerados ruido, lo que resulta útil en contextos caracterizados por alta heterogeneidad y presencia de valores atípicos. Sin embargo, el algoritmo requiere una capacidad computacional considerable, por lo que fue necesario aplicar técnicas de undersampling mediante StratifiedShuffleSplit de scikit-learn, reduciendo la muestra al 25% del dataset para poder ejecutar el modelo. Aun así, los resultados obtenidos no fueron adecuados para los fines del proyecto: tras múltiples ajustes de parámetros, el modelo clasificó aproximadamente 88% de los registros como ruido y generó alrededor de 330 clusters a partir del 12% restante. Este tipo de salida no permite obtener agrupaciones interpretables ni perfiles útiles para la segmentación de clientes, por lo que la técnica debió ser descartada.

De igual manera, también se consideró la implementación de un autoencoder como herramienta para reducir la dimensionalidad y obtener una representación latente más compacta de los datos. Desde el punto de vista teórico, los autoencoders permiten aprender estructuras subyacentes no lineales dentro de los datos, conservando las relaciones más relevantes y eliminando el ruido. Esto habría permitido capturar patrones complejos de coocurrencia entre productos, mejorando la posterior etapa de agrupamiento. No obstante, la aplicación del Autoencoder con DBSCAN resultó computacionalmente inviable debido al volumen y la dimensionalidad de los datos. Ambas técnicas presentan un costo computacional considerablemente más alto y demandan grandes cantidades de memoria y tiempo de procesamiento, lo que excedía la capacidad disponible para la ejecución del proyecto.

También se evaluó una combinación de undersampling, autoencoders y DBSCAN, obteniéndose resultados muy similares al enfoque de Word2Vec y DBSCAN, con una proporción elevada de ruido y una estructura de clusters igualmente poco interpretable.

A su vez, se evaluó una combinación de undersampling, autoencoders y K-Means. Para aplicar K-Means fue necesario determinar el número óptimo de clusters, identificándose k = 6 mediante el método del codo. No obstante, la clusterización obtenida presentó un silhouette score de 0.1, valor que evidencia una escasa separación entre grupos y una estructura de clusters poco definida. Ante la ausencia de una segmentación clara, se optó por aplicar un enfoque que permitiera abarcar la totalidad del dataset y generar una clusterización representativa. En consecuencia, se implementó finalmente la combinación Word2Vec y K-Means.

Inicialmente, se había previsto evaluar la calidad de los clusters utilizando el índice de Silhouette y representar gráficamente los resultados mediante la técnica de reducción de dimensionalidad t-SNE (t-distributed Stochastic Neighbor Embedding). Sin embargo, debido al tamaño y la complejidad del conjunto de datos, estas herramientas resultaron computacionalmente inviables, ya que requerían tiempos de procesamiento y consumo de memoria significativamente superiores a los recursos disponibles. Ante esta limitación, se optó por emplear el índice de Calinski–Harabasz (CHI) y complementar el análisis con otros métodos de validación interna, como el método del codo y pruebas exploratorias con algoritmos alternativos, entre ellos DBSCAN. Los resultados obtenidos mostraron, por un lado, que el valor del CHI aumentaba a medida que se reducía la cantidad de clusters (lo que indica que el modelo se ajusta mejor cuando se agrupan los datos en estructuras amplias y poco fragmentadas) y, por otro, que los valores de los distintos criterios de validación eran bajos o poco

diferenciados entre distintas configuraciones de K. Asimismo, DBSCAN no logró identificar agrupamientos densos y bien definidos, sino que tendió a considerar grandes porciones de los datos como ruido.

Este comportamiento sugiere que no existen clusters claramente definidos dentro del conjunto de datos bajo las representaciones y metodologías utilizadas y es coherente con la presencia de un elevado nivel de ruido en la base. En este sentido, cuando se señala que los métodos de validación no arrojan resultados contundentes se hace referencia a que, desde una perspectiva estrictamente estadística, no se encontró evidencia sólida que justificara una segmentación robusta y estable de los tickets en un número determinado de clusters; es decir, los indicadores de calidad de clustering no permiten sostener que exista una estructura segmentaria fuerte o una partición “natural” de los datos. No obstante, y reconociendo explícitamente esta limitación, se redefinió el enfoque hacia una clusterización de carácter demostrativo o representativo. En particular, se fijó un valor de K=6 el cual se extrae del intento de realizar undersampling + autoencoder + K-Means. Este valor de k no se toma como resultado de un criterio de optimalidad estadística, sino con el objetivo de ilustrar el potencial analítico de la técnica y explorar la generación de perfiles cualitativos de comportamiento de compra. En este marco, los clusters obtenidos no deben interpretarse como segmentos definitivos ni como base directa para la toma de decisiones, sino como una aproximación exploratoria que permite identificar patrones suaves (por ejemplo, tickets más orientados a compras de reposición, de stockeo o compras mixtas).

Este patrón también puede explicarse por la alta heterogeneidad del comportamiento de compra, el ruido inherente a los datos transaccionales y la ausencia de fronteras nítidas entre los perfiles de los clientes, factores que tienden a favorecer modelos con menos clusters y dificultan la identificación de estructuras internas robustas usando algoritmos como K-Means.

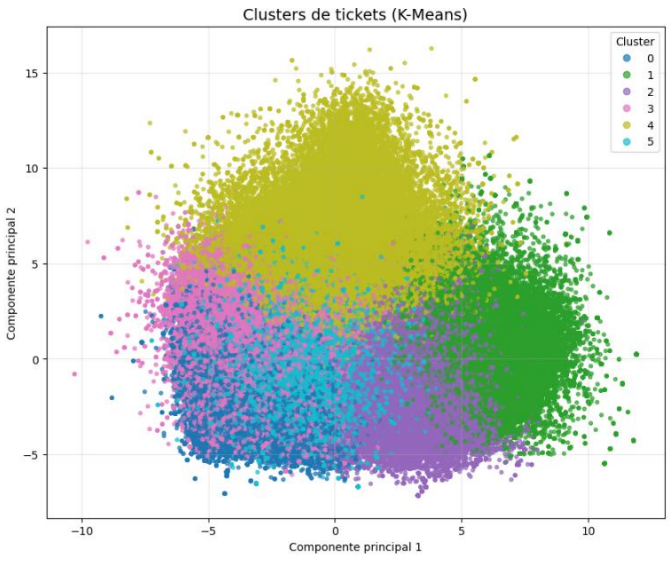


Figura 4.3.1 - Clusters de tickets utilizando K-Means sobre representación PCA en 2D.

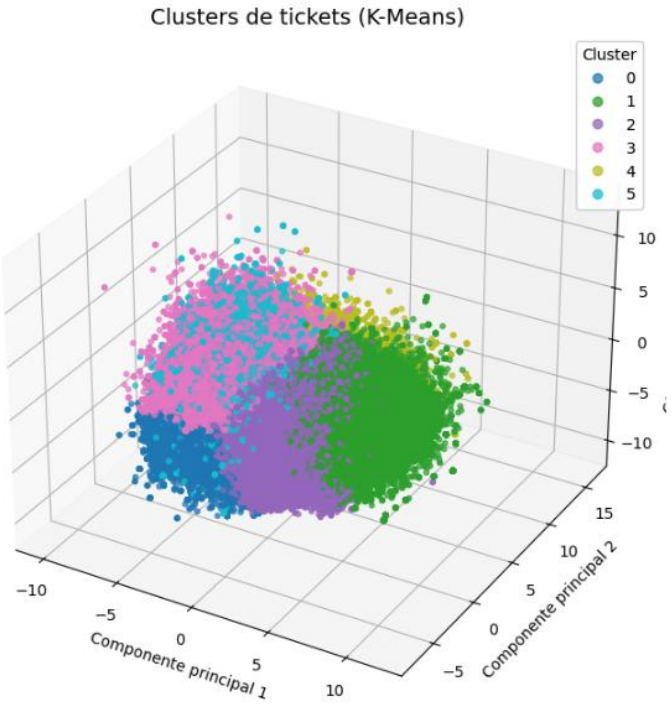


Figura 4.3.2 - Clusters de tickets utilizando K-Means sobre representación PCA en 3D.

ANÁLISIS DE LOS CLUSTERS

A pesar de las limitaciones mencionadas, especialmente el alto nivel de ruido y el hecho de que las métricas estadísticas de validación no respaldan de forma sólida la existencia de clusters bien definidos, los grupos obtenidos mediante la segmentación demostrativa (K-means = 6) muestran patrones coherentes con la lógica del negocio y con comportamientos habituales del consumidor. Esto puede explicarse porque, aunque el dataset no presenta separaciones "fuertes" desde el punto de vista estadístico, sí contiene señales suaves vinculadas a hábitos reales de compra que, aun siendo débiles, se manifiestan cuando se fuerza una estructura de clusters. En este sentido, si bien el ejercicio no permite extraer conclusiones definitivas ni construir segmentaciones operativas, sí revela una tensión interesante: los resultados son estadísticamente frágiles, pero cualitativamente reveladores. Por ello, el análisis ofrece una primera aproximación válida sobre cómo podrían organizarse grupos de clientes con comportamientos diferenciados.

Al analizar la proporción de clientes que pueden considerarse fidelizados dentro de cada cluster, se observa que la proporción de clientes fidelizados es relativamente homogénea (Anexo 3). Es decir, más allá de que algunos clusters sean más grandes o más chicos en términos absolutos, el peso relativo de clientes fidelizados dentro de cada uno se mantiene estable. Con la excepción de los clusters 0 y 3, los demás grupos presentan valores entre 6% y 9%.

El Cluster 3 presenta la mayor proporción de clientes fidelizados (12.3%). Esto tiene sentido desde el punto de vista del comportamiento del consumidor: este cluster está asociado principalmente a productos frescos (como frutas, verduras, carnes, panificados, etc.), categorías donde la preferencia del cliente por un supermercado específico suele ser más fuerte, ya sea por calidad percibida, frescura, presentación o confianza. Además, para muchos consumidores existe una diferencia real entre comprar frescos en un supermercado vs. ir a una feria, lo que refuerza aún más la fidelización hacia el retailer cuando la experiencia es positiva.

El Cluster 0 también muestra una proporción relativamente alta (11.8%). Esta proporción es coherente con la naturaleza de este grupo. Al tratarse de un cluster compuesto por productos de consumo cotidiano los clientes tienden a mantener rutinas de compra estables, orientadas a la reposición semanal del hogar. Este tipo de comportamiento fomenta la fidelidad, ya que la experiencia de compra en categorías frescas y de primera necesidad suele generar preferencia por tiendas que garantizan calidad, frescura, disponibilidad y precios predecibles.

Gráficas utilizadas para el análisis de los clusters:

Clases y subclases principales de los clusters:

Cluster 0
CLASS_NAME
HORTALIZA 89868
BOLSAS DE RESIDUOS Y MERCADO 60745
DULCES 56823
FIDEOS 49177
QUESOS AL CORTE 40510
LECHE FRESCA 37929
GASEOSAS 37356
PAN DE MESA 33920
AGUAS 32702
PAN 30123
Name: count, dtype: int64

Cluster 1
CLASS_NAME
BOLSAS DE RESIDUOS Y MERCADO 17226
VESTIMENTA 10198
PROTECCION FEMENINA 9043
CEPILLOS DENTALES 7065
DULCES 6768
JABONES 6538
GASEOSAS 6248
MARCADORES 6123
SHAMPOO 5652
DESODORANTE MUJER 5636
Name: count, dtype: int64

Cluster 2
CLASS_NAME
GASEOSAS 66282
AGUAS 46385
PLATO PRINCIPAL 40810
TARTAS Y EMPANADAS 15245
SANDWICHERIA 14107
ALFAJORES 13980
BOLSAS DE RESIDUOS Y MERCADO 9463
JUGOS 8698
BEBIDAS SABORIZADAS 7880
DULCES 7281
Name: count, dtype: int64

Cluster 3
CLASS_NAME
HORTALIZA 109408
BOLSAS DE RESIDUOS Y MERCADO 61180
QUESOS ENVASADOS 55650
AGUAS 47987
DULCES 39920
SALADAS 39795
TROPICALES 37296
GASEOSAS 37056
PAN 32462
CITRICOS 32122
Name: count, dtype: int64

Cluster 4
CLASS_NAME
DULCES 83279
ALFAJORES 70843
GASEOSAS 61372
BOLSAS DE RESIDUOS Y MERCADO 59014
BIZCOCHOS 38752
CARAMELOS 33615
BOMBONES 28727
AGUAS 25944
PLATO PRINCIPAL 25944
JUGOS 24193
Name: count, dtype: int64

Cluster 5
CLASS_NAME
GASEOSAS 54092
CERVEZAS 28004
ENVASES 18418
PAPAS FRITAS 16904
BOLSAS DE RESIDUOS Y MERCADO 16402
PAN 15710
AGUAS 14863
CIGARRILLOS 14833
SNACKS DE MAIZ 11069
OTROS SNACKS 9987
Name: count, dtype: int64

Cluster 0
SUB_NAME
BOLSAS DE MERCADOS 57590
PAN CONCESIONADO 30123
LECHE FRESCA ENTERA 28339
PAN DE MOLDE REGULAR 26713
BULBOS 24796
NO RELLENAS 23469
AZUCAR 19055
JUGOS EN POLVO 18155
ARROZ BLANCO 18142
YERBA TRADICIONAL 18095
Name: count, dtype: int64

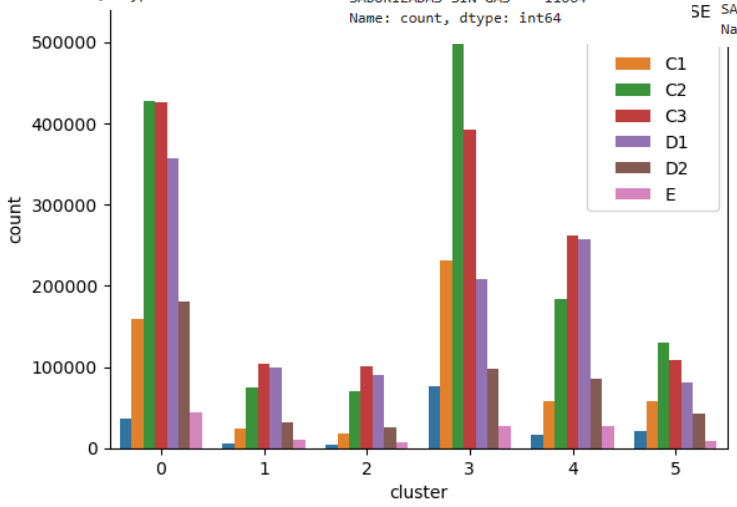
Cluster 1
SUB_NAME
BOLSAS DE MERCADOS 16232
CEPILLOS DENTALES ADULTOS 6206
TOALLAS HIGIENICAS 5483
JABONES COSMETICOS 5047
SHAMPOOS COSMETICO 3906
CREMAS DENTALES COMUNES 3775
DESODORANTES EN AEROSOL MUJER 3461
TOALLAS HUMEDAS COMUNES 3418
NO RELLENAS 3317
DESODORANTES EN AEROSOL HOMBRE 3306
Name: count, dtype: int64

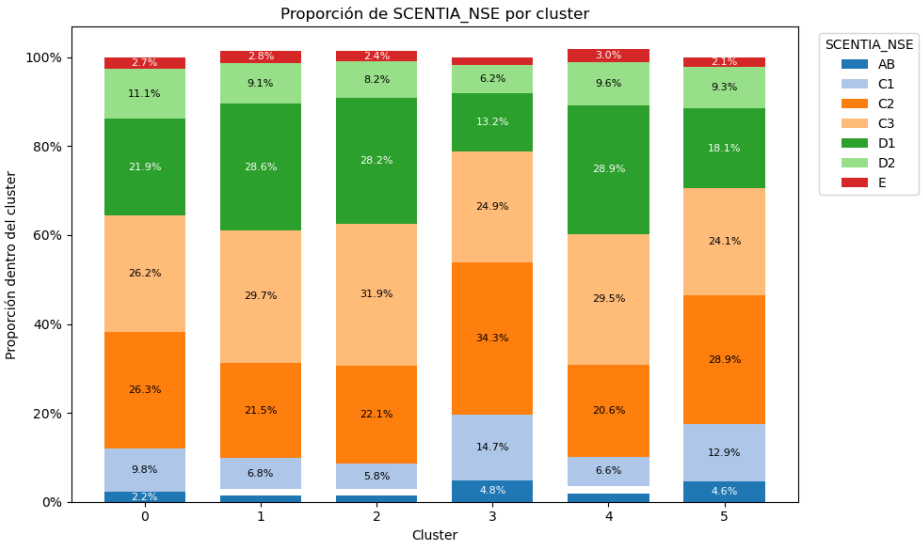
Cluster 2
SUB_NAME
COLA 27783
AGUA SIN GAS 23146
DE TERCEROS 22228
TARTAS Y EMPANADAS 15245
COLA LIGHT 13815
SABORES 12980
AGUA CON GAS 12131
SABORES LIGHT 11704
INDUSTRIALIZADOS 11392
SABORIZADAS SIN GAS 11064
Name: count, dtype: int64

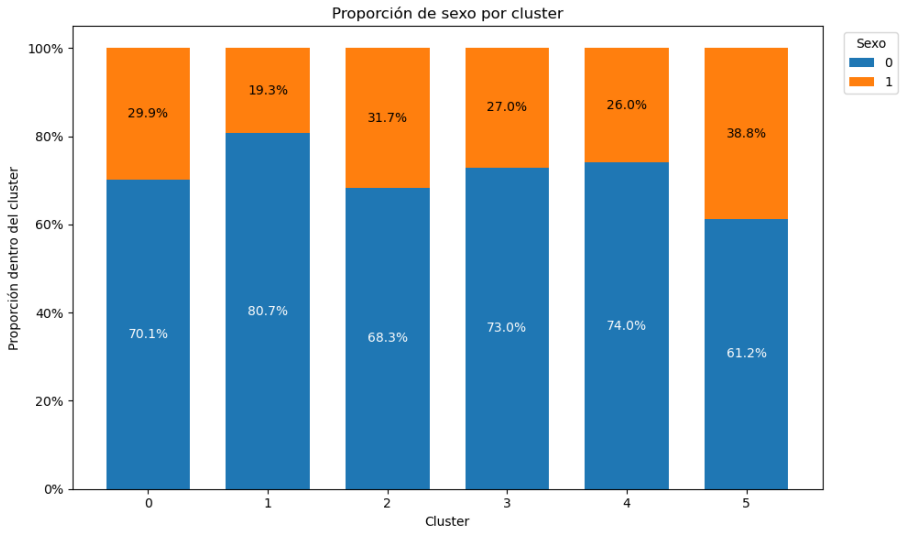
Cluster 3
SUB_NAME
BOLSAS DE MERCADOS 53886
PAN CONCESIONADO 32462
BANANAS 29894
AGUA SIN GAS 29850
TOMATES 23397
NO RELLENAS 20581
YOGURES BEBIBLES ENTERO 19418
FRUTOS 18137
BULBOS 17335
RAICES 16898
Name: count, dtype: int64

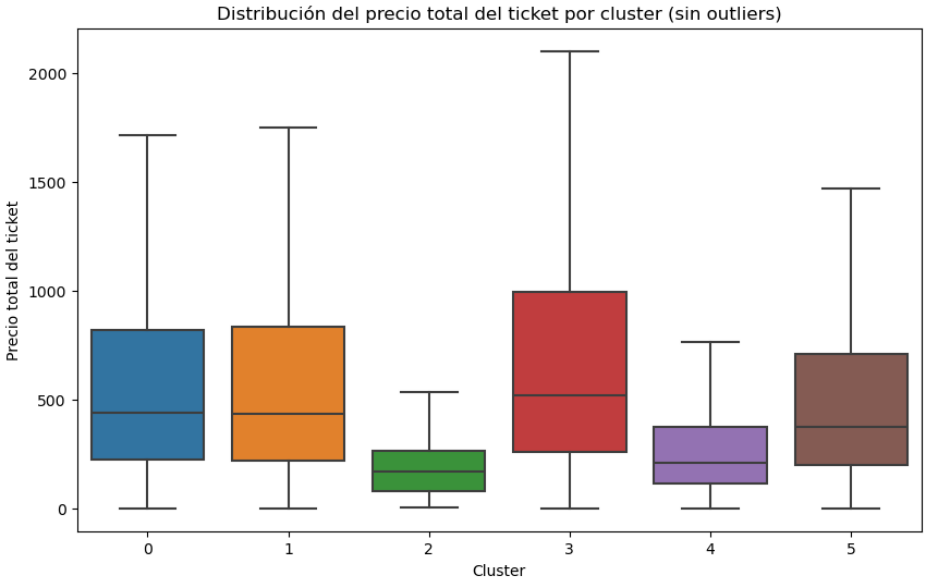
Cluster 4
SUB_NAME
INDUSTRIALIZADOS 61924
BOLSAS DE MERCADOS 58570
BIZCOCHOS CONCESIONARIO 38752
NO RELLENAS 34593
COLA 29779
CHOCOLATADA 20995
PAN CONCESIONADO 20595
TARTAS Y EMPANADAS 20243
RELLENA 20242
DE TERCEROS 15669
Name: count, dtype: int64

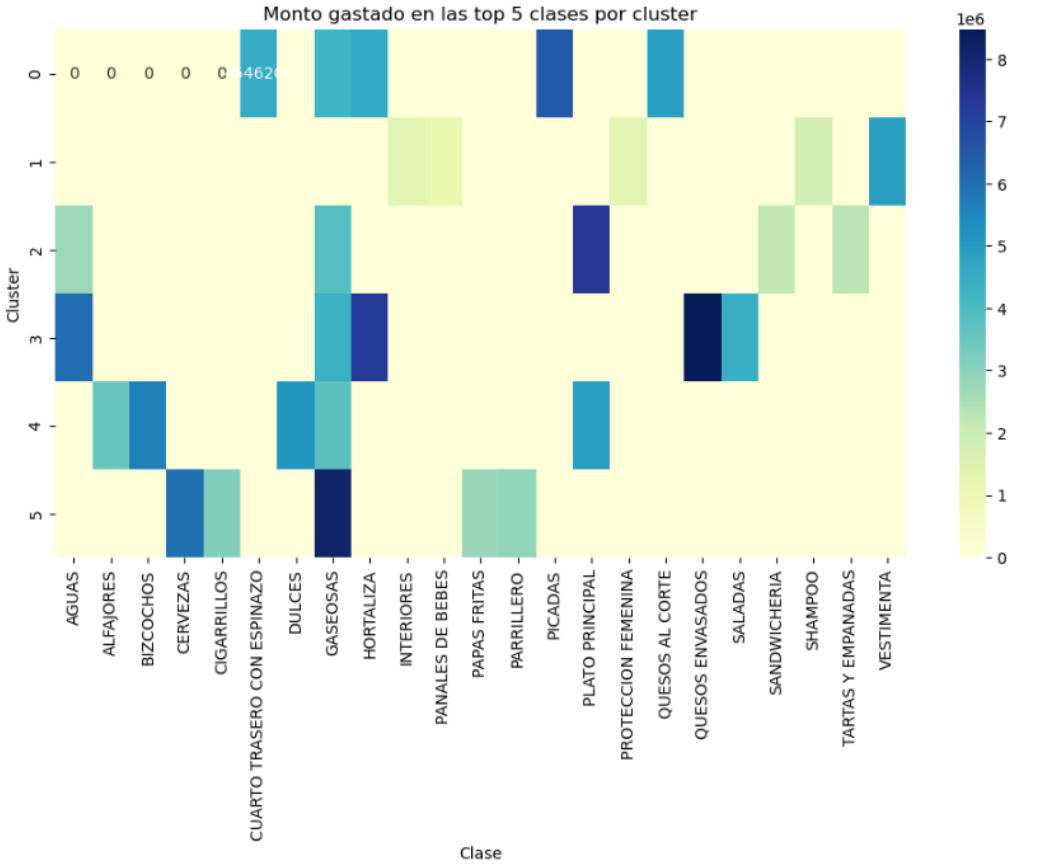
Cluster 5
SUB_NAME
COLA 20768
ENVASES 18418
CERVEZAS IMPORTADAS 16688
BOLSAS DE MERCADOS 16071
PAN CONCESIONADO 15710
CIGARRILLOS 14833
COLA LIGHT 13963
PAPAS FRITAS EN BOLSA 13160
CERVEZAS NACIONALES 10941
SABORES LIGHT 10411
Name: count, dtype: int64

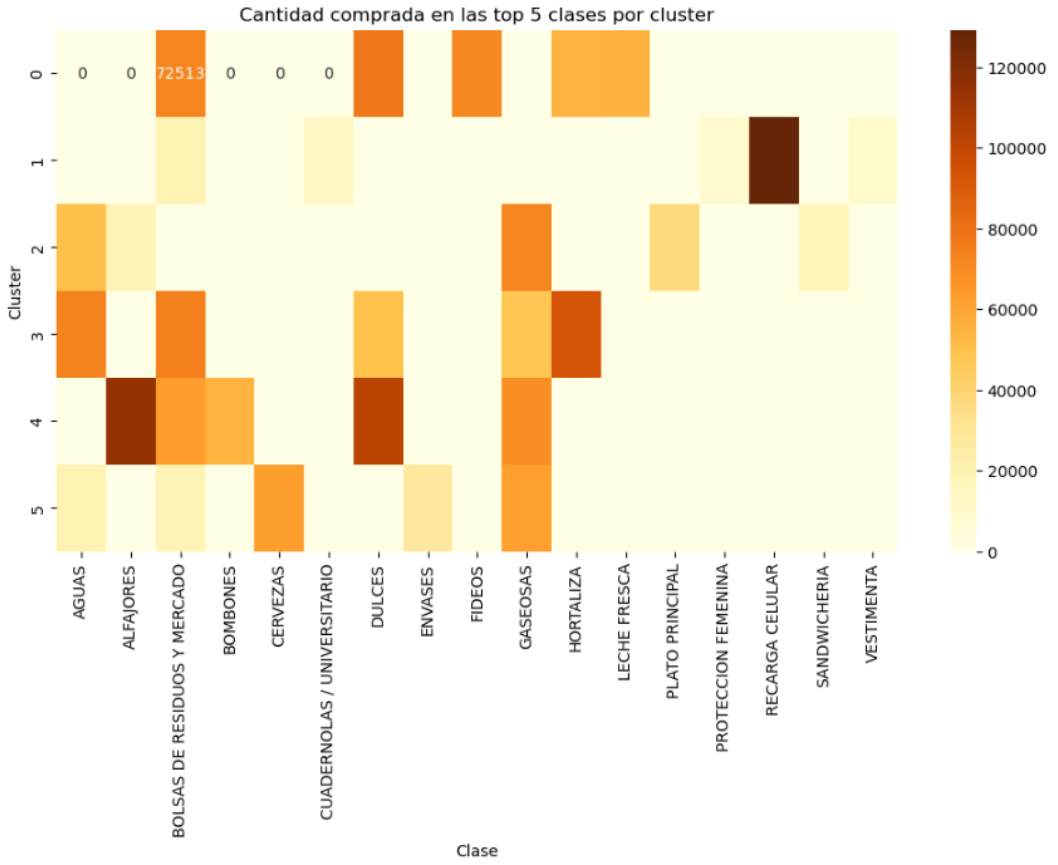


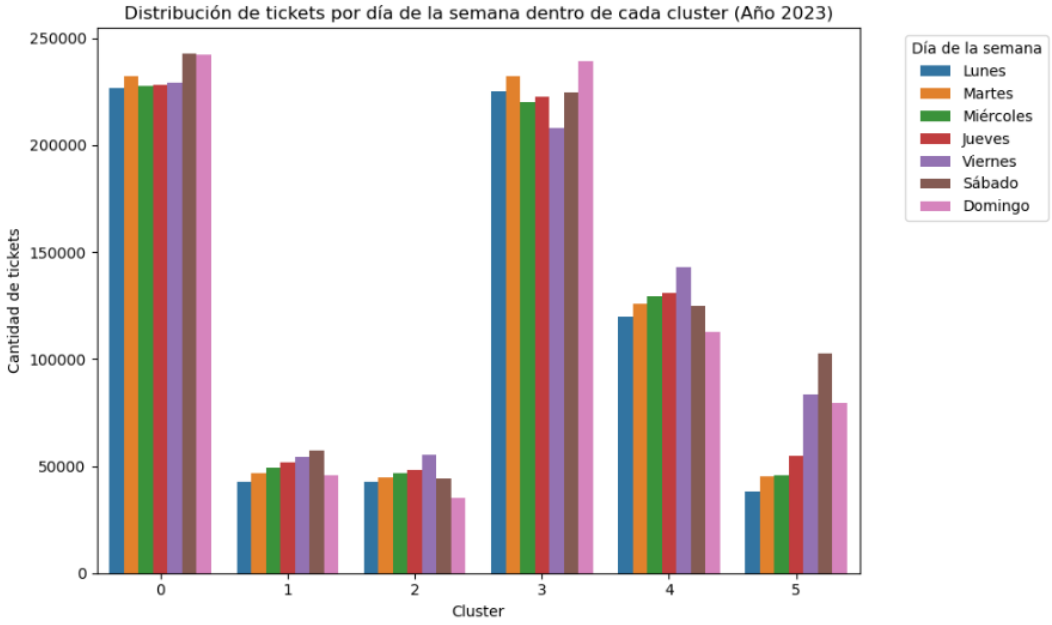

Proporción de SCENTIA_NSE por cluster
Proporción dentro del cluster
Cluster
SCENTIA_NSE
AB
C1
C2
C3
D1
D2
E
0%
20%
40%
60%
80%
100%
0
1
2
3
4
5
2.7%
11.1%
21.9%
26.2%
26.3%
9.8%
2.2%
2.8%
9.1%
28.6%
29.7%
21.5%
6.8%
2.4%
8.2%
28.2%
31.9%
22.1%
5.8%
6.2%
13.2%
24.9%
34.3%
14.7%
4.8%
3.0%
9.6%
28.9%
29.5%
20.6%
6.6%
2.1%
9.3%
18.1%
24.1%
28.9%
12.9%
4.6%


Proporción de sexo por cluster
Proporción dentro del cluster
Cluster
Sexo
0
1
0%
20%
40%
60%
80%
100%
0
1
2
3
4
5
29.9%
70.1%
19.3%
80.7%
31.7%
68.3%
27.0%
73.0%
26.0%
74.0%
38.8%
61.2%


Distribución del precio total del ticket por cluster (sin outliers)
Precio total del ticket
Cluster
0
500
1000
1500
2000
0
1
2
3
4
5


Monto gastado en las top 5 clases por cluster
Cluster
Clase
1e6
AGUAS
ALFAJORES
BIZCOCHOS
CERVEZAS
CIGARRILLOS
CUARTO TRASERO CON ESPINAZO
DULCES
GASEOSAS
HORTALIZA
INTERIORES
PANALES DE BEBES
PAPAS FRITAS
PARRILLERO
PICADAS
PLATO PRINCIPAL
PROTECCION FEMENINA
QUESOS AL CORTE
QUESOS ENVASADOS
SALADAS
SANDWICHERIA
SHAMPOO
TARTAS Y EMPANADAS
VESTIMENTA


Cantidad comprada en las top 5 clases por cluster
Cluster
Clase
AGUAS
ALFAJORES
BOLSAS DE RESIDUOS Y MERCADO
BOMBONES
CERVEZAS
CUADERNOLAS / UNIVERSITARIO
DULCES
ENVASES
FIDEOS
GASEOSAS
HORTALIZA
LECHE FRESCA
PLATO PRINCIPAL
PROTECCION FEMENINA
RECARGA CELULAR
SANDWICHERIA
VESTIMENTA



Cluster 0 – Compras de hogar y alimentación básica:

El Cluster 0 se caracteriza por concentrar productos de consumo cotidiano, principalmente hortalizas, dulces, fideos, quesos, pan, leche fresca y gaseosas. Este patrón sugiere un tipo de compra orientada a la reposición de alimentos básicos del hogar, realizada probablemente por consumidores que planifican sus compras. Es coherente que hay un aumento de tickets de este cluster los sábados y domingos, cuando es común realizar las compras para la semana.
La coexistencia de productos frescos (hortalizas, pan, lácteos) con alimentos industrializados (dulces, gaseosas, fideos) refleja un comportamiento de compra integral, en el cual el cliente busca abastecerse de una variedad de productos esenciales, combinando alimentos de primera necesidad con otros de placer o consumo ocasional.

En términos de necesidad, este cluster representa a consumidores que priorizan la frescura, la variedad y los precios accesibles, realizando compras completas y planificadas. Es posible inferir que se trata de grupos familiares o compradores responsables del abastecimiento del hogar, observando que el 50% central de los datos se concentra en individuos mayores de 30 y menores de 60.

La distribución del nivel socioeconómico presenta una forma aproximadamente normal, con una mayor concentración en los segmentos C2 y C3, y una menor presencia tanto en los extremos altos (AB) como en los bajos (E). Esta estructura es coherente con lo que se esperaría en función de la composición general de los clientes del supermercado, donde los grupos medios suelen representar la mayoría de los compradores habituales. En este sentido, el patrón observado sugiere que el Cluster 0 refleja un segmento transversal y representativo del público general, con una mezcla equilibrada de consumidores de distintos niveles socioeconómicos, pero con predominio de los sectores medios.

Este comportamiento es consistente con el perfil previamente identificado para este grupo, asociado a compras de hogar y alimentación básica, ya que dichos productos constituyen necesidades universales que atraen a consumidores de diferentes estratos, manteniendo una distribución proporcional a la base total de clientes.

Cluster 1 – Consumo rápido y conveniencia

El Cluster 1 está dominado por productos como gaseosas, aguas, platos principales, sandwichería, tartas y empanadas, alfajores y dulces, lo cual sugiere una orientación hacia compras de conveniencia o de consumo inmediato. Las subclases más frecuentes, como platos principales, tartas y empanadas y minutas, refuerzan la idea de una compra asociada a comidas listas para consumir, probablemente en horarios laborales o de tránsito.

Además, se observa que a medida que avanza la semana, desde el lunes hacia el sábado, el número de tickets pertenecientes a este cluster aumenta progresivamente, lo cual podría estar relacionado con el creciente cansancio acumulado de la semana laboral. Este patrón sugiere que los consumidores tienden a sustituir la preparación de comidas en el hogar por opciones prontas o listas para llevar hacia el final de la semana.
Este grupo representa un tipo de comprador que prioriza la rapidez, la disponibilidad y la practicidad, posiblemente trabajadores o estudiantes que buscan resolver una comida o merienda de forma rápida. El predominio de bebidas no alcohólicas y alimentos listos para consumir sugiere una compra impulsada por la necesidad del momento más que por planificación.

En este sentido, las necesidades principales del cluster giran en torno a la conveniencia, el acceso inmediato y la variedad en porciones individuales. Es el cluster que contiene a la menor cantidad de tickets.
Desde un punto de vista sociodemográfico, este cluster se distingue por reunir edades promedio más bajas que el resto de los grupos, concertándose entre 25 y 40 años, lo cual puede atribuirse al hecho de que los consumidores jóvenes suelen optar por comidas prontas o preparadas en lugar de cocinar. Este patrón de comportamiento está alineado con estilos de vida más dinámicos, donde prima la rapidez y la practicidad en las decisiones de compra.

En relación con el nivel socioeconómico, la distribución se asemeja a una forma aproximadamente normal, donde predomina la presencia de los grupos C2, C3 y D1, aunque con una ligera asimetría hacia los segmentos más bajos, destacando una mayor proporción de consumidores pertenecientes a la clase D1. Este desplazamiento sugiere que el consumo de comidas listas puede tener también una motivación económica, al representar una alternativa de bajo costo y menor planificación frente a la compra de ingredientes frescos o elaboraciones caseras.

Si bien se mantiene una mayoría de mujeres dentro de este grupo, se observa una mayor proporción relativa de hombres en comparación con la mayoría de los otros clusters. Este comportamiento podría vincularse con patrones de consumo asociados a rutinas laborales o estudiantiles, donde los hombres tienden a resolver las comidas diarias mediante opciones rápidas y accesibles.

Por último, se observa que el precio total por ticket en este cluster es significativamente más bajo que en el resto de los grupos. Esto indica que las compras suelen estar altamente enfocadas en productos específicos, como comidas prontas, bebidas o snacks, y no incluyen artículos de surtido o de reposición para el hogar. En consecuencia, el Cluster 1 refleja un perfil de consumidor pragmático, joven y orientado a la conveniencia, cuyas decisiones de compra están motivadas por la rapidez, el precio, la inmediatez del consumo y las soluciones “ready to eat”, más que por la planificación o el abastecimiento general.

Cluster 2 – Consumo impulsivo y productos indulgentes

El Cluster 2 presenta una alta concentración de productos como dulces, gaseosas, alfajores, bizcochos, caramelos y bombones, acompañados de subclases como industrializados, rellenas y bocaditos dulces.

Este patrón de consumo indica un comportamiento impulsivo o de gratificación inmediata, asociado a productos de indulgencia.
La coexistencia de bebidas azucaradas y alimentos de alto contenido calórico refleja un perfil de consumidor que busca satisfacer antojos o pequeños placeres diarios, más que realizar compras planificadas. Asimismo, la frecuencia de compra de este tipo de productos tiende a ser alta, aunque con tickets promedio bajos.

En comparación con el Cluster 1, este grupo muestra un comportamiento de consumo muy similar, aunque con una mayor cantidad de tickets y un importe promedio ligeramente superior. Por otro lado, se observa una leve menor proporción del segmento masculino respecto al Cluster 1.

En síntesis, el Cluster 2 representa una necesidad vinculada al placer, la variedad y el consumo por impulso. Los consumidores de este grupo priorizan la disponibilidad inmediata y las promociones, valorando más la gratificación emocional que la planificación o el precio unitario.

Cluster 3 – Compras frescas y alimentación saludable

El Cluster 3 agrupa predominantemente productos frescos y naturales, entre los que destacan hortalizas, frutas (tropicales y cítricos), quesos, aguas, pan y yogures. Las subclases más frecuentes, como bananas, tomates, bulbos y raíces, evidencian un perfil de compra centrado en alimentos perecederos y saludables. Este comportamiento se asocia a consumidores que buscan mantener una dieta equilibrada y que otorgan especial importancia a la calidad y frescura de los productos. La presencia de yogures bebibles y aguas sin gas refuerza la idea de un consumo orientado al bienestar, la naturalidad y la salud.
En términos de nivel socioeconómico, este cluster presenta una mayor concentración de clientes pertenecientes a los estratos más altos (AB, C1 y C2) en comparación con los demás grupos. Este patrón es coherente con la evidencia empírica que indica que los consumidores de mayor poder adquisitivo tienden a priorizar productos frescos, naturales y saludables, asociados a una mayor conciencia sobre la alimentación y la calidad nutricional. En este sentido, el consumo saludable puede interpretarse como un reflejo del capital cultural y económico de los segmentos más altos, quienes suelen tener tanto el conocimiento como la posibilidad económica de acceder a este tipo de productos.
Desde la perspectiva etaria, el Cluster 3 muestra la mediana de edad más alta entre todos los grupos, con una concentración significativa de consumidores entre los 40 y 60 años, y un rango extendido hacia edades mayores. Esto sugiere la presencia de un público adulto y maduro, con hábitos de compra más estables, planificados y orientados al bienestar a largo plazo. Este tipo de consumidor suele realizar compras más racionales, valorando la calidad por sobre el precio, y manteniendo una frecuencia de compra regular debido a la naturaleza perecedera de los productos adquiridos.
En línea con lo anterior, el análisis del precio total de los tickets muestra que este cluster presenta los tickets más altos del conjunto, evidenciando un mayor gasto promedio por compra. Este resultado es coherente con el perfil de consumidores de niveles socioeconómicos medios-altos y altos, cuyo comportamiento de compra se caracteriza por una menor sensibilidad al precio y una mayor disposición a pagar por productos frescos, de calidad superior y asociados a un estilo de vida saludable.
En cuanto al comportamiento a lo largo de la semana, se observa una disminución de las compras hacia el viernes y un aumento marcado los domingos, donde se alcanza el punto máximo de tickets. Este patrón sugiere que los consumidores de este cluster tienden a planificar sus compras de alimentos frescos durante el fin de semana, especialmente los domingos, en preparación para la semana entrante. La caída del viernes puede estar vinculada a que muchos consumidores posponen la compra de productos perecederos hasta el fin de semana, momento en el que disponen de más tiempo para hacer compras más completas y seleccionar productos frescos.

En conjunto, el Cluster 3 representa un segmento de consumidores maduros, de nivel socioeconómico medio-alto y alto, que priorizan la alimentación saludable, el consumo responsable y la frescura. Es un grupo estratégico para el diseño de ofertas premium, productos naturales y campañas de comunicación asociadas al bienestar, donde el valor percibido se apoya más en la calidad y la experiencia que en el precio.

Cluster 4 – Higiene, cuidado personal y artículos no alimenticios

El Cluster 4 se distingue del resto por su composición centrada en productos no alimenticios, principalmente vinculados al cuidado personal y la higiene del hogar. Entre las clases más frecuentes se encuentran protección femenina, cepillos dentales, jabones, shampoo, desodorantes y vestimenta, mientras que las subclases refuerzan esta tendencia con ítems como toallas higiénicas, cremas dentales y desodorantes en aerosol. Este patrón sugiere un tipo de compra más planificada y de menor frecuencia, destinada a la reposicón periódica de artículos de uso personal o doméstico.
En términos de volumen, este grupo presenta una de las menores cantidades de tickets junto con el Cluster 2, lo que coincide con la naturaleza de los productos que agrupa: bienes de reposición y consumo duradero, cuya compra no requiere alta recurrencia.
Desde la perspectiva etaria, el rango de edad del Cluster 4 es el más concentrado y acotado de todos los grupos, con una mediana en torno a los 40 años y una dispersión relativamente baja. Esto sugiere la presencia de un público adulto joven y adulto medio, caracterizado por rutinas estables y hábitos de compra predecibles. Este perfil etario coincide con una etapa de la vida en la que las decisiones de consumo tienden a ser más racionales y orientadas a la funcionalidad, reflejando una planificación consciente del gasto.
En cuanto al nivel socioeconómico, la distribución de este cluster se asemeja a la observada en los Clusters 0, 1 y 2, con una presencia significativa de los niveles C2, C3 y D1, lo que indica un público de ingresos medios. Esto resulta coherente con la composición de la canasta, que incluye productos esenciales y de primera necesidad, adquiridos de manera regular por la mayoría de los hogares.
Respecto al comportamiento por día de la semana, se observa que las compras de este cluster aumentan progresivamente a lo largo de la semana, alcanzando su pico máximo los días viernes, para luego disminuir durante el fin de semana. Esta tendencia sugiere que las compras de este tipo de productos suelen planificarse hacia el cierre de la semana laboral, cuando los consumidores destinan tiempo a realizar reposiciones domésticas o personales antes del fin de semana. La distribución es similar a la observada en los Clusters 2 y 3, reforzando la idea de un patrón de compra estructurado y recurrente, asociado a la planificación más que al impulso.
En síntesis, el Cluster 4 representa un segmento de consumidores racionales, planificadores y con poder adquisitivo medio, orientados a la compra funcional y recurrente de artículos de higiene y cuidado personal. Se trata de un grupo relevante para estrategias de fidelización por marca, programas de recompra y promociones cruzadas entre categorías complementarias dentro del hogar.

Cluster 5 – Ocio, recreación y consumo adulto

El Cluster 5 se caracteriza por la presencia destacada de cervezas, cigarrillos, gaseosas, snacks (papas fritas, snacks de maíz y otros) y envases retornables. Estas categorías revelan un patrón de consumo orientado al ocio y a la socialización, probablemente asociado a momentos de recreación o fines de semana.
La combinación de bebidas alcohólicas, cigarrillos y alimentos de acompañamiento (snacks) sugiere un perfil de consumidor adulto que realiza compras para momentos de disfrute o reunión social. Este cluster refleja un comportamiento de compra menos frecuente, pero con un ticket promedio más elevado, vinculado a situaciones de esparcimiento.

En cuanto al nivel socioeconómico, este cluster presenta una distribución con ligera asimetría hacia los niveles más altos, diferenciándose de la mayoría y asemejándose al Cluster 3, donde también predominan consumidores con mayor poder adquisitivo. Esta tendencia podría explicarse por la presencia de productos con precios unitarios más altos o asociados a marcas premium, especialmente dentro de las categorías de bebidas y cigarrillos.

Desde el punto de vista temporal, el comportamiento semanal evidencia una tendencia ascendente hacia el fin de semana, alcanzando su pico el sábado, seguido por un leve descenso el domingo. Este patrón es coherente con la naturaleza recreativa de los productos predominantes en este cluster, ya que las compras suelen concentrarse en los días previos al descanso o las actividades sociales. La menor actividad durante los primeros días de la semana refuerza esta interpretación, indicando que se trata de compras planificadas para el ocio más que para el consumo cotidiano.

Las necesidades predominantes en este grupo giran en torno al placer, la conveniencia y la experiencia social del consumo, por lo que estrategias comerciales basadas en promociones combinadas o packs temáticos (por ejemplo, cerveza + snack) podrían resultar particularmente efectivas para captar y fidelizar a este segmento.

5. POWER BI

ENFOQUE DEL DASHBOARD

El dashboard se diseñó con un enfoque orientado a la demanda, priorizando la creación de una herramienta práctica y accionable que apoye la toma de decisiones comerciales y operativas de la cadena.

A diferencia del análisis centrado en el comportamiento de los clientes, el tablero no busca estudiar preferencias personales ni patrones de compra a nivel micro, sino comprender la dinámica global de las ventas en sus distintas dimensiones. El objetivo principal fue brindar una visión integrada y comparativa que permita analizar la evolución de la demanda por sucursal, subclase, proveedor, canal de venta y tipo de local, identificando diferencias estructurales entre formatos (como hipermercado, supermercado tradicional o cercanía) así como tendencias y estacionalidades relevantes.

De esta manera, el dashboard no solo facilita la detección de patrones consistentes y la anticipación a cambios en el consumo, sino que también contribuye a optimizar el abastecimiento y fortalecer la comunicación con los proveedores. En conjunto, estas funciones permiten alcanzar una comprensión más profunda y operativa del desempeño comercial de la cadena.

EXTRACCIÓN DE DATOS Y MODELADO

Para la construcción del dashboard, se estableció una conexión directa entre Power BI y el data warehouse corporativo de Snowflake, utilizando las credenciales provistas por la empresa para cada integrante del equipo. La información fue consumida desde este entorno porque constituye la capa oficial de datos preparada por la organización: allí las tablas se encuentran integradas, curadas y estructuradas para su uso analítico, lo que facilita su incorporación en Power BI y evita trabajar con datos crudos o dispersos en múltiples fuentes. Esta integración permitió importar las tablas necesarias de forma segura y trabajar con datos reales y actualizados, manteniendo consistencia con los flujos operativos de la organización.

En caso de que la empresa decidiera incorporar el tablero dentro de su entorno productivo de Power BI, podría programar actualizaciones automáticas utilizando sus propias credenciales, garantizando así la actualización periódica de los indicadores. Las consultas SQL empleadas para generar el modelo se incluyen en los anexos (véase Anexo 4).

Como se mencionó previamente, el volumen transaccional de la cadena imposibilitaba trabajar con un nivel de detalle compra a compra sin comprometer el rendimiento. Por esta razón, se optó por construir una tabla transaccional agregada, lo que permitió mantener un equilibrio entre representatividad del dato, velocidad de carga y usabilidad del tablero. Esta tabla resume la información por año y mes (formato ANIOMES – YYYYMM), por sucursal, por proveedor y por subclase de producto. Cada fila refleja el comportamiento mensual de una combinación específica de estas dimensiones, incluyendo tanto la cantidad de unidades vendidas como el importe total vendido en pesos uruguayos. De esta forma, se conservan las dos perspectivas esenciales para el análisis de demanda: el volumen físico y el valor económico.

Durante la etapa de construcción del modelo tabular se realizaron, además, ciertos ajustes derivados de conversaciones con el equipo de la empresa. Algunas sucursales y subclases fueron excluidas deliberadamente por entenderse que distorsionaban la lectura de los datos o que figuraban en la base por razones operativas que no reflejan actividad comercial real. Estas decisiones permitieron depurar el modelo y garantizar que la información presentada en el dashboard representara de forma más fiel

el funcionamiento cotidiano de la cadena, evitando que elementos atípicos sesgaran la interpretación de los indicadores.

Para enriquecer el modelo y evitar duplicación de información, cada dimensión categórica presente en la tabla transaccional se relacionó con su respectiva tabla codiguera mediante relaciones de uno a muchos (1:N). Las codigueras incorporadas fueron las siguientes:

- Proveedores, con su identificador, nombre y país de origen.
- Sucursales, incluyendo identificador, descripción, ciudad, coordenadas, zona geográfica (Montevideo o interior), canal de venta (digital o físico) y tipo de local (hipermercado, supermercado o cercanía).
- Subclases, con su código, nombre, la clase a la que pertenecen y el tipo de venta (por unidad o por peso).
- Clases, con su identificador y descripción.

Adicionalmente, la tabla de clases se relaciona con la tabla de subclases mediante una relación 1:N, reflejando la jerarquía natural de categorías del surtido: múltiples subclases pertenecen a una misma clase, pero cada subclase reporta a una única clase.

En cuanto al manejo temporal, la columna ANIOMES de la tabla transaccional se vinculó con una tabla de calendario mensual mediante una relación muchos a uno (N:1). Esta tabla de calendario define, para cada mes, atributos como el año correspondiente, el trimestre, el primer día del mes y otras variables relevantes para la segmentación temporal del análisis. A su vez, este calendario mensual se relaciona con una tabla de calendario diaria a través de una relación 1:N, permitiendo preservar coherencia entre niveles de granularidad temporal y habilitando la expansión futura del modelo si la empresa decidiera incorporar análisis a nivel de día.

El resultado final es un modelo tabular optimizado, capaz de manejar más de ocho millones de registros sin comprometer el rendimiento del dashboard (una reducción drástica desde los 535 millones originales), y estructurado de manera que permita analizar la demanda de forma flexible por sucursal, proveedor, subclase, clase, canal de venta y temporalidad. La captura visual del modelo de datos puede observarse a continuación.

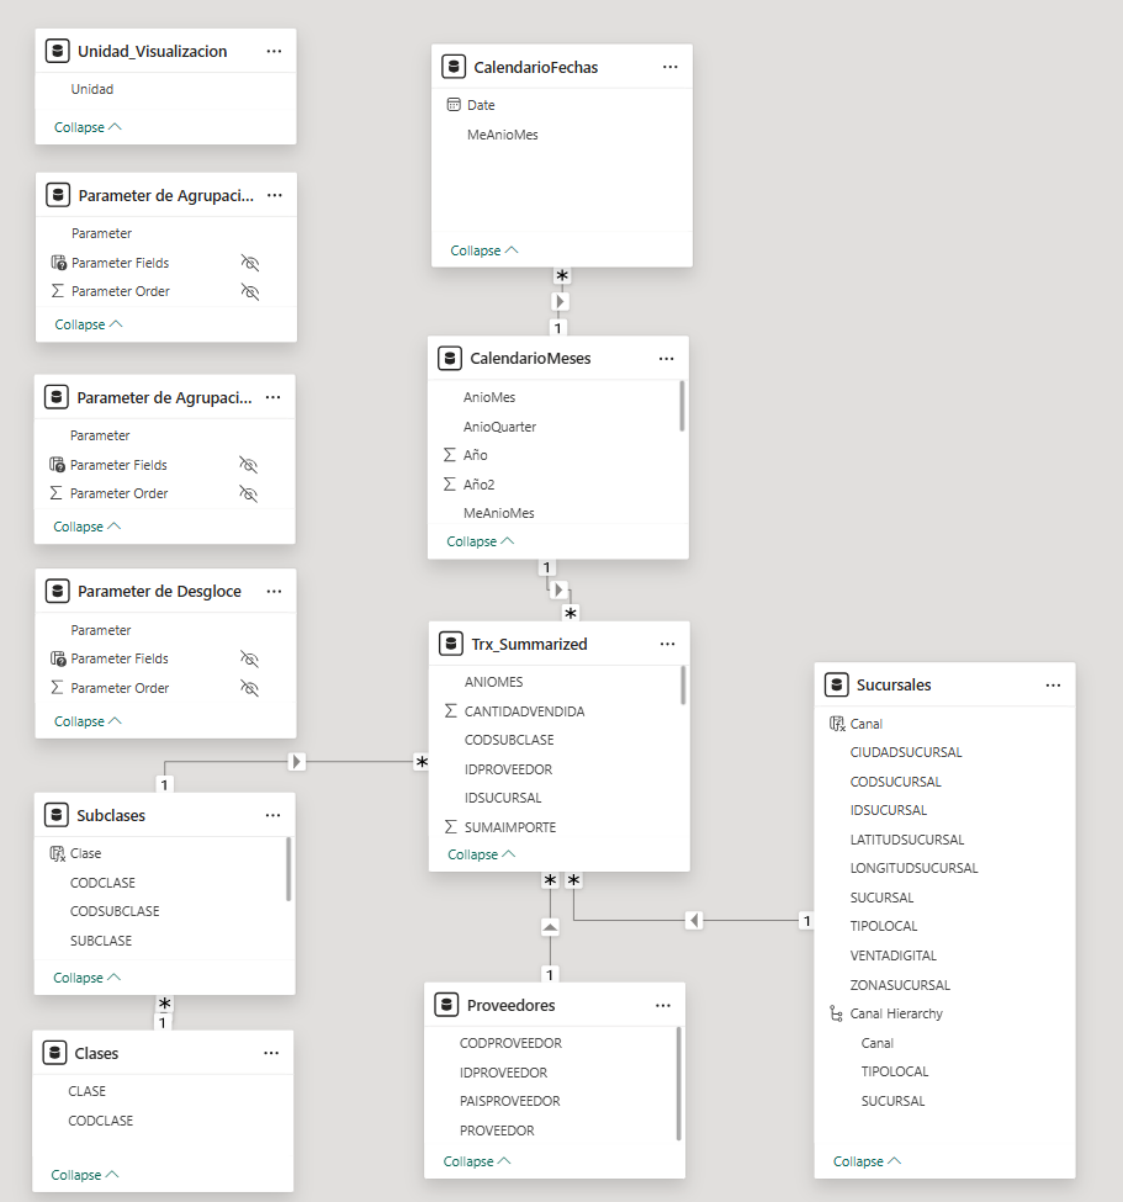


Figura 5.1 - Modelado de los datos en Power BI.

En la figura se visualizan también ciertas tablas que no forman parte del modelo analítico principal. Estas corresponden a tablas auxiliares (como parámetros o estructuras utilizadas únicamente como filtros) cuyo propósito es apoyar la navegación y el funcionamiento interno del tablero, pero que no contienen datos transaccionales ni intervienen en los cruces analíticos del modelo tabular.

PÁGINAS

El tablero se estructuró en cuatro páginas principales, cada una diseñada para abordar una perspectiva distinta del comportamiento de la demanda. Este enfoque permite al usuario explorar los datos de manera progresiva: desde una visión global del negocio hasta análisis detallados por categoría específica. Todas las páginas comparten un conjunto coherente de filtros que habilitan comparaciones consistentes entre unidades de tiempo, canales, tipos de venta y de sucursal, manteniendo la lógica analítica del tablero.

La organización de las hojas responde a dos objetivos centrales:

1. ofrecer una lectura integrada de la evolución de las ventas de la cadena
2. permitir profundizar en categorías particulares (subclases, sucursales y proveedores) para identificar diferencias relevantes en el comportamiento de la demanda según el ángulo de análisis seleccionado.

Para asegurar una interpretación consistente en todas las hojas, el tablero incorpora dos filtros obligatorios que estructuran la lectura del análisis. El primero permite seleccionar si las visualizaciones deben mostrarse en unidades físicas o en importe, lo que facilita examinar la demanda tanto desde la perspectiva del volumen vendido como desde su valor económico. El segundo filtro obliga a elegir la unidad de tiempo para representar las series de evolución (mes, trimestre o año, entre otras opciones), permitiendo adaptar la granularidad temporal según la necesidad del análisis. La combinación de ambos filtros brinda al usuario la capacidad de interpretar los datos desde distintos enfoques y asegura que todas las visualizaciones mantengan coherencia entre sí.

Más allá de las visualizaciones presentes en el documento, es importante señalar que el valor del dashboard no radica únicamente en su apariencia final, sino en la planificación técnica que lo sostiene. La estructura del modelo, la eficiencia de las relaciones y la definición de las medidas fueron pensadas de manera intencional, buscando equilibrar rendimiento, claridad y utilidad para el negocio. Gracias a ello, un volumen significativo de información (tres años de ventas en más de ciento veinte sucursales) puede analizarse de manera fluida y sin demoras. Además, a pesar de trabajar con datos ya agregados y sin el nivel de detalle de la compra individual, del producto específico o del cliente final, se logró construir una herramienta capaz de extraer información valiosa y, sobre todo, accionable. Las decisiones tomadas en torno a los filtros obligatorios, las medidas dinámicas y la organización de cada página apuntaron a ofrecer una experiencia clara y consistente, que permitiera obtener el máximo provecho de la información disponible sin añadir complejidad innecesaria.

Página general: Evolución de las ventas

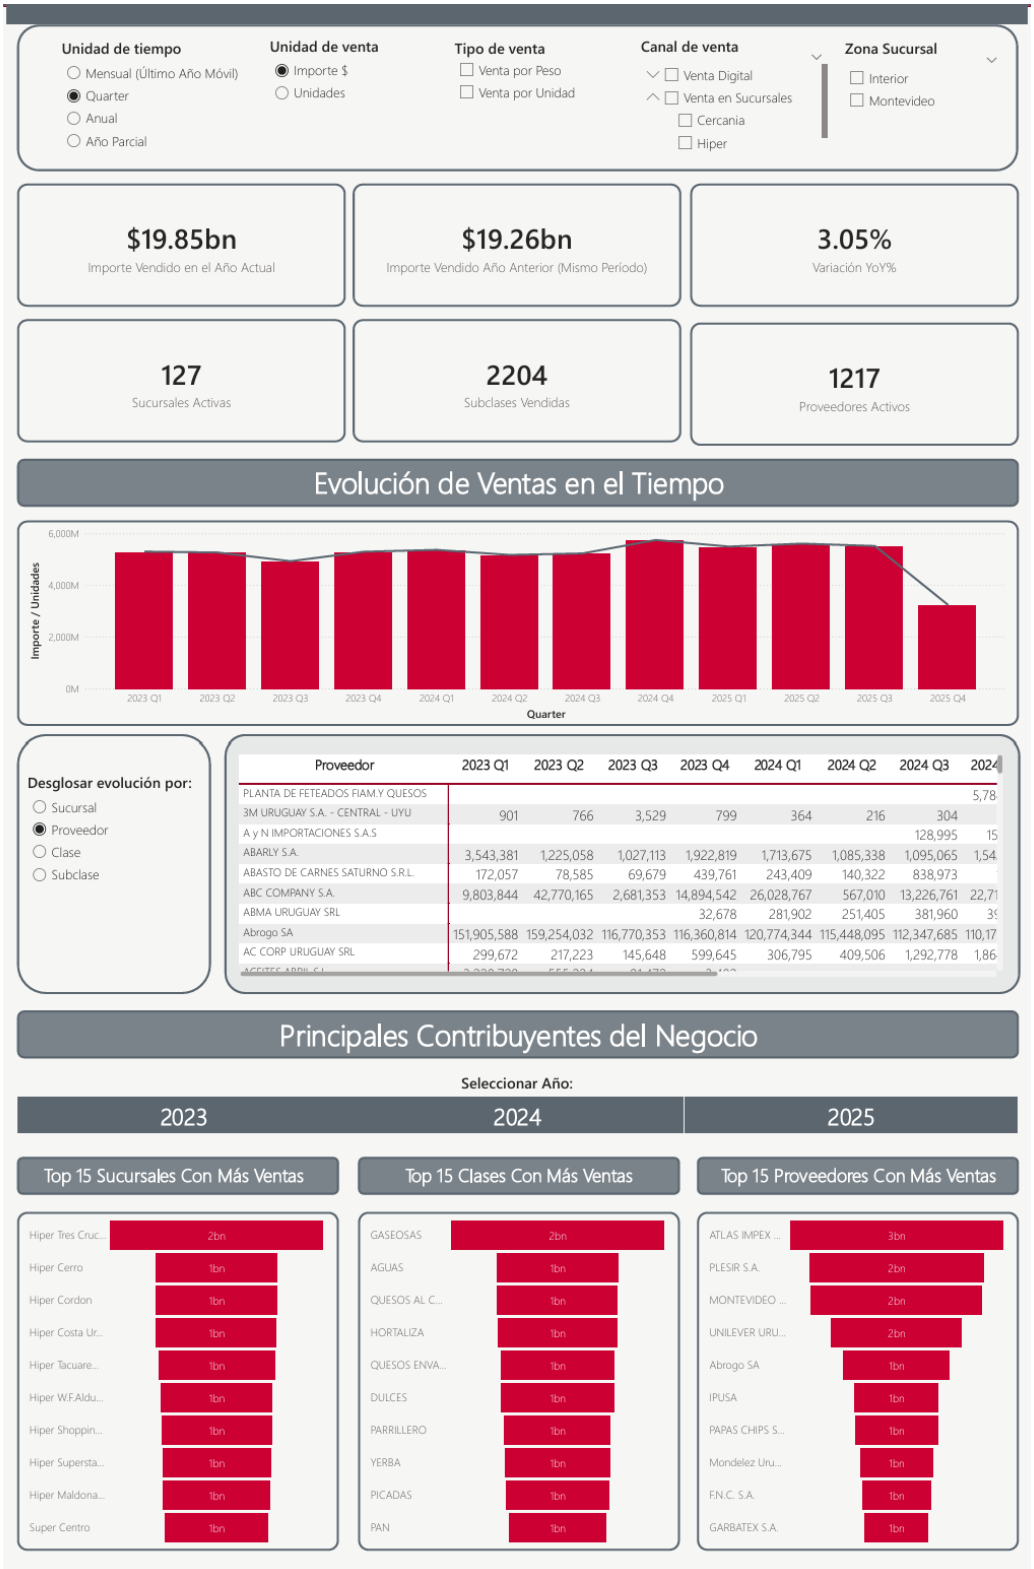


Figura 5.2 - Página 1 del tablero.

La primera página del tablero ofrece una visión general del desempeño comercial de la cadena, presentando de forma clara cómo evolucionan las ventas en distintos períodos. Su propósito es brindar un punto de partida para el análisis, permitiendo observar rápidamente cómo se comporta la demanda a nivel agregado y cómo varía en función del horizonte temporal seleccionado (mes, trimestre o año).

En la parte superior se incluyen varias tarjetas con indicadores simples que resumen los valores principales del período: ventas del año actual, ventas a la altura actual del año anterior, variación interanual y cantidad de sucursales, subclases y proveedores con actividad. Si bien el tablero permite realizar análisis detallados y desagregados, resulta fundamental que también ofrezca una lectura inicial clara y accesible. Estas tarjetas cumplen ese propósito al proporcionar un panorama general del desempeño comercial, permitiendo que el usuario obtenga rápidamente una idea del estado del negocio antes de profundizar en visualizaciones más complejas.

A continuación, se presenta un gráfico de barras que muestra la evolución temporal de las ventas y, junto a él, una matriz cuyo nivel de detalle puede seleccionarse desde un filtro dedicado. Esto permite desglosar la evolución por sucursal, proveedor, clase o subclase, combinando la lectura general con un análisis más específico de los segmentos que explican las variaciones en la demanda.

La página se complementa con tres visualizaciones que muestran las 15 sucursales, subclases y proveedores con mayor volumen de ventas. Estos rankings ayudan a dimensionar el peso relativo de cada categoría dentro del total y permiten detectar rápidamente a los actores más relevantes. Además, esta sección incorpora un filtro exclusivo que permite seleccionar el año para el cual se desean visualizar los rankings. De esta manera, el usuario puede observar cómo varían las posiciones relativas entre un año y otro, identificar categorías que ganan o pierden protagonismo y analizar la evolución de los principales contribuyentes a lo largo del tiempo.

Todas estas visualizaciones responden íntegramente a los filtros disponibles en la página, tales como tipo de venta (por unidad o por peso), canal (digital o sucursales) o zona geográfica.

Segunda página: Análisis por canal, sucursal

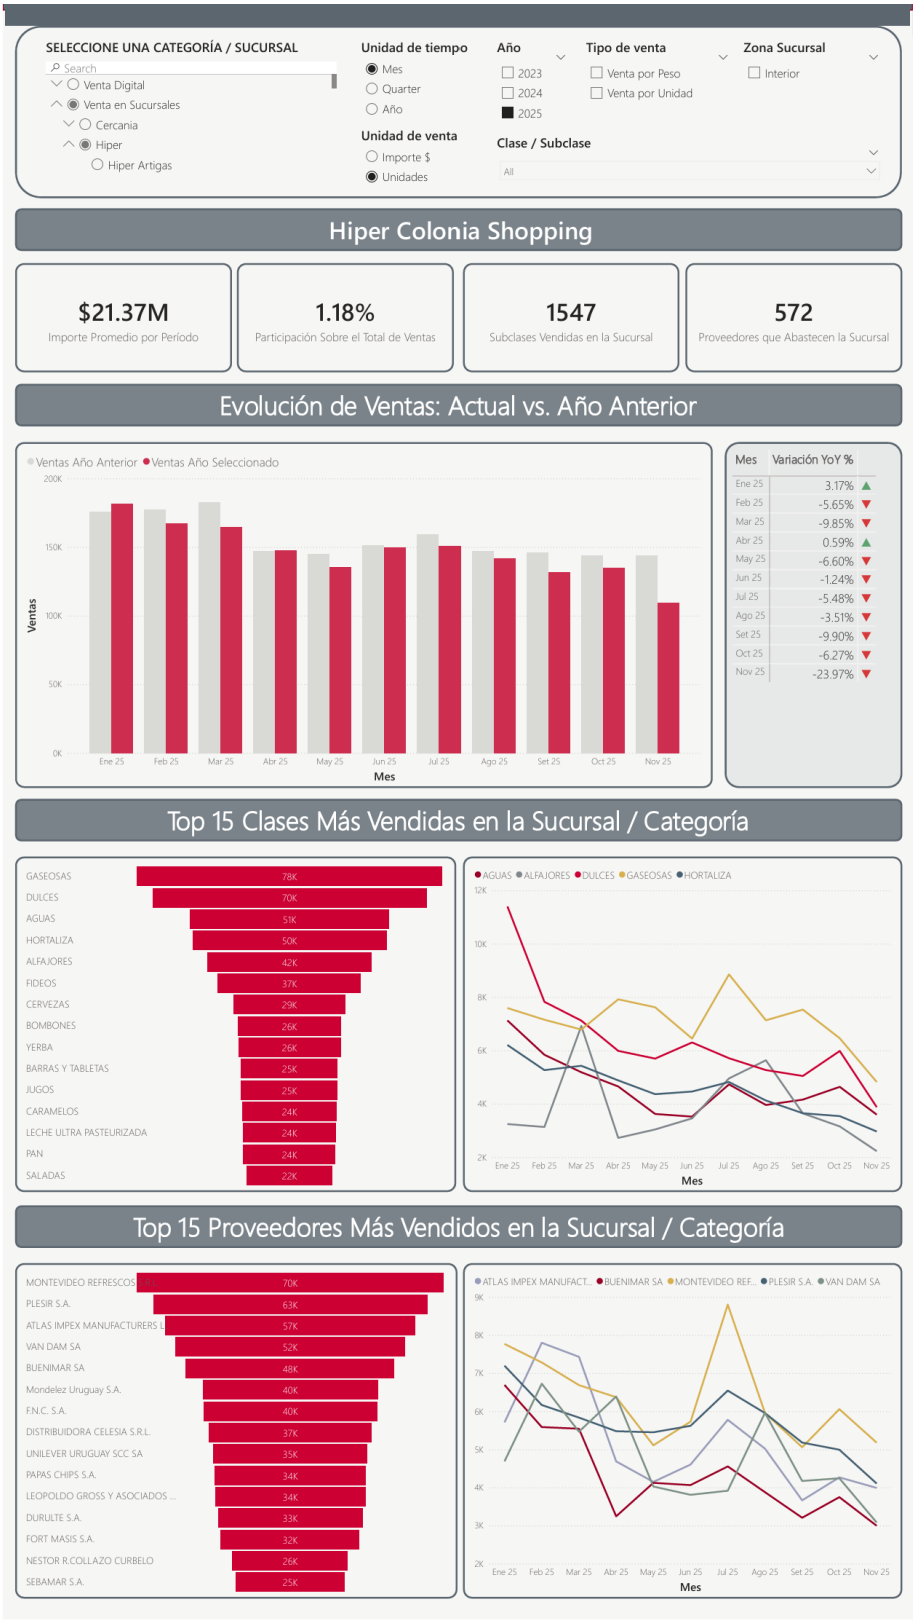


Figura 5.3 - Página 2 del tablero.

La tercera página permite analizar el comportamiento de una sucursal específica (o de un grupo de sucursales, cuando el usuario selecciona tipos de local o categorías más amplias) desde una perspectiva

local. Esta hoja tiene como objetivo identificar qué productos impulsan las ventas del local, cómo evolucionan sus ventas y qué rol desempeña la sucursal dentro del total de la cadena.

Luego de seleccionar la sucursal (o categoría), se presentan indicadores que resumen su desempeño reciente. Entre ellos se incluyen el importe y la cantidad vendida promediadas según el período seleccionado (mensual, trimestral o anual), su participación sobre el total de ventas, la cantidad de subclases comercializadas y el número de proveedores que abastecen al local. Estos indicadores permiten dimensionar de manera rápida el tamaño, la diversidad y la relevancia relativa de la sucursal dentro de la cadena.

La visualización principal de esta página compara la evolución temporal de las ventas con el mismo período del año anterior. De esta forma se observan cambios en el comportamiento de la sucursal, permitiendo diferenciar entre episodios puntuales y tendencias más persistentes.

La página incorpora también visualizaciones que combinan un ranking y una perspectiva temporal. Por un lado, se muestran las subclases con mayor volumen de ventas en la sucursal, y sobre ese conjunto se destaca la evolución temporal de las cinco principales, lo que permite identificar cuáles categorías explican la mayor parte del desempeño del local y cómo varían a lo largo del tiempo. De manera análoga, se presenta un ranking de los proveedores más relevantes para la sucursal, complementado con una gráfica que muestra la evolución de aquellos con mayor peso relativo. Este enfoque conjunto facilita comprender no solo quiénes son los actores más importantes, sino también cómo se comportan sus ventas en el tiempo.

Tercera página: Análisis por proveedor

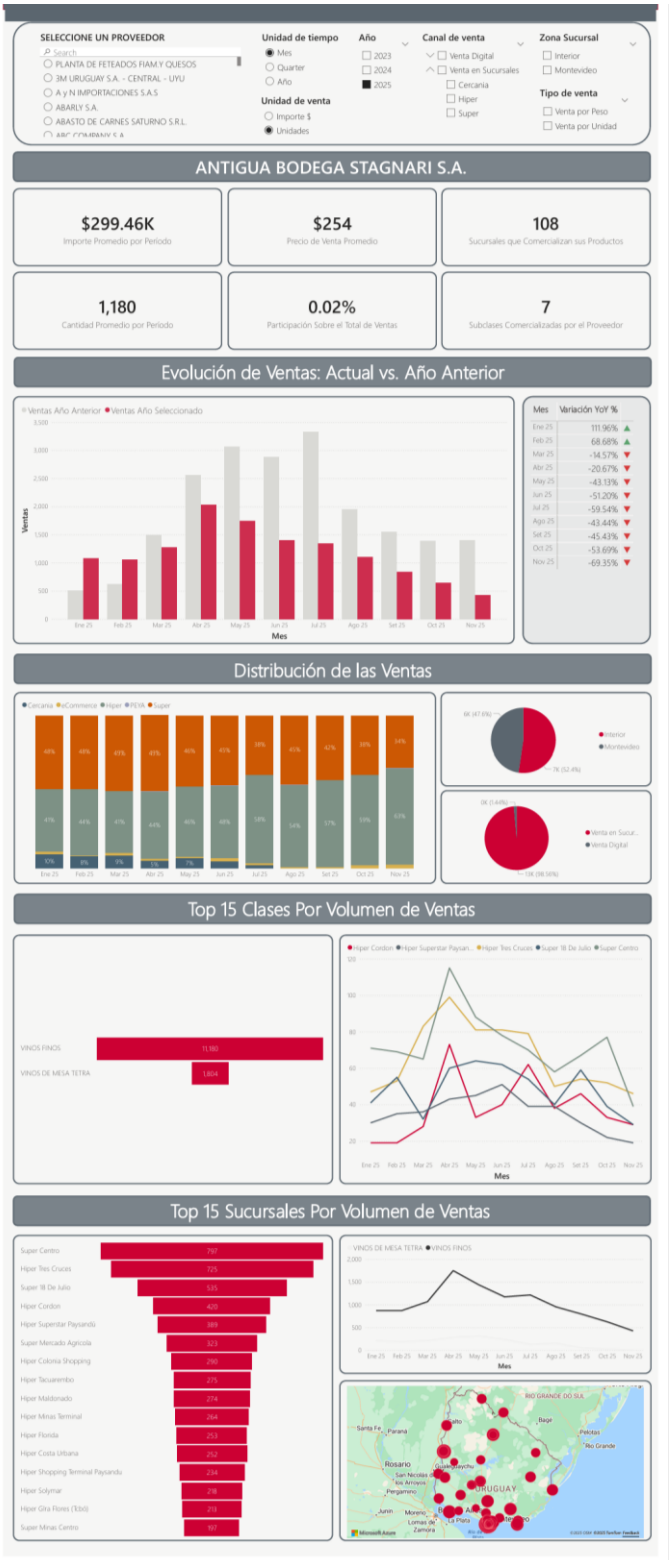


Figura 5.4 - Página 3 del tablero.

La tercera página analiza el desempeño de un proveedor específico dentro de la cadena, permitiendo evaluar su aporte al negocio, cómo se distribuyen sus productos entre las distintas sucursales y cuáles son las categorías más relevantes en su portafolio.

Los indicadores superiores resumen el desempeño global del proveedor: importe y la cantidad vendida promediadas según el período seleccionado (mensual, trimestral o anual), el precio de venta promedio, su participación sobre el total de ventas, el número de sucursales donde registra actividad y la cantidad de subclases que comercializa. Estos datos permiten dimensionar rápidamente la importancia del proveedor dentro del surtido.

Al igual que en las páginas anteriores, se presenta una comparación temporal entre el año actual y el año anterior, facilitando la detección de fluctuaciones en la demanda. También se incorpora una visualización de la distribución por canal y por tipo de local, lo cual permite identificar si el proveedor tiene mayor presencia en tiendas físicas, en el canal digital o en determinados formatos comerciales.

Se incluyen además visualizaciones que permiten analizar tanto las subclases como las sucursales más relevantes para el proveedor. En ambos casos, se presenta un ranking de las categorías con mayor volumen de ventas junto con una gráfica que muestra la evolución temporal de las más destacadas. Finalmente, un mapa interactivo complementa este análisis al mostrar en qué sucursales sus productos alcanzan mayor presencia, representada mediante círculos proporcionales al nivel de ventas.

Cuarta página: Análisis por Clase y Subclase

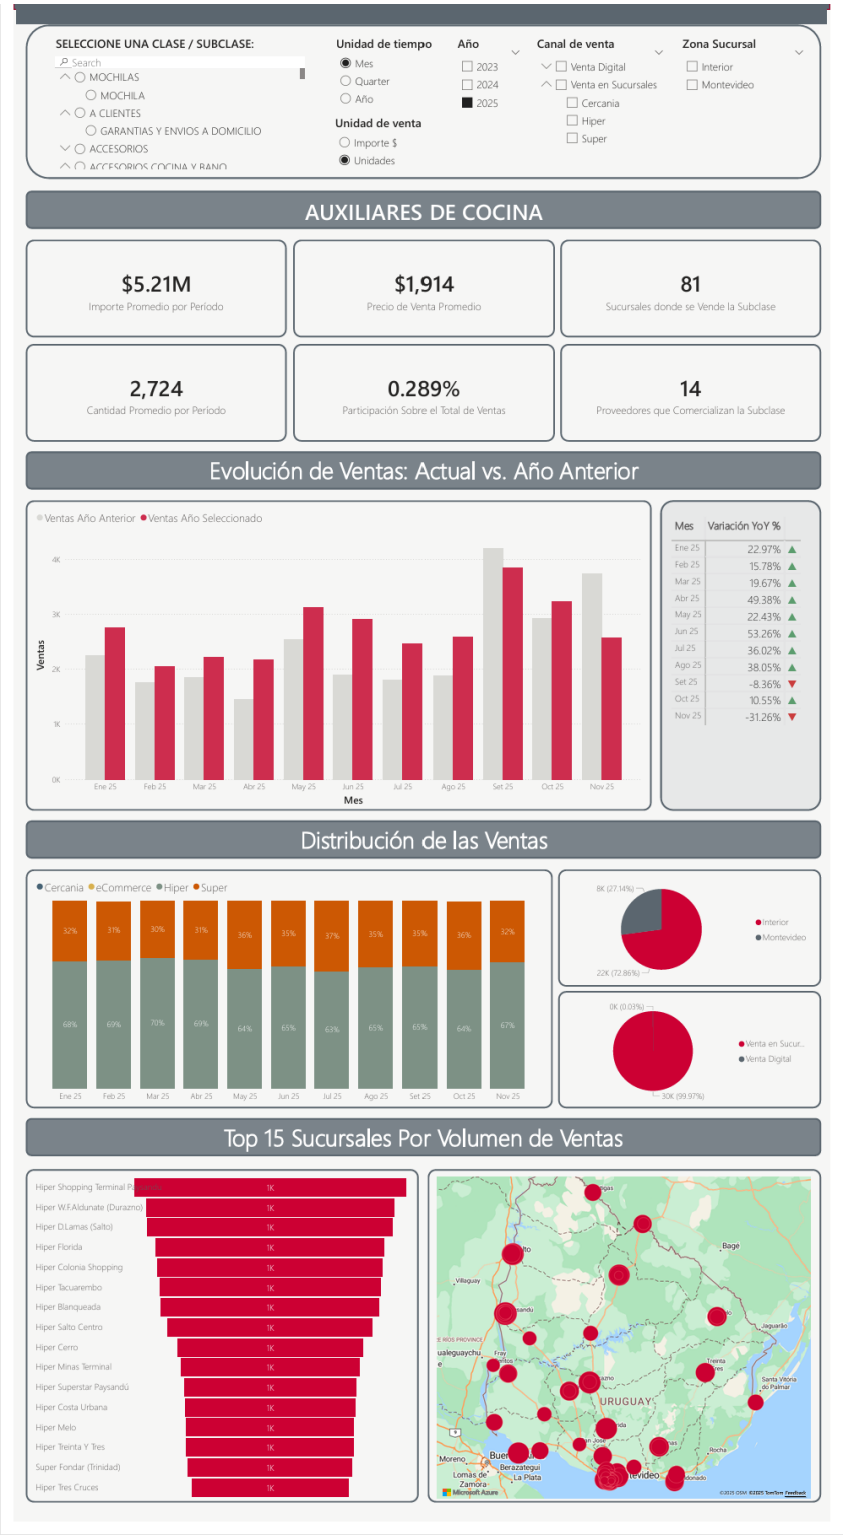


Figura 5.5 - Página 4 del tablero.

La cuarta página está orientada al análisis detallado de una categoría de producto específica. Aquí el usuario debe seleccionar una subclase o clase para acceder a una lectura focalizada sobre su comportamiento en la cadena. El objetivo es comprender cómo evoluciona la demanda de esa

categoría en particular, cuál es su peso dentro del total de ventas y en qué contextos (sucursales, canales o formatos) adquiere mayor relevancia.

La página comienza con un conjunto de indicadores que resumen el desempeño de la categoría seleccionada. Entre ellos se incluyen el importe y la cantidad vendida promediadas según el período elegido (mensual, trimestral o anual), el precio de venta promedio, el número de sucursales donde la categoría registra ventas, su participación sobre el total y la cantidad de proveedores que la comercializan. Estos indicadores facilitan una lectura rápida y permiten dimensionar la importancia relativa de la categoría dentro de la cadena.

Se presenta luego un gráfico comparativo entre las ventas actuales y las del mismo período del año anterior, lo cual permite evaluar variaciones recientes y detectar señales de crecimiento o caída. Este componente es especialmente útil para categorías sensibles a la estacionalidad.

Complementando este análisis, la página incluye visualizaciones que muestran la distribución de la demanda por canal de venta, tipo de local y tipo de venta, lo que permite detectar diferencias estructurales en el comportamiento de la categoría. Asimismo, se incorpora un mapa interactivo que representa cada sucursal del país con un punto proporcional al nivel de ventas, facilitando así la identificación de patrones geográficos y diferencias regionales.

Finalmente, se presenta el Top 15 de sucursales donde se vende más la subclase seleccionada, acompañado por un gráfico de líneas que muestra la evolución temporal del Top 5. De esta manera, la página permite analizar en detalle dónde se concentra la demanda y cómo varía en el tiempo dentro de los principales puntos de venta.

MEDIDAS Y MÉTRICAS UTILIZADAS

Las medidas desarrolladas en Power BI se diseñaron con el objetivo de que el dashboard pudiera adaptarse a distintas formas de analizar la demanda, sin duplicar visualizaciones ni crear versiones paralelas de cada página. Para ello se definió un conjunto acotado de medidas que permiten cambiar entre unidades de análisis (importe o unidades) y entre diferentes escalas temporales, manteniendo siempre la coherencia entre las visualizaciones.

La medida central del tablero es _Ventas_Dinámico, que actúa como base para la mayoría de los cálculos. Esta medida responde directamente al filtro Unidad de venta: cuando el usuario selecciona “Unidades”, suma la cantidad vendida; cuando selecciona “Importe $”, suma el monto vendido. De esta forma, todas las páginas del dashboard pueden analizarse tanto desde la perspectiva del volumen físico como desde la perspectiva económica. Esta dualidad es fundamental, ya que el comportamiento de la demanda no siempre coincide con el aporte económico: aquello que se vende en grandes cantidades no necesariamente es lo que genera la mayor facturación, tanto a nivel de categorías como de sucursales y proveedores.

Además, se incorporó un parámetro de campos para gestionar la selección del nivel temporal en el que se desea analizar la evolución de las ventas. Esto permite visualizar tendencias por mes, trimestre, año completo o año parcial, opción disponible exclusivamente en la página general del tablero. Esta vista es especialmente útil, ya que evita comparaciones distorsionadas cuando el año en curso aún no ha finalizado: cada año histórico se recorta hasta el mismo punto temporal del año actual, lo que permite evaluar cómo evolucionaba la demanda en años anteriores a la misma altura del calendario. Para implementar este comportamiento se creó la medida _Ventas_Mix, que combina la lógica de

_Ventas_Dinámico con el parámetro temporal, integrando ambas dimensiones en un cálculo único y coherente.

En esta primera página, el usuario puede alternar entre la evolución anual de los últimos dos años, la evolución trimestral del mismo período, la evolución mensual del año actual o la vista de año parcial. Esta flexibilidad permite adaptar la lectura del comportamiento global según el tipo de análisis que se desee realizar.

En las demás páginas del tablero, la selección temporal se limita a las escalas mensual, trimestral o anual. El usuario puede, además, acotar el horizonte seleccionando un año específico, lo que contribuye a mantener la claridad de las visualizaciones cuando el período completo abarca un lapso demasiado amplio.

Con el fin de habilitar análisis comparativos, se incluyeron medidas adicionales orientadas a contrastar el desempeño actual con el del año anterior. Entre ellas se destacan _Ventas_Dinámico_PrevYear, que captura las ventas del mismo período, pero del año previo, y _Ventas_Dinámico_YoY%, que calcula la variación porcentual interanual. Estas medidas permiten evaluar si la empresa (o la categoría analizada) se encuentra mejor o peor que en el mismo punto del año anterior, identificando cambios relevantes en el comportamiento de la demanda.

El tablero incorpora también un conjunto de medidas diseñadas para alimentar las tarjetas utilizadas como KPIs en todas las páginas. Entre ellas se incluyen:

- la cantidad de sucursales activas o, según el caso, la cantidad de sucursales en las que se comercializa la subclase o los productos del proveedor seleccionado;
- la cantidad de subclases vendidas en la sucursal, o la cantidad de subclases comercializadas por un proveedor;
- la cantidad de proveedores que abastecen la sucursal o la subclase analizada;
- el porcentaje de participación de la categoría seleccionada sobre el total de ventas;
- medidas específicas para subclases y proveedores, tales como el total vendido en unidades, el total vendido en importe y el precio promedio resultante.

Finalmente, el modelado del tablero incorporó el uso de jerarquías, un recurso que permite organizar categorías en distintos niveles dentro de un mismo campo y facilita la navegación entre escalas de análisis sin necesidad de cambiar de filtro. En el caso de los productos, se construyó una jerarquía que permite alternar entre clases y subclases dentro del mismo selector, lo que simplifica la exploración del surtido y permite adaptar el nivel de detalle según la necesidad del análisis. De forma similar, se definió una jerarquía para las sucursales que organiza los distintos formatos y canales de venta, permitiendo analizar la demanda desde una perspectiva más general o específica. Este enfoque reduce la cantidad de filtros necesarios y contribuye a una navegación más intuitiva del tablero.

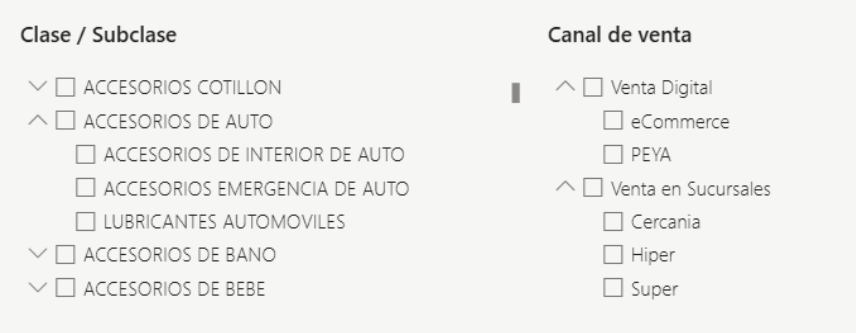


Figura 5.6 - Jerarquías.

Las medidas y parámetros mencionados se presentan en detalle en el Anexo 5.

6. CONCLUSIONES GENERALES

El desarrollo del proyecto permitió transformar un conjunto de datos masivo y complejo en información estructurada y analíticamente útil, aportando una comprensión más profunda sobre los patrones generales de consumo en la cadena. A través del uso combinado de técnicas de representación vectorial (Word2Vec) y algoritmos de agrupamiento (K-Means), se generó una clusterización suave, cuyo objetivo fue explorar posibles formas de estructurar perfiles de clientes a partir de sus comportamientos de compra. Si bien no se obtuvo una segmentación definitiva ni operativa, los resultados reflejan diferencias sutiles pero coherentes con la lógica del negocio y el comportamiento humano, ofreciendo una primera aproximación válida sobre cómo podrían organizarse grupos de clientes con hábitos de consumo distintos.

La experiencia evidenció la importancia de definir correctamente los objetivos y el alcance al trabajar con bases de datos de gran escala. Las limitaciones computacionales, la heterogeneidad del comportamiento de los consumidores y la amplia definición del concepto de "fidelizado" dejaron en evidencia la necesidad de utilizar enfoques analíticos escalables, adaptativos y acordes al volumen y calidad de los datos disponibles. Asimismo, el análisis mostró que el programa de fidelidad actual no necesariamente distingue a clientes realmente vinculados con la marca de aquellos que utilizan la tarjeta solo de forma eventual. Esto abre la puerta a revisar tanto la definición de fidelización como los incentivos asociados, a fin de mejorar su efectividad y su alineación con los patrones reales de consumo.

Desde una perspectiva metodológica, el proyecto demostró que los enfoques híbridos, como la combinación de embeddings y técnicas de clustering, son especialmente prometedores en entornos de retail con alta dimensionalidad y datos desestructurados. Se identificó la importancia de trabajar con datos más depurados, consistentes y completos, especialmente en lo referente al programa de fidelidad, para elevar la calidad interpretativa de futuros modelos.

Los resultados obtenidos ilustran el potencial analítico de estas técnicas, pero también evidencian las limitaciones impuestas por la infraestructura disponible y por la calidad del dato. Con una base más sólida, habría sido posible evaluar la evolución temporal del comportamiento de miles de clientes, detectar transiciones entre patrones de compra y construir una segmentación dinámica con mayor granularidad, capaz de anticipar riesgos de abandono e informar decisiones comerciales de forma más proactiva.

El desarrollo del dashboard en Power BI complementó los análisis anteriores al ofrecer una visualización estructurada de la demanda, permitiendo observar su evolución en diferentes escalas temporales y comparar el desempeño entre sucursales, subclases y proveedores. Su diseño, basado en datos

agregados y en una estructura flexible de filtros, facilita identificar tendencias y estacionalidades, reconocer diferencias entre formatos y canales de venta, y detectar variaciones relevantes que puedan influir en la planificación comercial. Aunque el tablero no busca analizar el comportamiento individual del cliente (como sí lo hace la clusterización), aporta una perspectiva operativa valiosa sobre la dinámica general del negocio, habilitando un monitoreo continuo de las ventas y apoyando decisiones vinculadas al surtido, la gestión con proveedores y la anticipación de cambios en la demanda.

Sugerencias a futuro:

- Con base en estas observaciones, se sugiere aprovechar estos clusters demostrativos como punto de partida para rediseñar el programa de fidelidad, orientando los incentivos hacia conductas que reflejen verdadera lealtad y no solamente el registro en el sistema o el uso esporádico de la tarjeta. A nivel estratégico, una línea concreta de acción consiste en diseñar un esquema de beneficios diferenciado según el perfil identificado, donde los clientes de mayor valor potencial reciban incentivos alineados con su comportamiento (descuentos específicos, beneficios personalizados, contenido relevante), mientras que los segmentos de menor compromiso sean estimulados mediante acciones orientadas a incrementar su frecuencia y su ticket promedio. De esta forma, el programa de fidelidad podría pasar de un modelo principalmente transaccional a una herramienta estratégica para gestionar la relación con el cliente, reduciendo la proporción de usuarios inactivos y fortaleciendo la recurrencia. Cabe señalar que, durante el proyecto, el equipo de la empresa manifestó que ya se encuentra trabajando en la distinción entre clientes recurrentes y fidelizados, por lo que estos resultados deben entenderse como un insumo complementario a las iniciativas actualmente en desarrollo.
- Adicionalmente, se identificó la necesidad de mejorar la calidad y la estructura interna de los datos, particularmente en lo relativo a la definición y organización del surtido. Se recomienda revisar y depurar las clases y subclases, ya que la estructura actual presenta niveles de granularidad heterogéneos y, en algunos casos, redundantes. Una reorganización más coherente permitiría que las clases representaran categorías amplias y conceptualmente claras, mientras que las subclases, si bien específicas, podrían optimizarse para evitar dispersiones innecesarias. Una estructura más prolija facilitaría la interpretación, permitiría identificar tendencias con mayor precisión y potenciaría los análisis realizados tanto en procesos de modelado como en el dashboard de Power BI.
- En la misma línea, se sugiere revisar y optimizar el Modelo Entidad–Relación (MER), donde se detectaron redundancias e ineficiencias contrarias a las buenas prácticas de diseño de bases de datos. Una revisión estructural y la normalización de ciertas tablas permitirían reducir ambigüedades, mejorar la consistencia lógica y habilitar procesos analíticos más robustos.
- Ampliar el alcance temporal y geográfico del análisis: incorporar nuevas sucursales y más años de información permitirá validar la estabilidad de los patrones observados y capturar variaciones estacionales o asociadas al contexto económico.
- Incorporar métricas adicionales de valor de cliente: integrar indicadores como margen, rentabilidad neta o recurrencia anual permitirá comprender el aporte económico de cada perfil y alinear los incentivos del programa de fidelidad con el valor real del cliente.
- Optimizar la infraestructura técnica: migrar parte del procesamiento a un entorno cloud o de alto rendimiento permitirá ejecutar modelos más complejos (como autoencoders variacionales o clustering jerárquico), actualmente limitados por la capacidad de memoria y procesamiento.
- Desarrollar modelos predictivos: una vez que se cuente con una segmentación más definida, robusta y construida sobre datos depurados, los resultados podrán utilizarse como insumo para

modelos predictivos de mayor complejidad, tales como predicción de churn, recomendación personalizada o estimación de propensión a compra. Esto permitiría avanzar hacia estrategias de fidelización más dinámicas y adaptativas, donde las acciones comerciales se ajusten en función del riesgo de abandono, el valor proyectado del cliente y su evolución dentro de los distintos perfiles de comportamiento.

- Profundizar en el análisis por proveedor: Conectar los resultados con los acuerdos comerciales y el surtido permitiría identificar oportunidades conjuntas entre la cadena y sus socios estratégicos (promociones, incentivos compartidos, estrategias de surtido por segmento.
- Formalizar una hoja de ruta ETL: definir fuentes, procesos de limpieza, normalización y actualización periódica en Snowflake permitirá recalcular embeddings y clusters de forma estable y automatizada, integrando sus resultados en el dashboard analítico.

BIBLIOGRAFÍA

Adobe Experience Cloud Team. (2025, 21 de marzo). Market segmentation — definition, types, and examples. Adobe Business. https://business.adobe.com/blog/basics/market-segmentation

Awan, A. (2024, 9 de diciembre). Introduction to t-SNE. https://www.datacamp.com/tutorial/introduction-t-sne

Chen, F., Zhang, T., & Liu, R. (2021, 2 de agosto). An active learning method based on variational autoencoder and DBSCAN clustering. Computational Intelligence and Neuroscience, 2021, Article 9952596. https://doi.org/10.1155/2021/9952596

Contentsquare. (2024, 18 de agosto). Segmentación de clientes: definición, ejemplos y ventajas. https://contentsquare.com/es-es/guias/segmentacion-de-clientes/

Córdoba, G. (2011, 10 de febrero). Análisis RFM en retail. Empezando a segmentar clientes (I). Unica360. https://www.unica360.com/analisis-rfm-en-retail-empezando-a-segmentar-clientes-i

Dickey, D. A., & Fuller, W. A. (1979). *Distribution of the estimators for autoregressive time series with a unit root*. Journal of the American Statistical Association, 74(366), 427–431. Taylor & Francis Online+1

Dickey, D. A., & Fuller, W. A. (1981). *Likelihood ratio statistics for autoregressive time series with a unit root*. Econometrica. scirp.org

Geeks for Geeks. (2025, 11 de julio). Silhouette Algorithm to determine the optimal value of k. Geeks for Geeks. https://www.geeksforgeeks.org/machine-learning/silhouette-algorithm-to-determine-the-optimal-value-of-k/

Goldberg, Y., & Levy, O. (2014). word2vec explained: Deriving Mikolov et al.'s negative-sampling word-embedding method. https://arxiv.org/abs/1402.3722

IBM (2025, 1 de abril). ¿Qué es el análisis de componentes principales (PCA)?. https://www.ibm.com/es-es/think/topics/principal-component-analysis

Idrees, H. (2024, 22 de octubre). K-Means vs. DBSCAN: Clustering algorithms for grouping data. Medium. https://medium.com/@hassaanidrees7/k-means-vs-dbscan-clustering-algorithms-for-grouping-data-a4969034cfcc

Johnson, M., Duvenaud, D., Wiltschko, A. B., Adams, R. P., & Datta, S. R. (2016). Composing graphical models with neural networks for structured representations and fast inference. Advances in Neural Information Processing Systems, 29.

Karl, T. (2024, 12 de febrero). DBSCAN vs. K-Means: A guide in Python. New Horizons. https://www.newhorizons.com/resources/blog/dbscan-vs-kmeans-a-guide-in-python

Ma, L., & Zhang, Y. (2015). Using Word2Vec to process big text data. 2015 IEEE International Conference on Big Data (Big Data). https://ieeexplore.ieee.org/abstract/document/7364114

Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient estimation of word representations in vector space. arXiv. https://arxiv.org/abs/1301.3781

Montgomery, D. C., & Runger, G. C. (2014). Applied Statistics and Probability for Engineers (6th ed.). Wiley. https://kolegite.com/EE_library/books_and_lectures/%D0%9C%D0%B0%D1%82%D0%B5%D0%BC%D0%B0%D1%82%D0%B8%D0%BA%D0%B0/Applied%20Statistics%20and%20Probability%20for%20Engineering.pdf

Montgomery, D. C. (2017). Design and Analysis of Experiments (9th ed.). Wiley. https://appliedscincesheet.uoanbar.edu.iq/catalog/Design%20and%20analysis%20of%20experiments%201.pdf

Mushtaq, R. (2011). Testing Time Series Data for Stationarity. SSRN Electronic Journal. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=1911068

Ng, A. (2011). CS294A Lecture Notes. Stanford University. https://web.stanford.edu/class/cs294a/sparseAutoencoder_2011new.pdf

Oliver, R. L. (1999). Whence consumer loyalty? Journal of Marketing, 63(Special Issue), 33–44.
Rodriguez, D. (2023, 9 de junio). Método del codo (Elbow method) para seleccionar el número óptimo de clústeres en K-means. https://www.analyticslane.com/2023/06/09/metodo-del-codo-elbow-method-para-seleccionar-el-numero-optimo-de-clusteres-en-k-means/

Radford, A., Narasimhan, K., Salimans, T., & Sutskever, I. (2018). Improving Language Understanding by Generative Pre-Training. OpenAI.

Rojas Huamán, A. (2020). Análisis de datos para identificar perfiles de clientes por características similares de hábitos de compras [Trabajo de fin de máster, Universidad Politécnica de Madrid]. Escuela Técnica Superior de Ingenieros Informáticos.

Rong, X. (2014). word2vec parameter learning explained. arXiv. https://arxiv.org/abs/1411.2738

Saha, R. (2023, 4 de mayo). Influence of various text embeddings on clustering performance in NLP. arXiv. https://doi.org/10.48550/arXiv.2305.03144

Scikit-learn Developers. (s. f.). 2.3. Clustering — scikit-learn 1.7.2 documentation. Recuperado de https://scikit-learn.org/stable/modules/clustering.html#calinski-harabasz-index

Syahra, Y., Fadlil, A., & Yuliansyah, H. (2025). Customer segmentation using RFM and K-Means clustering to support CRM in retail industry. Sinkron: Jurnal dan Penelitian Teknik Informatika, 9(3), 1120–1131. https://doi.org/10.33395/sinkron.v9i3.14974

Trovar, J. (2023, 28 de febrero). Método Elbow y método de siluetas para la determinación del número de clústeres en K-means. https://forum.huawei.com/enterprise/intl/es/thread/m%C3%A9todo-elbow-y-m%C3%A9todo-de-siluetas-para-la-determinaci%C3%B3n-del-n%C3%BAmero-de-cl%C3%BAsteres-en-k-means/667237354135502848?blogId=667237354135502848

Tschannen, M., Bachem, O., & Lucic, M. (2018). Recent advances in autoencoder-based representation learning. https://arxiv.org/abs/1812.05069

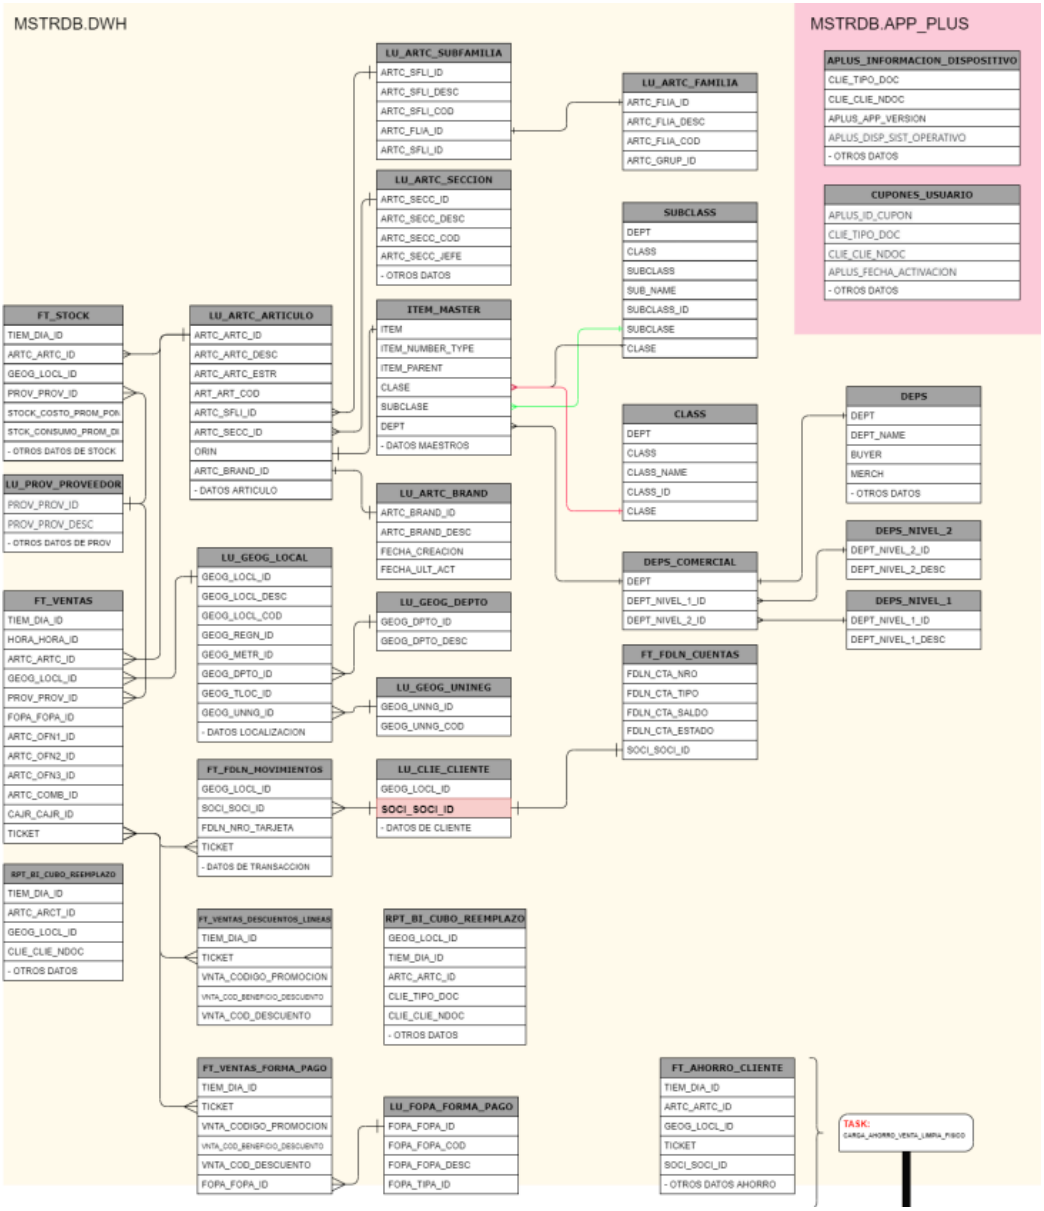
Turney, P. D., & Pantel, P. (2010). From frequency to meaning: Vector space models of semantics. Journal of Artificial Intelligence Research, 37, 141–188.

Van den Oord, A., Vinyals, O., & Kavukcuoglu, K. (2017). Neural discrete representation learning. arXiv preprint arXiv:1711.00937.

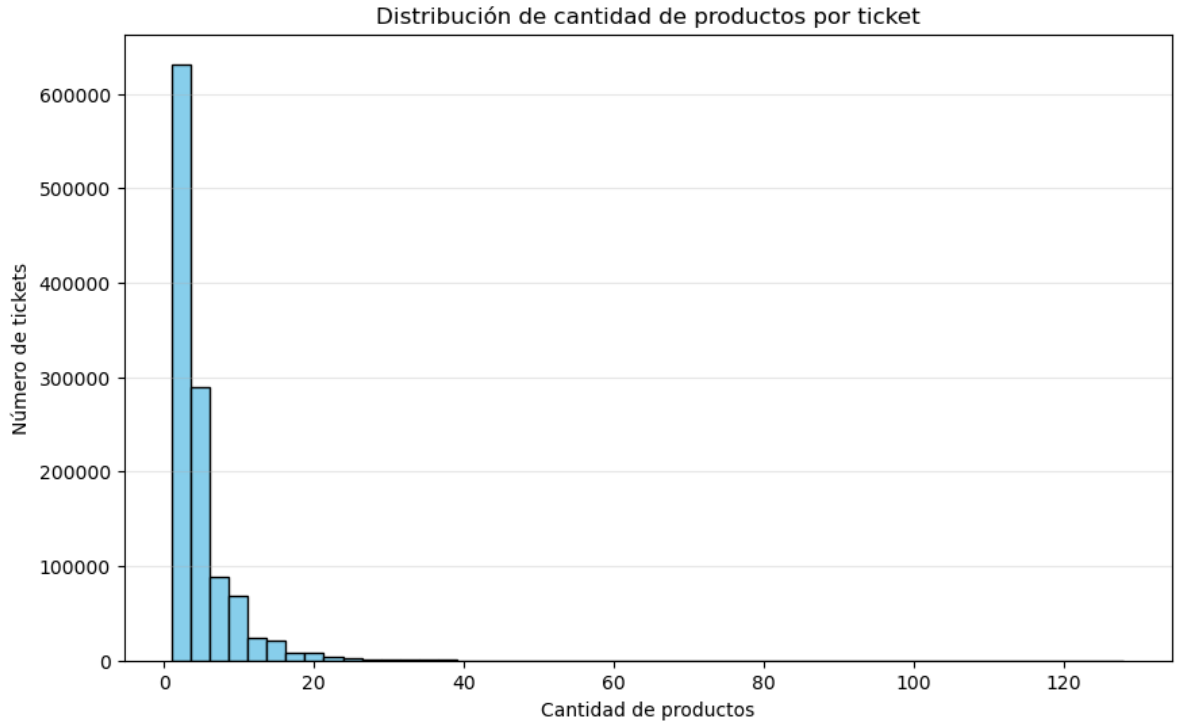
Zhang, Y. (2018). A better autoencoder for image: Convolutional autoencoder. https://www.semanticscholar.org/paper/A-Better-Autoencoder-for-Image%3A-Convolutional-Zhang/b1786e74e233ac21f503f59d03f6af19a3699024

ANEXOS

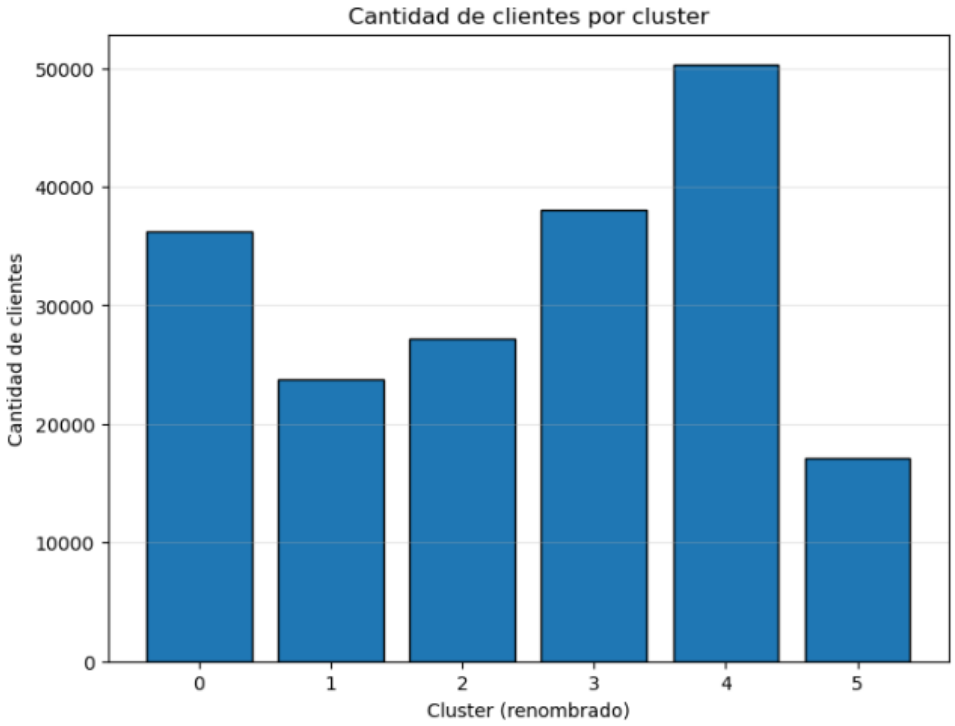
Anexo 1 - Modelo Entidad-Relación de la base de datos

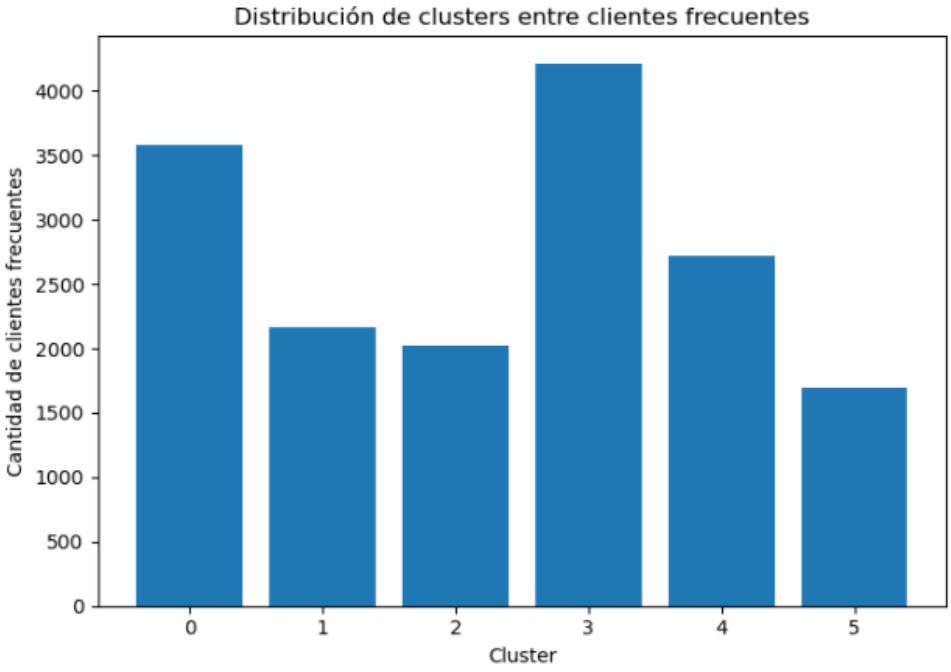


Anexo 2 - Gráfica utilizada para determinar la ventana de contexto de Word2Vec



Anexo 3 - Distribución de clientes frecuentes y no frecuentes por cluster





Anexo 4 – Queries utilizadas para la obtención y transformación de los datos de entrada del PBI

---- TABLA TRANSACCIONAL

```
SELECT
    TO_NUMBER(TO_VARCHAR(V.TIEM_DIA_ID, 'YYYYMM'))  AnioMes,
    V.GEOG_LOCL_ID                                  IdSucursal,
    SC.SUBCLASE                                     CodSubClase,
    V.PROV_PROV_ID                                  IdProveedor,
    SUM(V.VNTA_UNIDADES)                            CantidadVendida,
    SUM(V.VNTA_IMPORTE_CON_IVA)                     SumaImporte
FROM MSTRDB.DWH.FT_VENTAS           V
JOIN MSTRDB.DWH.LU_ARTC_ARTICULO    A  ON A.ARTC_ARTC_ID = V.artc_artc_id
JOIN MSTRDB.DWH.ITEM_MASTER         I  ON I.item         = A.orin
JOIN MSTRDB.DWH.CLASS               C  ON C.clase        = I.clase
JOIN MSTRDB.DWH.SUBCLASS            SC ON SC.clase       = I.clase
                                      AND SC.subclase = I.subclase
JOIN MSTRDB.DWH.LU_GEOG_LOCAL       G  ON G.GEOG_LOCL_ID = V.GEOG_LOCL_ID
WHERE TO_NUMBER(TO_VARCHAR(V.TIEM_DIA_ID, 'YYYYMM')) >= (YEAR(CURRENT_DATE())- 2)* 100 + 01 |
    AND C.CLASE NOT IN (1980001, 490002, 910001)
    AND SC.SUBCLASE NOT IN (300010001, 13600020002, 13600010002, -1)
    AND G.GEOG_UNNG_ID NOT IN (3, 4, 5, 7, 8, 9, 11)
    AND G.GEOG_TLOC_ID NOT IN (6, 7, 11, 12)
    AND G.GEOG_LOCL_ID NOT IN (200, 202, 204, 307, 221, 306, 155, 122, 123, 174, 152, 70)
GROUP BY TO_NUMBER(TO_VARCHAR(V.TIEM_DIA_ID, 'YYYYMM')), V.GEOG_LOCL_ID, SC.SUBCLASE , V.PROV_PROV_ID
ORDER BY TO_NUMBER(TO_VARCHAR(V.TIEM_DIA_ID, 'YYYYMM')) ASC, V.GEOG_LOCL_ID, SC.SUBCLASE , V.PROV_PROV_ID
```

--- CODIGUERAS

-------- codiguera proveedores

```
SELECT DISTINCT P.PROV_PROV_ID      IdProveedor,
                P.PROV_PROV_COD     CodProveedor,
                P.PROV_PROV_DESC    Proveedor,
                P.PROV_PROV_PAIS    PaisProveedor
FROM MSTRDB.DWH.FT_VENTAS           V
JOIN MSTRDB.DWH.LU_PROV_PROVEEDOR   P  ON P.PROV_PROV_ID = V.PROV_PROV_ID
WHERE TO_NUMBER(TO_VARCHAR(V.TIEM_DIA_ID, 'YYYYMM')) >= TO_NUMBER(TO_VARCHAR(ADD_MONTHS(CURRENT_DATE(), -24), 'YYYYMM'))
```

-------- codiguera Subclases

```
WITH TipoVentaPorSubclase AS (
    SELECT
        SC.SUBCLASE AS CodSubClase,
        CASE
            WHEN SUM(CASE WHEN MOD(V.VNTA_UNIDADES, 1) > 0 THEN 1 ELSE 0 END) > 0 THEN 'peso'
            ELSE 'unidad'
        END AS TipoVenta
    FROM MSTRDB.DWH.FT_VENTAS V
    JOIN MSTRDB.DWH.LU_ARTC_ARTICULO A ON A.ARTC_ARTC_ID = V.artc_artc_id
    JOIN MSTRDB.DWH.ITEM_MASTER I ON I.item = A.orin
    JOIN MSTRDB.DWH.SUBCLASS SC ON SC.clase = I.clase AND SC.subclase = I.subclase
    WHERE TO_NUMBER(TO_VARCHAR(V.TIEM_DIA_ID, 'YYYYMM')) >= TO_NUMBER(TO_VARCHAR(ADD_MONTHS(CURRENT_DATE(), -36), 'YYYYMM'))
        AND V.VNTA_UNIDADES > 0
        AND V.VNTA_IMPORTE_CON_IVA > 0
        AND SC.SUBCLASE NOT IN (300010001, 13600020002, 13600010002)
    GROUP BY SC.SUBCLASE
)

SELECT DISTINCT
    SC.SUBCLASE       AS CodSubClase,
    SC.SUB_NAME       AS SubClase,
    SC.CLASE          AS CodClase,
    TV.TipoVenta      AS TipoVenta
FROM MSTRDB.DWH.ITEM_MASTER I
JOIN MSTRDB.DWH.SUBCLASS SC ON SC.clase = I.clase AND SC.subclase = I.subclase
INNER JOIN TipoVentaPorSubclase TV ON TV.CodSubClase = SC.SUBCLASE
```

-------- codiguera clase

```
SELECT DISTINCT CLASE       CodClase,
                CLASS_NAME  Clase
FROM MSTRDB.DWH.CLASS
```

-------- codiguera sucursales

```
WITH SucursalesConVentas AS (
    SELECT DISTINCT V.GEOG_LOCL_ID AS IdSucursal
    FROM MSTRDB.DWH.FT_VENTAS V
    WHERE TO_NUMBER(TO_VARCHAR(V.TIEM_DIA_ID, 'YYYYMM')) >= TO_NUMBER(TO_VARCHAR(ADD_MONTHS(CURRENT_DATE(), -36), 'YYYYMM'))
        AND V.VNTA_UNIDADES > 0
        AND V.VNTA_IMPORTE_CON_IVA > 0
)

SELECT DISTINCT
    LOC.GEOG_LOCL_ID       AS IdSucursal,
    LOC.GEOG_LOCL_COD      AS CodSucursal,
    LOC.GEOG_LOCL_DESC     AS Sucursal,
    LOC.GEOG_LOCL_LAT      AS LatitudSucursal,
    LOC.GEOG_LOCL_LON      AS LongitudSucursal,
    LOC.GEOG_LOCL_CIUDAD   AS CiudadSucursal,
    CASE
        WHEN ( LOC.GEOG_LOCL_DESC LIKE '%PEYA%' OR LOC.GEOG_LOCL_DESC LIKE '%ECOMMERCE%' OR LOC.GEOG_LOCL_DESC = 'Darkstore') THEN NULL
        WHEN LOC.GEOG_LOCL_CIUDAD = 'Montevideo' THEN 'Montevideo'
        WHEN (GEOG_LOCL_CIUDAD IS NULL OR GEOG_LOCL_CIUDAD = 'No especificado') AND LOC.GEOG_LOCL_DESC IN ('Shopping', 'Portones') THEN 'Montevideo'
        ELSE 'Interior'
    END                     AS ZonaSucursal,
    CASE
        WHEN ( LOC.GEOG_LOCL_DESC LIKE '%PEYA%' OR LOC.GEOG_LOCL_DESC LIKE '%ECOMMERCE%' OR LOC.GEOG_LOCL_DESC = 'Darkstore') THEN 1
        ELSE 0
    END                     AS VentaDigital,
    CASE WHEN LOC.GEOG_LOCL_DESC LIKE '%PEYA%' THEN 'PEYA' ELSE GTL.GEOG_TLOC_DESC END    AS TipoLocal
FROM MSTRDB.DWH.LU_GEOG_LOCAL LOC
JOIN SucursalesConVentas            S    ON S.IdSucursal = LOC.GEOG_LOCL_ID
JOIN MSTRDB.DWH.LU_GEOG_TIPO_LOCAL  GTL  ON GTL.GEOG_TLOC_ID = LOC.GEOG_TLOC_ID
WHERE LOC.GEOG_UNNG_ID NOT IN (3, 4, 5, 7, 8, 9, 11)
    AND LOC.GEOG_TLOC_ID NOT IN (6, 7, 11, 12)
    AND LOC.GEOG_LOCL_ID NOT IN (200, 202, 204, 307, 221, 306, 155, 122, 123, 174, 152, 70)
```

Anexo 5 – Medidas y parámetros del dashboard

```
_Ventas_Dinamico =
VAR Unidad = SELECTEDVALUE('Unidad_Visualizacion'[Unidad])

RETURN
    SWITCH(TRUE, Unidad = "Unidades", SUM(Trx_Summarized[CANTIDADVENDIDA]), Unidad = "Importe $",SUM
    (Trx_Summarized[SUMAIMPORTE]) )
```

```
_Ventas_Mensual_UltAño =
 VAR MaxMeAnioMes =  CALCULATE(MAX(Trx_Summarized[ANIOMES]), ALL(Trx_Summarized))
VAR AnioMax = LEFT(MaxMeAnioMes,4)
VAR AnioPrevio = AnioMax - 1
VAR MesMax = RIGHT(MaxMeAnioMes,2)


VAR MeAnioMesInicio = VALUE(AnioPrevio & MesMax)

RETURN
    CALCULATE(
    Trx_Summarized[_Ventas_Dinamico],
    Trx_Summarized[ANIOMES] >= MeAnioMesInicio
)
```

```
_Ventas_Año_Parcial =
VAR FechaMaxActual = CALCULATE(MAX(Trx_Summarized[ANIOMES]), ALL(Trx_Summarized))
VAR MesFechaMax = RIGHT(FechaMaxActual,2)
VAR AnioSeleccionado = SELECTEDVALUE(CalendarioMeses[Año])


VAR Inicio = VALUE(AnioSeleccionado & "01")
VAR Corte = VALUE(AnioSeleccionado & MesFechaMax)


RETURN
CALCULATE(
    Trx_Summarized[_Ventas_Dinamico],
    Trx_Summarized[ANIOMES] >= Inicio &&
    Trx_Summarized[ANIOMES] <= Corte
)
```

```
Parametro de Agrupación de Fechas = {
    ("Mensual (Último Año Móvil)", NAMEOF('CalendarioMeses'[Short_Month]), 0),
    ("Quarter", NAMEOF('CalendarioMeses'[AnioQuarter]), 1),
    ("Anual", NAMEOF('CalendarioMeses'[Año]), 2),
    ("Año Parcial", NAMEOF('CalendarioMeses'[Año2]), 3)
}
```

```
_Ventas_Mix =
VAR __SelectedValue =SELECTEDVALUE('Parametro de Agrupación de Fechas'[Parameter Fields])

RETURN
    SWITCH(
    TRUE(),
    __SelectedValue = "'CalendarioMeses'[Short_Month]", CALCULATE(Trx_Summarized[_Ventas_Mensual_UltAño]),
    __SelectedValue = "'CalendarioMeses'[Año2]",         CALCULATE(Trx_Summarized[_Ventas_Año_Parcial]),
                                                            [_Ventas_Dinamico]
    )
```

```
_Ventas_dinamico_PrevYear =
VAR MesesActuales =
    VALUES ( 'CalendarioMeses'[MeAnioMes] )

VAR MesesPrevioAnio =
    SELECTCOLUMNS(
        MesesActuales,
        "AnioMesPrev", [MeAnioMes] - 100
    )

VAR MaxMesReal =
    CALCULATE(
        MAX ( 'Trx_Summarized'[AnioMes] ),
        ALL ( 'Trx_Summarized' )
    )

RETURN
IF( MAX ( 'CalendarioMeses'[MeAnioMes] ) > MaxMesReal, BLANK(),
    CALCULATE(
        [_Ventas_dinamico],
        REMOVEFILTERS ( 'CalendarioMeses' ),
        TREATAS(
            MesesPrevioAnio,
            'Trx_Summarized'[AnioMes]
        )
    )
)
```

```
_Ventas_dinamico_YoY% =
VAR VentasActual    = [_Ventas_dinamico]
VAR VentasPrevYear = [_Ventas_dinamico_PrevYear]
RETURN
IF(
    NOT ISBLANK(VentasPrevYear) && VentasPrevYear <> 0,
    DIVIDE( VentasActual - VentasPrevYear, VentasPrevYear ),
    BLANK()
)
```

```
_Tarj_ParticipacionProveedor =
VAR ImporteFiltro =
    SUM( Trx_Summarized[SUMAIMPORTE] )

VAR ImporteTotal =
    CALCULATE(
        SUM( Trx_Summarized[SUMAIMPORTE] ),
        REMOVEFILTERS( Proveedores )
    )

RETURN
    DIVIDE( ImporteFiltro, ImporteTotal )
```

```
_Tarj_ParticipacionSubclase =
VAR ImporteFiltro =
    SUM( Trx_Summarized[SUMAIMPORTE] )

VAR ImporteTotal =
    CALCULATE(
        SUM( Trx_Summarized[SUMAIMPORTE] ),
        REMOVEFILTERS( Subclases )
    )

RETURN
    DIVIDE( ImporteFiltro, ImporteTotal )
```

```
_Tarj_ParticipacionSucursal =
VAR ImporteFiltro =
    SUM( Trx_Summarized[SUMAIMPORTE] )

VAR ImporteTotal =
    CALCULATE(
        SUM( Trx_Summarized[SUMAIMPORTE] ),
        REMOVEFILTERS( Sucursales )
    )

RETURN
    DIVIDE( ImporteFiltro, ImporteTotal )
```

```
_Tarj_ImporteTotal_MismaAlturaAñoAnterior =
VAR UltimoAnioMes =
    CALCULATE(
        MAX ( Trx_Summarized[ANIOMES] ),
        ALL ( Trx_Summarized[ANIOMES] )
    )

VAR PenultimoAno =  VALUE( LEFT(UltimoAnioMes, 4)) - 1
VAR UltimoMes =  VALUE( RIGHT(UltimoAnioMes, 2))

RETURN
CALCULATE(
    SUM ( Trx_Summarized[SUMAIMPORTE] ),
    CalendarioMeses[Año] = PenultimoAno , CalendarioMeses[MesNro] <= UltimoMes
)
```

ANÁLISIS ESTADÍSTICO

Para evaluar rigurosamente los patrones temporales presentes en la serie de ventas del supermercado, se incorporó un análisis estadístico orientado a testear la existencia de tendencia, estacionalidad y estacionalidad semanal. En primer lugar, se aplicó la prueba de raíz unitaria ADF (Augmented Dickey-Fuller) con el objetivo de determinar si la serie presenta estacionariedad o evidencia de tendencia estocástica. Luego, mediante la descomposición STL se extrajeron explícitamente las componentes de tendencia, estacionalidad y residuo, permitiendo contrastar estadísticamente si la estacionalidad difiere de cero de forma sistemática. Finalmente, se evaluó la presencia de estacionalidad semanal mediante un ANOVA de un factor, comparando las medias de ventas entre días de la semana. En conjunto, estas pruebas permiten caracterizar formalmente la dinámica temporal de la serie.

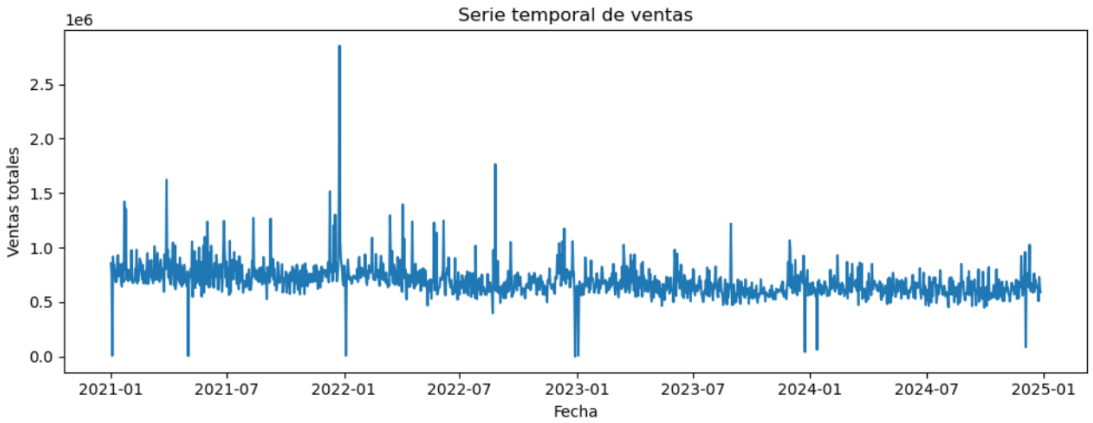


Figura 4.3.3 - Serie temporal de ventas diarias (2021–2025).

La serie original presenta una volatilidad considerable con picos pronunciados, especialmente al inicio. Estos comportamientos extremos sugieren la ocurrencia de eventos de venta excepcionales, particularmente concentrados en los últimos días de cada año.

Los resultados de la prueba ADF indican que la serie de ventas no presenta una raíz unitaria. El estadístico obtenido (–4.76) y su p-valor asociado (0.0000638) permiten rechazar la hipótesis nula de no estacionariedad con un nivel de confianza del 95%. Esto sugiere que la serie es estacionaria en términos estocásticos y, por lo tanto, no presenta una tendencia persistente que evolucione en el tiempo, lo cual es consistente con la estructura temporal observada en los datos.

La descomposición de la serie de tiempo separa los datos observados en sus componentes fundamentales: tendencia, estacionalidad y residual.

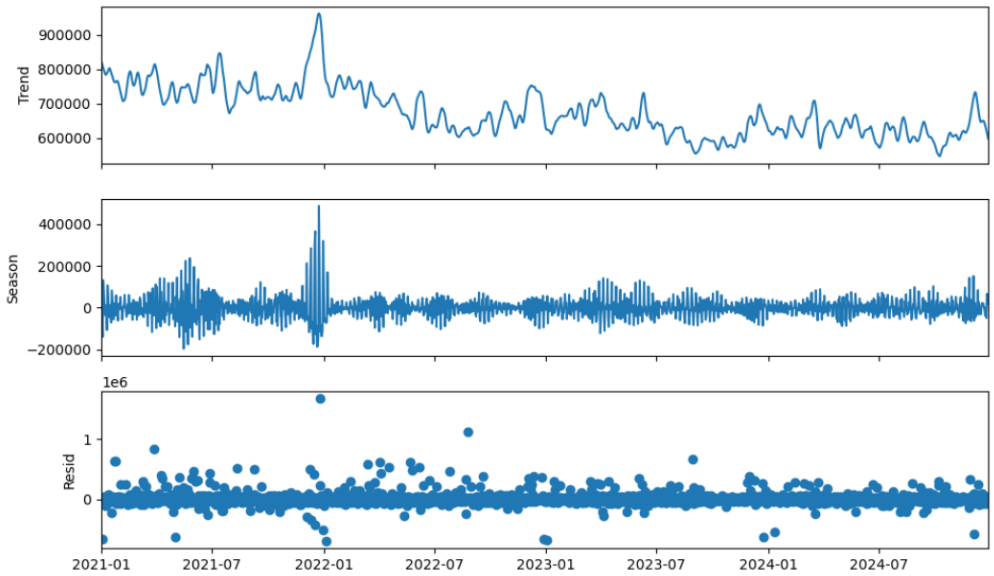


Figura 4.3.4 - Descomposición de la serie de ventas en tendencia, estacionalidad y residuo.

La tendencia a largo plazo muestra una evolución no lineal de las ventas. Se identifica un crecimiento sostenido durante 2021, que alcanza un máximo hacia finales de ese año o comienzos de 2022. A partir de ese punto, se observa una fase de contracción generalizada durante 2022 y 2023, caracterizada por una disminución gradual de la base de ventas. Hacia 2024, la tendencia se estabiliza en un nivel más bajo, lo que indica que el descenso se detuvo, aunque sin señales de recuperación hacia los valores máximos previos.

En relación con la estacionalidad, la serie muestra oscilaciones recurrentes a lo largo del período analizado, lo que visualmente sugiere la presencia de patrones cíclicos asociados a factores temporales regulares, posiblemente vinculados a ciclos semanales, mensuales o a festividades anuales que impulsan la demanda. Además, la amplitud de estos ciclos parece atenuarse en los años más recientes (2023–2024) respecto a 2021–2022, lo que podría reflejar un cambio en la sensibilidad de las ventas a estos factores estacionales.

Con el objetivo de evaluar la presencia de estacionalidad sistemática, se realizó una prueba t para contrastar si la componente estacional extraída mediante la descomposición STL presenta media distinta de cero. Se testeó H0: μ estacional = 0. El p-valor obtenido (0.998) es ampliamente superior al umbral de significación del 5%. Por lo tanto, no se rechaza la hipótesis nula, lo que indica que, aunque existen fluctuaciones visibles a lo largo del tiempo, estas no son lo suficientemente consistentes ni estables como para considerarse un patrón estacional persistente. En consecuencia, la evidencia estadística sugiere que la serie no presenta estacionalidad sistemática, más allá de las variaciones puntuales observadas en el gráfico.

Para evaluar la presencia de estacionalidad semanal en la serie de ventas, se aplicó un ANOVA de un factor, utilizando como grupos los valores de ventas correspondientes a cada día de la semana. Bajo la hipótesis nula se plantea que las medias de ventas son iguales entre los siete días, lo que implicaría ausencia de diferencias sistemáticas asociadas al día de la semana. El p-valor obtenido (0.602) es considerablemente superior al nivel de significación del 5%, por lo que no se rechaza la hipótesis nula. En consecuencia, no se encuentra evidencia estadística de estacionalidad semanal fuerte, lo que sugiere que, en promedio, las ventas no difieren de manera significativa entre los distintos días de la semana.

Por último, el componente residual recoge la variación no explicada por la tendencia ni la estacionalidad, integrando tanto ruido como eventos aleatorios. La concentración de residuos en torno a cero indica que la descomposición captura adecuadamente la mayor parte de la dinámica de la serie. Sin embargo, la presencia de outliers significativos revela la existencia de eventos atípicos de gran magnitud, más allá de los patrones regulares, que impactaron las ventas, destacándose entre ellos el pico extraordinario registrado a fines de 2021.